TRƯỜNG ĐẠI HỌC SÀI GÒN
KHOA CÔNG NGHỆ THÔNG TIN

--------***--------

BÁO CÁO MÔN HỌC
MÁY HỌC

LAB05. PHÂN TÍCH KHÁM PHÁ DỮ LIỆU

Giảng viên hướng dẫn:	TS. Đỗ Như Tài
Nhóm sinh viên thực hiện:	**Mã số sinh viên:**
Cao Ngọc Hân	3124411083
Nguyễn An Nhung	3124411203
Trần Đỗ Khánh Linh	3124411151

Thành phố Hồ Chí Minh, tháng 10 năm 2026

LỜI MỞ ĐẦU

Trong thời đại dữ liệu bùng nổ như hiện nay, hầu hết các bài toán trong lĩnh vực Khoa học dữ liệu và Học máy đều bắt đầu từ một câu hỏi rất cơ bản: dữ liệu mình đang có thực sự trông như thế nào? Trước khi nghĩ tới việc chọn mô hình hay tinh chỉnh tham số, người làm dữ liệu cần hiểu rõ cấu trúc, phân phối, chất lượng và các mối quan hệ ẩn bên trong tập dữ liệu. Đó chính là vai trò của Phân tích khám phá dữ liệu (Exploratory Data Analysis – EDA).

Bài báo cáo "Phân tích khám phá dữ liệu" được nhóm em thực hiện dựa trên tài liệu thực hành của môn học, gồm ba phần chính: Thống kê mô tả, Xử lý và trực quan hóa dữ liệu, Phân tích đơn biến và hai biến. Nhóm em đã áp dụng các kỹ thuật này trên nhiều tập dữ liệu thực tế khác nhau: dữ liệu chất lượng rượu đỏ (Red Wine Quality), dữ liệu bệnh tiểu đường (Pima Indians Diabetes), dữ liệu bán lẻ trực tuyến (Online Retail) và dữ liệu chiến dịch tiếp thị (Customer Personality Analysis – Marketing Campaign).

Do kiến thức và kinh nghiệm còn hạn chế, báo cáo chắc chắn không tránh khỏi những thiếu sót. Nhóm em rất mong nhận được sự góp ý của Thầy để bài báo cáo được hoàn thiện hơn.

LỜI CẢM ƠN

Để hoàn thành bài báo cáo thực hành này, nhóm em xin gửi lời cảm ơn chân thành và sâu sắc nhất đến thầy Đỗ Như Tài.

Trong suốt quá trình học tập và thực hiện bài lab, nhờ những bài giảng tâm huyết, tài liệu thực hành được biên soạn chi tiết cùng sự hướng dẫn tận tình của thầy, nhóm em mới có thể tiếp cận quy trình phân tích khám phá dữ liệu một cách bài bản, từ thống kê mô tả, trực quan hóa cho đến phân tích đơn biến, hai biến và sử dụng các công cụ EDA tự động.

Do kiến thức chuyên môn và kinh nghiệm thực tế còn nhiều giới hạn, bài làm khó tránh khỏi những thiếu sót trong quá trình xử lý dữ liệu, lựa chọn biểu đồ hay diễn giải kết quả. Kính mong thầy thông cảm và góp ý để nhóm em rút kinh nghiệm cho các bài thực hành và dự án sau.

Nhóm em xin kính chúc thầy luôn dồi dào sức khỏe, hạnh phúc và thành công trong sự nghiệp giáo dục!

Nhóm em xin chân thành cảm ơn!

NHẬN XÉT CỦA GIẢNG VIÊN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

PHÂN CÔNG

MSSV	Tên	Phân công
3124411083	Cao Ngọc Hân	Nhóm Trưởng Mục 1.1: - Thống kê mô tả (Mean, Std, Median, IQR,...) & Tiền xử lý / Làm sạch dữ liệu . - Soạn Báo cáo Word (.docx) (Tổng hợp & trả lời lý thuyết)
3124411203	Nguyễn An Nhung	Mục 1.2: - Trực quan hóa dữ liệu cơ bản bằng Matplotlib & Seaborn (Bar Chart, Subplots) - Soạn Báo cáo Word (.docx) (Tổng hợp & trả lời lý thuyết)
3124411151	Trần Đỗ Khánh Linh	Mục 1.3: - Phân tích Đơn/Hai biến (Penguins, Housing) & Chạy EDA tự động (ydata_profiling, D-Tale). - Thiết kế Slide PowerPoint (.pptx)

MỤC LỤC

LỜI MỞ ĐẦU 2
LỜI CẢM ƠN 3
NHẬN XÉT CỦA GIẢNG VIÊN 4
PHÂN CÔNG 5
Chương 1. TỔNG QUAN BÀI THỰC HÀNH & MÔI TRƯỜNG PHÂN TÍCH 8
1.1. Mục tiêu của bài thực hành 8
1.2. Kết cấu bài thực hành và dữ liệu sử dụng 8
Chương 2. THỐNG KÊ MÔ TẢ 10
2.1. Cơ sở lý thuyết về thống kê mô tả 10
2.2. Bài tập thực hành 1 – Thống kê mô tả dữ liệu rượu đỏ (Red Wine Quality) 15
2.3. Bài tập thực hành 2 – Thống kê mô tả dữ liệu bệnh tiểu đường (Pima Indians Diabetes) 23
2.4. Tổng kết Chương 2 31
Chương 3. XỬ LÝ VÀ TRỰC QUAN HÓA DỮ LIỆU 32
3.1. Cơ sở lý thuyết về xử lý và trực quan hóa dữ liệu 32
3.2. Bài tập thực hành 1 – Trực quan hóa dữ liệu rượu đỏ 36
3.3. Bài tập thực hành 2 – Phần A: Trực quan hóa dữ liệu bệnh tiểu đường 43
3.4. Bài tập thực hành 2 – Phần B: EDA dữ liệu mua sắm Online Retail 50
3.5. Tổng kết kết quả phân tích khám phá dữ liệu 62
Chương 4. PHÂN TÍCH ĐƠN BIẾN VÀ HAI BIẾN 63

4.1. Cơ sở lý thuyết về phân tích đơn biến và hai biến 63
4.2. Bài tập thực hành 1 – Ứng dụng thư viện SweetViz 67
4.3. Bài tập thực hành 2 – Ứng dụng thư viện AutoViz 76
KẾT LUẬN 99
TÀI LIỆU THAM KHẢO 101

Chương 1. TỔNG QUAN BÀI THỰC HÀNH

1.1. Mục tiêu của bài thực hành

Bài thực hành "Phân tích khám phá dữ liệu" nhằm giúp người học nắm vững các kỹ thuật cơ bản trong khám phá dữ liệu để hiểu rõ đặc điểm và cấu trúc của tập dữ liệu. Theo tài liệu hướng dẫn, bài thực hành hướng đến ba mục tiêu chính:

Thống kê mô tả: thực hiện các bước phân tích thống kê mô tả để xác định các đặc trưng chính của dữ liệu như giá trị trung bình, trung vị, độ lệch chuẩn và phân bố của dữ liệu.

Trực quan hóa dữ liệu: sử dụng các công cụ trực quan hóa như histogram, boxplot, scatter plot để phát hiện các mẫu, xu hướng hoặc bất thường trong dữ liệu; làm quen với các thư viện Python như Pandas, Matplotlib và Seaborn.

Nhận diện vấn đề chất lượng dữ liệu: phát hiện giá trị thiếu, giá trị ngoại lai, dữ liệu không nhất quán; từ đó đề xuất phương pháp tiền xử lý phù hợp và đưa ra những nhận định ban đầu, làm nền tảng cho các bước phân tích sâu hơn hoặc xây dựng mô hình.

1.2. Kết cấu bài thực hành và dữ liệu sử dụng

Bài thực hành được chia thành 3 phần, tương ứng với các chương 2, 3, 4 của báo cáo. Ở mỗi phần, tài liệu đều có phần ôn tập lý thuyết, bài làm mẫu và các bài tập thực hành. Trong báo cáo này, nhóm em tập trung trình bày phần lý thuyết và toàn bộ các bài tập thực hành:

Phần 1.1 – Thống kê mô tả (Chương 2): Bài tập thực hành 1 trên dữ liệu chất lượng rượu đỏ; Bài tập thực hành 2 trên dữ liệu bệnh tiểu đường.

Phần 1.2 – Xử lý và trực quan hóa dữ liệu (Chương 3): Bài tập thực hành 1 trực quan hóa dữ liệu rượu đỏ; Bài tập thực hành 2 trực quan hóa dữ liệu bệnh tiểu đường và EDA trên dữ liệu mua sắm Online Retail.

Phần 1.3 – Phân tích đơn biến và hai biến (Chương 4): Bài tập thực hành 1 tìm hiểu thư viện SweetViz; Bài tập thực hành 2 tìm hiểu thư viện AutoViz, cả hai đều áp dụng trên dữ liệu Marketing Campaign.

Các tập dữ liệu được sử dụng trong báo cáo được tổng hợp trong bảng dưới đây (kích thước được lấy từ kết quả chạy code thực tế):

STT	Tập dữ liệu	Nguồn	Kích thước gốc	Sử dụng ở
1	Red Wine Quality (winequality-red.csv)	Kaggle / UCI	1.599 dòng × 12 cột	Chương 2, 3
2	Pima Indians Diabetes (diabetes.csv)	Kaggle / UCI	768 dòng × 9 cột	Chương 2, 3
3	Online Retail (Online Retail.xlsx)	Kaggle / UCI	541.909 dòng × 8 cột	Chương 3
4	Customer Personality Analysis (marketing_campaign.csv)	Kaggle	2.240 dòng × 29 cột	Chương 4

Bảng 1.1. Các tập dữ liệu sử dụng trong bài thực hành

Chương 2. THỐNG KÊ MÔ TẢ

2.1. Cơ sở lý thuyết về thống kê mô tả

2.1.1. Thống kê mô tả là gì? Khác gì với thống kê suy luận?

Thống kê mô tả (Descriptive Statistics) là tập hợp các phương pháp dùng để thu thập, tóm tắt, trình bày và mô tả các đặc trưng của một tập dữ liệu thông qua các con số (trung bình, trung vị, độ lệch chuẩn…), bảng biểu và biểu đồ. Mục tiêu của thống kê mô tả là trả lời câu hỏi "dữ liệu đang có trông như thế nào?", chỉ mô tả đúng những gì quan sát được mà không đưa ra kết luận vượt ra ngoài dữ liệu đó.

Tiêu chí	Thống kê mô tả	Thống kê suy luận
Mục đích	Tóm tắt, mô tả dữ liệu đang có	Suy rộng kết luận từ mẫu ra tổng thể
Phạm vi kết luận	Chỉ đúng cho tập dữ liệu quan sát	Áp dụng cho tổng thể, kèm sai số
Công cụ	Mean, median, mode, std, IQR, bảng tần số, biểu đồ	Khoảng tin cậy, kiểm định giả thuyết, hồi quy
Yếu tố xác suất	Không cần	Bắt buộc (p-value, độ tin cậy)
Vị trí trong EDA	Bước đầu tiên của EDA	Thực hiện sau khi đã hiểu dữ liệu

Bảng 2.1. So sánh thống kê mô tả và thống kê suy luận

2.1.2. Các thước đo thống kê mô tả chính và khi nào nên dùng trung vị thay cho trung bình

Các thước đo thống kê mô tả được chia thành ba nhóm chính:

Nhóm đo xu hướng trung tâm: cho biết giá trị "điển hình" của dữ liệu, gồm trung bình (mean), trung vị (median) và yếu vị (mode).

Nhóm đo độ phân tán: cho biết dữ liệu trải rộng hay tập trung quanh giá trị trung tâm, gồm khoảng biến thiên (range), phương sai (variance), độ lệch chuẩn (standard deviation), khoảng tứ phân vị (IQR) và hệ số biến thiên (CV).

Nhóm đo hình dạng phân phối: gồm độ lệch (skewness) và độ nhọn (kurtosis).

Thước đo	Công thức / Cách tính	Ý nghĩa
Trung bình (Mean)	$\bar{x} = (1/n)\cdot\Sigma x_i$	Giá trị trung bình cộng, nhạy cảm với ngoại lai

Thước đo	Công thức / Cách tính	Ý nghĩa
Trung vị (Median)	Giá trị đứng giữa sau khi sắp xếp tăng dần	Chia dữ liệu thành hai nửa bằng nhau, bền vững với ngoại lai
Yếu vị (Mode)	Giá trị xuất hiện nhiều nhất	Dùng tốt cho cả biến định tính
Phương sai (Variance)	$s^2 = \Sigma(x_i - \bar{x})^2 / (n - 1)$	Mức độ phân tán quanh trung bình (đơn vị bình phương)
Độ lệch chuẩn (Std)	$s = \sqrt{s^2}$	Độ phân tán trung bình, cùng đơn vị với dữ liệu
Khoảng biến thiên (Range)	Max − Min	Độ rộng toàn bộ dữ liệu
Tứ phân vị (Q1, Q2, Q3)	Các điểm chia dữ liệu tại 25%, 50%, 75%	Mô tả vị trí và phân bố dữ liệu
Khoảng tứ phân vị (IQR)	IQR = Q3 − Q1	Độ phân tán của 50% dữ liệu ở giữa
Bách phân vị (Percentile)	P_k: k% dữ liệu nhỏ hơn hoặc bằng P_k	Xác định vị trí tương đối của một giá trị
Hệ số biến thiên (CV)	$CV = s / \bar{x} \times 100\%$	So sánh độ phân tán giữa các biến khác đơn vị
Độ lệch (Skewness)	Mô-men bậc 3 chuẩn hóa	> 0: lệch phải; < 0: lệch trái; ≈ 0: đối xứng
Độ nhọn (Kurtosis)	Mô-men bậc 4 chuẩn hóa − 3	> 0: đuôi dày, nhiều giá trị cực trị

Bảng 2.2. Các thước đo thống kê mô tả chính

Khi nào nên dùng trung vị thay cho trung bình? Trung bình được tính từ tất cả các giá trị nên rất nhạy cảm với giá trị cực trị, trong khi trung vị chỉ phụ thuộc vào thứ tự nên gần như không bị ảnh hưởng. Vì vậy nên dùng trung vị trong các trường hợp:

Dữ liệu có phân phối lệch mạnh (ví dụ thu nhập, giá nhà, doanh thu, lượng đường dư trong rượu).

Dữ liệu có nhiều giá trị ngoại lai hoặc có lỗi nhập liệu chưa được xử lý.

Dữ liệu dạng thứ bậc (ordinal), nơi phép cộng trung bình không có ý nghĩa rõ ràng.

Khi điền giá trị thiếu cho biến số bị lệch – điền bằng trung vị sẽ không kéo lệch phân phối như điền bằng trung bình.

Ngược lại, với dữ liệu gần đối xứng, không có ngoại lai thì trung bình là lựa chọn tốt vì tận dụng được thông tin của toàn bộ quan sát và có nhiều tính chất toán học thuận lợi.

2.1.3. Cách xác định phân bố của tập dữ liệu và các loại phân bố phổ biến

Để xác định phân bố của một tập dữ liệu, nhóm em thường kết hợp ba cách tiếp cận:

Trực quan hóa: vẽ histogram kết hợp đường mật độ KDE để quan sát hình dạng; dùng boxplot để xem tính đối xứng và ngoại lai; dùng biểu đồ Q-Q plot để so sánh với phân phối chuẩn lý thuyết.

Chỉ số thống kê: so sánh mean với median; tính skewness và kurtosis. Thông thường |skew| < 0,5 được xem là gần đối xứng, 0,5 – 1 là lệch vừa, > 1 là lệch mạnh.

Kiểm định thống kê: dùng các kiểm định như Shapiro-Wilk, Kolmogorov-Smirnov hoặc D'Agostino để kiểm tra giả thuyết dữ liệu có phân phối chuẩn.

Dạng phân bố	Dấu hiệu nhận biết	Ví dụ thực tế
Phân bố chuẩn (đối xứng)	Hình chuông; mean ≈ median ≈ mode; skew ≈ 0	Chiều cao, pH và density của rượu đỏ
Lệch phải (positive skew)	Đuôi kéo dài về bên phải; mean > median > mode; skew > 0	Thu nhập, Insulin, residual_sugar, giá trị đơn hàng
Lệch trái (negative skew)	Đuôi kéo dài về bên trái; mean < median < mode; skew < 0	Điểm thi bài dễ, tuổi thọ thiết bị
Phân bố đều (uniform)	Các giá trị có tần suất gần như nhau	Kết quả gieo xúc xắc
Phân bố hai đỉnh (bimodal)	Histogram có hai đỉnh rõ rệt	Dữ liệu gộp từ hai nhóm khác nhau

Bảng 2.3. Các dạng phân bố phổ biến và dấu hiệu nhận biết

2.1.4. Ý nghĩa của độ lệch chuẩn và phạm vi trong đánh giá sự phân tán

Phạm vi (Range = Max − Min) cho biết độ rộng toàn bộ của dữ liệu. Ưu điểm là dễ tính, dễ hiểu; nhược điểm là chỉ dựa vào hai giá trị cực trị nên rất nhạy cảm với ngoại lai – chỉ cần một giá trị nhập sai là phạm vi thay đổi rất lớn.

Độ lệch chuẩn (Standard Deviation) đo khoảng cách trung bình của các quan sát so với giá trị trung bình, có cùng đơn vị với dữ liệu gốc. Độ lệch chuẩn nhỏ nghĩa là dữ liệu tập trung sát quanh trung bình (đồng đều), độ lệch chuẩn lớn nghĩa là dữ liệu phân tán rộng. Với dữ liệu xấp xỉ phân phối chuẩn, quy tắc thực nghiệm 68 – 95 – 99,7 cho biết khoảng 68% dữ liệu nằm trong $\bar{x} \pm 1s$, 95% nằm trong $\bar{x} \pm 2s$ và 99,7% nằm trong $\bar{x} \pm 3s$.

Khi cần so sánh độ phân tán giữa các biến có đơn vị hoặc độ lớn khác nhau (ví dụ total_sulfur_dioxide tính bằng mg/dm³ và density xấp xỉ 1), nhóm em sử dụng thêm hệ số biến thiên $CV = s / \bar{x} \times 100\%$. Còn khi dữ liệu có nhiều ngoại lai, IQR là thước đo phân tán bền vững hơn cả phạm vi lẫn độ lệch chuẩn.

2.1.5. Sự khác biệt giữa Q1, Q2, Q3 trong biểu đồ hộp (boxplot)

Tứ phân vị là ba giá trị chia tập dữ liệu đã sắp xếp thành bốn phần, mỗi phần chứa khoảng 25% số quan sát:

Q1 (tứ phân vị thứ nhất – bách phân vị 25): 25% dữ liệu nhỏ hơn hoặc bằng Q1; là cạnh dưới của hộp.

Q2 (tứ phân vị thứ hai – trung vị): 50% dữ liệu nhỏ hơn hoặc bằng Q2; là đường kẻ ngang bên trong hộp.

Q3 (tứ phân vị thứ ba – bách phân vị 75): 75% dữ liệu nhỏ hơn hoặc bằng Q3; là cạnh trên của hộp.

Chiều cao của hộp chính là $IQR = Q3 - Q1$, chứa 50% dữ liệu ở giữa. Hai "râu" (whiskers) kéo dài tới giá trị xa nhất còn nằm trong khoảng $[Q1 - 1{,}5 \cdot IQR \ ; \ Q3 + 1{,}5 \cdot IQR]$; các điểm nằm ngoài khoảng này được vẽ riêng và được xem là ngoại lai theo quy tắc Tukey. Vị trí của Q2 trong hộp còn cho biết độ lệch: nếu Q2 nằm gần Q1 và râu trên dài thì dữ liệu lệch phải, ngược lại là lệch trái.

2.1.6. Xử lý giá trị thiếu (missing values) trước khi tính toán thống kê mô tả

Giá trị thiếu nếu không được xử lý sẽ làm các hàm tính toán trả về NaN hoặc làm sai lệch kết quả. Quy trình xử lý mà nhóm em áp dụng gồm các bước:

1. **Phát hiện:** dùng df.isnull().sum() hoặc df.info() để đếm giá trị thiếu ở từng cột. Cần chú ý cả các giá trị thiếu "ẩn" như số 0 bất hợp lý (Glucose = 0, BMI = 0 trong dữ liệu tiểu đường), chuỗi rỗng, "?" hoặc "N/A".
2. **Đánh giá cơ chế thiếu:** thiếu hoàn toàn ngẫu nhiên (MCAR), thiếu ngẫu nhiên có điều kiện (MAR) hay thiếu không ngẫu nhiên (MNAR), và tỷ lệ thiếu của từng cột.

3. **Lựa chọn cách xử lý:** xóa dòng (dropna) khi tỷ lệ thiếu rất nhỏ; xóa cột khi tỷ lệ thiếu quá lớn và cột không quan trọng; điền giá trị (imputation) bằng mean (dữ liệu đối xứng), median (dữ liệu lệch), mode (biến định tính), điền theo nhóm (groupby + transform) hoặc dùng các phương pháp nâng cao như KNN Imputer, hồi quy.
4. **Kiểm tra lại:** sau khi xử lý cần thống kê lại để chắc chắn không còn giá trị thiếu và phân phối không bị biến dạng quá nhiều.

2.1.7. Cách đọc và diễn giải biểu đồ histogram và boxplot

Histogram chia trục giá trị thành các khoảng (bin) và vẽ cột có chiều cao bằng số quan sát (hoặc tỷ lệ) rơi vào từng khoảng. Khi đọc histogram, nhóm em chú ý: (1) vị trí đỉnh cao nhất – vùng giá trị phổ biến nhất; (2) hình dạng – đối xứng, lệch phải hay lệch trái, một đỉnh hay nhiều đỉnh; (3) độ rộng – dữ liệu tập trung hay trải rộng; (4) các cột cô lập ở xa – dấu hiệu ngoại lai; (5) các đỉnh nhọn bất thường – có thể do dữ liệu được điền khuyết hoặc giá trị mặc định (như cột tần suất lớn tại 0).

Boxplot tóm tắt dữ liệu bằng 5 con số: min (râu dưới), Q1, median, Q3, max (râu trên) và các điểm ngoại lai. Khi đọc boxplot cần quan sát: vị trí đường median, độ cao của hộp (IQR), độ dài hai râu, số lượng và vị trí các điểm ngoại lai. Boxplot đặc biệt hữu ích khi đặt nhiều hộp cạnh nhau để so sánh một biến số giữa các nhóm, ví dụ so sánh Glucose giữa nhóm mắc bệnh và không mắc bệnh tiểu đường.

2.1.8. Xử lý giá trị ngoại lai (outliers) trước khi thực hiện thống kê mô tả

Ngoại lai là các quan sát khác biệt rõ rệt so với phần lớn dữ liệu. Quy trình xử lý ngoại lai nhóm em áp dụng gồm:

1. **Phát hiện:** dùng quy tắc IQR (ngoài khoảng $[Q1 - 1{,}5 \cdot IQR\ ;\ Q3 + 1{,}5 \cdot IQR]$), Z-score ($|z| > 3$) với dữ liệu gần chuẩn, kết hợp boxplot và scatter plot để quan sát trực quan.
2. **Tìm nguyên nhân:** xác định ngoại lai là lỗi (nhập sai, lỗi đo, giá trị phi lý như tuổi > 100, số lượng âm do đơn hủy) hay là giá trị thật nhưng hiếm (rượu có lượng đường đặc biệt cao, khách hàng mua sỉ số lượng lớn).

3. **Xử lý phù hợp:** loại bỏ nếu là lỗi; giữ lại và dùng các thước đo bền vững (median, IQR) nếu là giá trị thật; giới hạn giá trị (capping/winsorizing) tại một ngưỡng bách phân vị; hoặc biến đổi dữ liệu (log, căn bậc hai) để giảm ảnh hưởng của đuôi dài.
4. **Ghi nhận và so sánh:** nên báo cáo thống kê trước và sau khi xử lý để thấy rõ tác động của ngoại lai.

Điều quan trọng là không nên xóa ngoại lai một cách máy móc, vì trong nhiều bài toán (phát hiện gian lận, khách hàng VIP) chính các ngoại lai lại mang thông tin giá trị nhất.

2.2. Bài tập thực hành 1 – Thống kê mô tả dữ liệu rượu đỏ (Red Wine Quality)

Tập dữ liệu Red Wine Quality gồm các chỉ số hóa lý của rượu vang đỏ Bồ Đào Nha (biến thể "Vinho Verde") và điểm chất lượng (quality) do chuyên gia đánh giá trên thang 0 – 10. Mục tiêu của bài tập là thực hiện đầy đủ thống kê mô tả trên tập dữ liệu này, từ kiểm tra chất lượng dữ liệu đến tính toán các chỉ số và tìm hiểu mối liên hệ giữa các đặc trưng với chất lượng rượu.

2.2.1. Bước 1: Nạp dữ liệu & kiểm tra kích thước tổng quan

Nhóm em đọc file winequality-red.csv (các cột được phân tách bằng dấu chấm phẩy), tạo bản sao để xử lý và chuẩn hóa tên cột:

```
wine_raw = pd.read_csv(tim_file("winequality-red.csv"), sep=';')

wine = wine_raw.copy()
wine.columns = wine.columns.str.replace(' ', '_')

print(f"Kích thước dữ liệu: {wine.shape[0]} dòng, {wine.shape[1]} cột")
wine.head()
```

Kết quả thực thi:

```
Đã tìm thấy file dữ liệu tại: ./Lab_Phan_tich_kham_pha_du_lieu/wine-quality/winequality-red.csv
Kích thước dữ liệu: 1599 dòng, 12 cột
```

Nhận xét:

Dữ liệu có 1.599 dòng và 12 cột; tên cột sau chuẩn hóa dễ truy xuất hơn trong code.

Kiểm tra kiểu dữ liệu và số giá trị non-null

Sau khi nạp dữ liệu, nhóm em kiểm tra kiểu dữ liệu và số giá trị non-null của từng cột bằng hàm info():

```
# Kiểu dữ liệu của từng thuộc tính
wine.info()
```

Kết quả thực thi:

```
<class 'pandas.DataFrame'>
RangeIndex: 1599 entries, 0 to 1598
Data columns (total 12 columns):
 #    Column                Non-Null Count  Dtype
---   ------                --------------  -----
 0    fixed_acidity         1599 non-null   float64
 1    volatile_acidity      1599 non-null   float64
 2    citric_acid           1599 non-null   float64
 3    residual_sugar        1599 non-null   float64
 4    chlorides             1599 non-null   float64
 5    free_sulfur_dioxide   1599 non-null   float64
 6    total_sulfur_dioxide  1599 non-null   float64
 7    density               1599 non-null   float64
 8    pH                    1599 non-null   float64
 9    sulphates             1599 non-null   float64
 10   alcohol               1599 non-null   float64
 11   quality               1599 non-null   int64
dtypes: float64(11), int64(1)
memory usage: 150.0 KB
```

Nhận xét:

Toàn bộ các biến đều là biến định lượng, phù hợp để áp dụng đầy đủ các thước đo thống kê mô tả.

2.2.2. Bước 2: Kiểm tra giá trị khuyết thiếu & dữ liệu trùng lặp

Trước khi tính toán thống kê, cần đảm bảo dữ liệu không bị thiếu và không có bản ghi lặp lại làm sai lệch kết quả:

```
# 1. Giá trị khuyết thiếu
print("Số giá trị khuyết thiếu mỗi cột:")
print(wine.isnull().sum().to_string())

# 2. Dữ liệu trùng lặp
so_trung = wine.duplicated().sum()
print(f"\nSố dòng trùng lặp hoàn toàn: {so_trung} ({so_trung / len(wine) *
100:.2f}%)")
```

```
# Loại bỏ dòng trùng lặp để các chỉ số thống kê không bị thiên lệch
wine = wine.drop_duplicates().reset_index(drop=True)
print(f"Kích thước sau khi loại trùng lặp: {wine.shape[0]} dòng, {wine.shape[1]}
cột")
```

Kết quả thực thi:

```
Số giá trị khuyết thiếu mỗi cột:
fixed_acidity             0
volatile_acidity          0
citric_acid               0
residual_sugar            0
chlorides                 0
free_sulfur_dioxide       0
total_sulfur_dioxide      0
density                   0
pH                        0
sulphates                 0
alcohol                   0
quality                   0

Số dòng trùng lặp hoàn toàn: 240 (15.01%)
Kích thước sau khi loại trùng lặp: 1359 dòng, 12 cột
```

Nhận xét:

Việc loại trùng lặp giúp các chỉ số thống kê và tần số không bị phóng đại bởi những mẫu bị ghi nhận lặp lại.

2.2.3. Bước 3: Bảng thống kê mô tả đầy đủ (numpy + scipy.stats)

Nhóm em gọi hàm bang_thong_ke_mo_ta đã xây dựng ở Chương 1 cho toàn bộ 12 biến để có bảng thống kê đầy đủ:

```
wine_features = [c for c in wine.columns if c != 'quality']

tk_wine = bang_thong_ke_mo_ta(wine, wine.columns)
tk_wine.round(3)
```

Kết quả thực thi:

Biến	Mean	Median	Mode	Variance	Std	Min	Max	Range	Q1	Q3	IQR	P60	Skewness	Kurtosis	C
fixed_acidity	8.311	7.900	7.200	3.017	1.737	4.600	15.900	11.300	7.100	9.200	2.100	8.300	0.940	1.041	2
volatile_acidity	0.529	0.520	0.500	0.034	0.183	0.120	1.580	1.460	0.390	0.640	0.250	0.570	0.728	1.240	3
citric_acid	0.272	0.260	0.000	0.038	0.196	0.000	1.000	1.000	0.090	0.430	0.340	0.320	0.312	-0.790	7
residual_sugar	2.523	2.200	2.000	1.829	1.352	0.900	15.500	14.600	1.900	2.600	0.700	2.300	4.543	29.252	5
chlorides	0.088	0.079	0.080	0.002	0.049	0.012	0.611	0.599	0.070	0.091	0.021	0.083	5.496	38.478	5
free_sulfur_dioxide	15.893	14.000	6.000	109.145	10.447	1.000	72.000	71.000	7.000	21.000	14.000	16.000	1.225	1.881	6
total_sulfur_dioxide	46.826	38.000	28.000	1116.158	33.409	6.000	289.000	283.000	22.000	63.000	41.000	46.000	1.539	4.023	7
density	0.997	0.997	0.997	0.000	0.002	0.990	1.004	0.014	0.996	0.998	0.002	0.997	0.045	0.823	
pH	3.310	3.310	3.300	0.024	0.155	2.740	4.010	1.270	3.210	3.400	0.190	3.340	0.232	0.872	
sulphates	0.659	0.620	0.540	0.029	0.171	0.330	2.000	1.670	0.550	0.730	0.180	0.650	2.404	11.057	2
alcohol	10.432	10.200	9.500	1.171	1.082	8.400	14.900	6.500	9.500	11.100	1.600	10.500	0.859	0.155	1
quality	5.623	6.000	5.000	0.678	0.824	3.000	8.000	5.000	5.000	6.000	1.000	6.000	0.192	0.335	1

Bảng 2.4. Bảng thống kê mô tả đầy đủ 12 biến của dữ liệu rượu đỏ

Nhận xét:

Với các biến lệch mạnh, trung vị (median) là thước đo trung tâm đáng tin cậy hơn trung bình. Biến quality có mean 5,62, median 6, mode 5 – chất lượng rượu tập trung ở mức trung bình.

2.2.4. Bước 4: Đối chiếu nhanh bằng hàm describe() của pandas

Để kiểm chứng kết quả tự tính, nhóm em đối chiếu với hàm describe() có sẵn của pandas:

```
wine.describe().T
```

Kết quả thực thi:

	count	mean	std	min	25%	50%	75%	
fixed_acidity	1359.0	8.310596	1.736990	4.60000	7.1000	7.9000	9.20000	15.90
volatile_acidity	1359.0	0.529478	0.183031	0.12000	0.3900	0.5200	0.64000	1.58
citric_acid	1359.0	0.272333	0.195537	0.00000	0.0900	0.2600	0.43000	1.00
residual_sugar	1359.0	2.523400	1.352314	0.90000	1.9000	2.2000	2.60000	15.50
chlorides	1359.0	0.088124	0.049377	0.01200	0.0700	0.0790	0.09100	0.61
free_sulfur_dioxide	1359.0	15.893304	10.447270	1.00000	7.0000	14.0000	21.00000	72.00
total_sulfur_dioxide	1359.0	46.825975	33.408946	6.00000	22.0000	38.0000	63.00000	289.00
density	1359.0	0.996709	0.001869	0.99007	0.9956	0.9967	0.99782	1.00
pH	1359.0	3.309787	0.155036	2.74000	3.2100	3.3100	3.40000	4.01
sulphates	1359.0	0.658705	0.170667	0.33000	0.5500	0.6200	0.73000	2.00
alcohol	1359.0	10.432315	1.082065	8.40000	9.5000	10.2000	11.10000	14.90
quality	1359.0	5.623252	0.823578	3.00000	5.0000	6.0000	6.00000	8.00

Bảng 2.5. Kết quả hàm describe() của dữ liệu rượu đỏ sau khi loại trùng lặp

Nhận xét:

Khẳng định các phép tính bằng numpy/scipy là chính xác; describe() phù hợp để xem nhanh, còn bảng tự xây dựng cung cấp thêm mode, IQR, skewness, kurtosis, CV.

2.2.5. Bước 5: Phân phối của biến mục tiêu quality

Biến quality là biến mục tiêu nên nhóm em khảo sát riêng phân phối tần số của biến này và gom thành 3 nhóm chất lượng:

```
# Tần số và tỷ lệ % của từng mức chất lượng
quality_dist = pd.DataFrame({
    'Tần số': wine['quality'].value_counts().sort_index(),
    'Tỷ lệ %': (wine['quality'].value_counts(normalize=True).sort_index() *
100).round(2)
})
display(quality_dist)

# Gom nhóm chất lượng: Thấp (3-4), Trung bình (5-6), Cao (7-8)
wine['quality_group'] = pd.cut(wine['quality'], bins=[2, 4, 6, 8],
                               labels=['Thấp (3-4)', 'Trung bình (5-6)', 'Cao (7-
```

```
8)'])
display(wine['quality_group'].value_counts().to_frame(name='Tần số'))
```

Kết quả thực thi:

quality	Tần số	Tỷ lệ %
3	10	0.74
4	53	3.90
5	577	42.46
6	535	39.37
7	167	12.29
8	17	1.25

Bảng 2.6. Tần số và tỷ lệ % theo từng mức chất lượng quality

quality_group	Tần số
Trung bình (5-6)	1112
Cao (7-8)	184
Thấp (3-4)	63

Bảng 2.7. Số lượng mẫu theo nhóm chất lượng quality_group

Nhận xét:

Dữ liệu mất cân bằng lớp nghiêm trọng – nếu xây dựng mô hình phân loại cần cân nhắc gom nhóm hoặc dùng kỹ thuật cân bằng dữ liệu.

2.2.6. Bước 6: Phát hiện giá trị ngoại lai bằng quy tắc IQR

Nhóm em áp dụng hàm dem_ngoai_lai_iqr cho 11 đặc trưng hóa lý để đếm số lượng ngoại lai:

```
nl_wine = dem_ngoai_lai_iqr(wine, wine_features)
nl_wine.round(3)
```

Kết quả thực thi:

Biến	Cận dưới	Cận trên	Số ngoại lai	Tỷ lệ %
residual_sugar	0.850	3.650	126	9.272
chlorides	0.039	0.122	87	6.402
sulphates	0.280	1.000	55	4.047
total_sulfur_dioxide	-39.500	124.500	45	3.311
fixed_acidity	3.950	12.350	41	3.017
density	0.992	1.001	35	2.575
pH	2.925	3.685	28	2.060
free_sulfur_dioxide	-14.000	42.000	26	1.913
volatile_acidity	0.015	1.015	19	1.398
alcohol	7.100	13.500	12	0.883
citric_acid	-0.420	0.940	1	0.074

Bảng 2.8. Số lượng giá trị ngoại lai theo quy tắc 1.5 × IQR – dữ liệu rượu đỏ

Nhận xét:

Các ngoại lai chủ yếu nằm ở phía giá trị lớn, phù hợp với độ lệch phải đã tính. Đây có thể là các loại rượu có thành phần đặc biệt chứ không hẳn là lỗi nhập liệu, nên chưa loại bỏ mà chỉ ghi nhận để xử lý ở bước mô hình hóa.

2.2.7. Bước 7: Thống kê mô tả theo nhóm chất lượng

Để thấy sự khác biệt giữa rượu tốt và rượu kém, nhóm em so sánh giá trị trung bình của các đặc trưng theo 3 nhóm chất lượng:

```
# So sánh giá trị trung bình của các đặc trưng giữa 3 nhóm chất lượng
tk_nhom_wine = wine.groupby('quality_group', observed=True)[wine_features].mean().T
tk_nhom_wine.round(3)
```

Kết quả thực thi:

quality_group	Thấp (3-4)	Trung bình (5-6)	Cao (7-8)
fixed_acidity	7.871	8.251	8.820
volatile_acidity	0.724	0.539	0.406
citric_acid	0.174	0.261	0.373
residual_sugar	2.685	2.484	2.704
chlorides	0.096	0.090	0.076
free_sulfur_dioxide	12.063	16.428	13.973
total_sulfur_dioxide	34.444	49.425	35.359
density	0.997	0.997	0.996
pH	3.384	3.309	3.289
sulphates	0.592	0.648	0.746
alcohol	10.216	10.259	11.553

Bảng 2.9. Giá trị trung bình các đặc trưng theo 3 nhóm chất lượng rượu

Nhận xét:

Rượu chất lượng cao thường có nồng độ cồn cao, độ axit bay hơi thấp, nhiều axit citric và sulphates hơn.

2.2.8. Bước 8: Mức độ tương quan giữa các đặc trưng và quality

Cuối cùng, nhóm em tính hệ số tương quan Pearson giữa từng đặc trưng với quality và sắp xếp giảm dần:

```
corr_quality = wine[wine_features +
['quality']].corr()['quality'].drop('quality').sort_values(ascending=False)
corr_quality.to_frame(name='Hệ số tương quan r với quality').round(3)
```

Kết quả thực thi:

	Hệ số tương quan r với quality
alcohol	0.480
sulphates	0.249
citric_acid	0.228
fixed_acidity	0.119
residual_sugar	0.014
free_sulfur_dioxide	-0.050
pH	-0.055
chlorides	-0.131
total_sulfur_dioxide	-0.178
density	-0.184
volatile_acidity	-0.395

Bảng 2.10. Hệ số tương quan giữa các đặc trưng và biến quality

Nhận xét:

Kết quả thống nhất với Bước 7: alcohol và volatile_acidity là hai đặc trưng quan trọng nhất ảnh hưởng đến chất lượng rượu đỏ.

2.3. Bài tập thực hành 2 – Thống kê mô tả dữ liệu bệnh tiểu đường (Pima Indians Diabetes)

Tập dữ liệu Pima Indians Diabetes ghi nhận 8 chỉ số sức khỏe của phụ nữ gốc Pima (từ 21 tuổi trở lên) cùng biến mục tiêu Outcome cho biết người đó có mắc bệnh tiểu đường hay không. Điểm đặc biệt của bộ dữ liệu này là các giá trị khuyết thiếu được ghi dưới dạng số 0, nên ngoài thống kê mô tả, bài tập còn tập trung vào việc phát hiện và xử lý dữ liệu khuyết thiếu ẩn.

2.3.1. Bước 1: Nạp dữ liệu & kiểm tra kích thước tổng quan

Nhóm em nạp file diabetes.csv và xem 5 dòng đầu tiên:

```
diab_raw = pd.read_csv(tim_file("diabetes.csv"))
diab = diab_raw.copy()

print(f"Kích thước dữ liệu: {diab.shape[0]} dòng, {diab.shape[1]} cột")
```

```
diab.head()
```

Kết quả thực thi:

```
Đã tìm thấy file dữ liệu tại: ./Lab_Phan_tich_kham_pha_du_lieu/diabetes.csv
Kích thước dữ liệu: 768 dòng, 9 cột
```

Nhận xét:

Dữ liệu có 768 dòng, 9 cột; ngay ở các dòng đầu đã thấy Insulin và SkinThickness bằng 0 – dấu hiệu của dữ liệu khuyết thiếu ẩn.

Kiểm tra kiểu dữ liệu và số giá trị non-null

Tiếp theo là kiểm tra kiểu dữ liệu và số giá trị non-null của các cột:

```
diab.info()
```

Kết quả thực thi:

```
<class 'pandas.DataFrame'>
RangeIndex: 768 entries, 0 to 767
Data columns (total 9 columns):
 #   Column                    Non-Null Count  Dtype
---  ------                    --------------  -----
 0   Pregnancies               768 non-null    int64
 1   Glucose                   768 non-null    int64
 2   BloodPressure             768 non-null    int64
 3   SkinThickness             768 non-null    int64
 4   Insulin                   768 non-null    int64
 5   BMI                       768 non-null    float64
 6   DiabetesPedigreeFunction  768 non-null    float64
 7   Age                       768 non-null    int64
 8   Outcome                   768 non-null    int64
dtypes: float64(2), int64(7)
memory usage: 54.1 KB
```

Nhận xét:

Info() báo không có giá trị null, nhưng cần kiểm tra thêm các giá trị 0 bất hợp lý ở bước tiếp theo.

2.3.2. Bước 2: Kiểm tra khuyết thiếu, trùng lặp & giá trị 0 bất hợp lý

Bên cạnh giá trị NaN và dòng trùng lặp, nhóm em kiểm tra các cột về mặt sinh học không thể bằng 0 (Glucose, BloodPressure, SkinThickness, Insulin, BMI):

```
print(f"Tổng số ô NaN: {diab.isnull().sum().sum()}")
print(f"Số dòng trùng lặp: {diab.duplicated().sum()}")


cot_khong_the_bang_0 = ['Glucose', 'BloodPressure', 'SkinThickness', 'Insulin',
'BMI']
zero_df = pd.DataFrame({
    'Số giá trị 0': (diab[cot_khong_the_bang_0] == 0).sum(),
    'Tỷ lệ %': ((diab[cot_khong_the_bang_0] == 0).mean() * 100).round(2)
}).sort_values('Số giá trị 0', ascending=False)
zero_df
```

Kết quả thực thi:

```
Tổng số ô NaN: 0
Số dòng trùng lặp: 0
```

	Số giá trị 0	Tỷ lệ %
Insulin	374	48.70
SkinThickness	227	29.56
BloodPressure	35	4.56
BMI	11	1.43
Glucose	5	0.65

Bảng 2.11. Số lượng và tỷ lệ giá trị 0 bất hợp lý trong dữ liệu tiểu đường

Nhận xét:

Nếu không xử lý, các giá trị 0 sẽ kéo lệch mean và min (bảng thống kê ở Bước 3 ngay dưới đây cho thấy Glucose, BMI đều có min = 0), dẫn tới kết luận sai về dữ liệu.

2.3.3. Bước 3: Thống kê mô tả TRƯỚC khi xử lý giá trị 0

Để có mốc so sánh, nhóm em tính thống kê mô tả khi dữ liệu vẫn còn các giá trị 0 bất hợp lý:

```
diab_features = [c for c in diab.columns if c != 'Outcome']
bang_thong_ke_mo_ta(diab, diab_features)[['Mean', 'Median', 'Std', 'Min', 'Max',
'Skewness']].round(3)
```

Kết quả thực thi:

Biến	Mean	Median	Std	Min	Max	Skewness
Pregnancies	3.845	3.000	3.370	0.000	17.00	0.900
Glucose	120.895	117.000	31.973	0.000	199.00	0.173
BloodPressure	69.105	72.000	19.356	0.000	122.00	-1.840
SkinThickness	20.536	23.000	15.952	0.000	99.00	0.109
Insulin	79.799	30.500	115.244	0.000	846.00	2.268
BMI	31.993	32.000	7.884	0.000	67.10	-0.428
DiabetesPedigreeFunction	0.472	0.372	0.331	0.078	2.42	1.916
Age	33.241	29.000	11.760	21.000	81.00	1.127

Bảng 2.12. Thống kê mô tả dữ liệu tiểu đường trước khi xử lý giá trị 0

Nhận xét:

Các giá trị 0 bất hợp lý đang làm sai lệch thống kê, cần xử lý ở bước tiếp theo.

2.3.4. Bước 4: Xử lý giá trị 0 – thay bằng NaN rồi điền trung vị theo từng nhóm Outcome

Các giá trị 0 được chuyển thành NaN, sau đó điền bằng trung vị tính riêng theo từng nhóm Outcome:

```
diab[cot_khong_the_bang_0] = diab[cot_khong_the_bang_0].replace(0, np.nan)

for col in cot_khong_the_bang_0:
    diab[col] = diab.groupby('Outcome')[col].transform(lambda x:
x.fillna(x.median()))

print(f"Số ô khuyết thiếu còn lại: {diab.isnull().sum().sum()}")

diab.groupby('Outcome')[cot_khong_the_bang_0].median().round(2)
```

Kết quả thực thi:

```
Số ô khuyết thiếu còn lại: 0
```

Outcome	Glucose	BloodPressure	SkinThickness	Insulin	BMI
0	107.0	70.0	27.0	102.5	30.1
1	140.0	74.5	32.0	169.5	34.3

Bảng 2.13. Giá trị trung vị dùng để điền khuyết theo từng nhóm Outcome

Nhận xét:

Không còn ô khuyết thiếu. Lưu ý: Insulin bị điền gần một nửa nên phân phối có 2 đỉnh nhân tạo tại 102,5 và 169,5; khi xây dựng mô hình cần tính median trên tập train để tránh rò rỉ thông tin từ biến mục tiêu.

2.3.5. Bước 5: Bảng thống kê mô tả đầy đủ SAU khi xử lý

Sau khi xử lý, nhóm em lập lại bảng thống kê mô tả đầy đủ cho toàn bộ các biến:

```
tk_diab = bang_thong_ke_mo_ta(diab, diab.columns)
tk_diab.round(3)
```

Kết quả thực thi:

Biến	Mean	Median	Mode	Variance	Std	Min	Max	Range	Q1	Q3	IQR
Pregnancies	3.845	3.000	1.000	11.354	3.370	0.000	17.00	17.000	1.000	6.000	5.000
Glucose	121.677	117.000	99.000	928.065	30.464	44.000	199.00	155.000	99.750	140.250	40.500
BloodPressure	72.389	72.000	70.000	146.556	12.106	24.000	122.00	98.000	64.000	80.000	16.000
SkinThickness	29.090	28.000	27.000	79.047	8.891	7.000	99.00	92.000	25.000	32.000	7.000
Insulin	141.754	102.500	102.500	7938.961	89.101	14.000	846.00	832.000	102.500	169.500	67.000
BMI	32.435	32.050	30.100	47.341	6.880	18.200	67.10	48.900	27.500	36.600	9.100
DiabetesPedigreeFunction	0.472	0.372	0.254	0.110	0.331	0.078	2.42	2.342	0.244	0.626	0.382
Age	33.241	29.000	22.000	138.303	11.760	21.000	81.00	60.000	24.000	41.000	17.000
Outcome	0.349	0.000	0.000	0.227	0.477	0.000	1.00	1.000	0.000	1.000	1.000

Bảng 2.14. Bảng thống kê mô tả đầy đủ dữ liệu tiểu đường sau khi xử lý

Nhận xét:

Sau xử lý, các chỉ số phản ánh đúng thực tế sinh học. BMI trung bình 32,4 cho thấy phần lớn bệnh nhân trong mẫu ở mức béo phì.

2.3.6. Bước 6: Phân phối biến mục tiêu Outcome

Nhóm em khảo sát phân phối của biến mục tiêu Outcome:

```
outcome_dist = pd.DataFrame({
    'Tần số': diab['Outcome'].value_counts().sort_index(),
    'Tỷ lệ %': (diab['Outcome'].value_counts(normalize=True).sort_index() *
100).round(2)
})
outcome_dist.index = ['0 - Không mắc bệnh', '1 - Mắc bệnh']
outcome_dist
```

Kết quả thực thi:

	Tần số	Tỷ lệ %
0 - Không mắc bệnh	500	65.1
1 - Mắc bệnh	268	34.9

Bảng 2.15. Phân phối biến mục tiêu Outcome

Nhận xét:

Dữ liệu mất cân bằng ở mức trung bình (khoảng 2:1), cần lưu ý khi đánh giá mô hình (nên dùng thêm Recall, F1 thay vì chỉ Accuracy).

2.3.7. Bước 7: Thống kê mô tả theo nhóm Outcome

Để thấy sự khác biệt giữa người mắc bệnh và không mắc bệnh, nhóm em so sánh trung bình, trung vị của các chỉ số theo nhóm Outcome:

```
# So sánh trung bình và trung vị giữa nhóm không bệnh (0) và nhóm mắc bệnh (1)
tk_nhom_diab = diab.groupby('Outcome')[diab_features].agg(['mean', 'median']).T
tk_nhom_diab.columns = ['Không bệnh (0)', 'Mắc bệnh (1)']
tk_nhom_diab['Chênh lệch (1 - 0)'] = tk_nhom_diab['Mắc bệnh (1)'] -
tk_nhom_diab['Không bệnh (0)']
tk_nhom_diab.round(3)
```

Kết quả thực thi:

		Không bệnh (0)	Mắc bệnh (1)	Chênh lệch (1 - 0)
Pregnancies	mean	3.298	4.866	1.568
	median	2.000	4.000	2.000
Glucose	mean	110.622	142.302	31.680
	median	107.000	140.000	33.000
BloodPressure	mean	70.844	75.272	4.428
	median	70.000	74.500	4.500
SkinThickness	mean	27.170	32.672	5.502
	median	27.000	32.000	5.000
Insulin	mean	117.172	187.616	70.444
	median	102.500	169.500	67.000
BMI	mean	30.846	35.399	4.553
	median	30.100	34.300	4.200
DiabetesPedigreeFunction	mean	0.430	0.550	0.121
	median	0.336	0.449	0.113
Age	mean	31.190	37.067	5.877
	median	27.000	36.000	9.000

Bảng 2.16. So sánh trung bình và trung vị các chỉ số giữa hai nhóm Outcome

Nhận xét:

Glucose là dấu hiệu phân biệt rõ ràng nhất giữa hai nhóm, tiếp theo là Insulin, BMI và Age.

2.3.8. Bước 8: Ngoại lai (IQR) & tương quan với Outcome

Cuối cùng, nhóm em đếm ngoại lai theo IQR và tính hệ số tương quan của từng chỉ số với Outcome:

```
display(dem_ngoai_lai_iqr(diab, diab_features).round(3))

corr_outcome = diab.corr()['Outcome'].drop('Outcome').sort_values(ascending=False)
display(corr_outcome.to_frame(name='Hệ số tương quan r với Outcome').round(3))
```

Kết quả thực thi:

Biến	Cận dưới	Cận trên	Số ngoại lai	Tỷ lệ %
SkinThickness	14.50	42.50	87	11.328
Insulin	2.00	270.00	51	6.641
DiabetesPedigreeFunction	-0.33	1.20	29	3.776
BloodPressure	40.00	104.00	14	1.823
Age	-1.50	66.50	9	1.172
BMI	13.85	50.25	8	1.042
Pregnancies	-6.50	13.50	4	0.521
Glucose	39.00	201.00	0	0.000

Bảng 2.17. Số lượng giá trị ngoại lai theo quy tắc IQR – dữ liệu tiểu đường

	Hệ số tương quan r với Outcome
Glucose	0.496
Insulin	0.377
BMI	0.316
SkinThickness	0.295
Age	0.238
Pregnancies	0.222
BloodPressure	0.174
DiabetesPedigreeFunction	0.174

Bảng 2.18. Hệ số tương quan giữa các chỉ số và biến Outcome

Nhận xét:

Số ngoại lai của SkinThickness và Insulin tăng một phần do IQR bị thu hẹp sau khi điền median. Glucose là đặc trưng dự báo quan trọng nhất cho bệnh tiểu đường.

2.4. Tổng kết Chương 2

1. **Bài tập 1.1.3 – Rượu đỏ:** 1.599 mẫu (240 dòng trùng lặp → còn 1.359), không khuyết thiếu; quality tập trung ở mức 5–6; residual_sugar, chlorides, sulphates lệch phải mạnh; alcohol (r = 0,48) và volatile_acidity (r = -0,40) ảnh hưởng mạnh nhất đến chất lượng.
2. **Bài tập 1.1.4 – Tiểu đường:** 768 bệnh nhân, 34,9% mắc bệnh; phát hiện khuyết thiếu ẩn dưới dạng giá trị 0 (Insulin 48,7%, SkinThickness 29,6%) và xử lý bằng median theo nhóm; Glucose (r = 0,50) là chỉ số quan trọng nhất.

Chương 3. XỬ LÝ VÀ TRỰC QUAN HÓA DỮ LIỆU

3.1. Cơ sở lý thuyết về xử lý và trực quan hóa dữ liệu

3.1.1. Vai trò của trực quan hóa dữ liệu trong phân tích và EDA

Phát hiện nhanh các mẫu và xu hướng: mắt người nhận ra hình dạng phân phối, xu hướng tăng giảm, tính mùa vụ trên biểu đồ nhanh hơn nhiều so với đọc hàng nghìn con số.

Phát hiện bất thường: ngoại lai, giá trị phi lý, đỉnh nhọn do điền khuyết thiếu thường lộ rõ trên histogram, boxplot, scatter plot.

Kiểm chứng giả định: kiểm tra tính chuẩn, tính tuyến tính, hiện tượng đa cộng tuyến trước khi xây dựng mô hình.

Tránh kết luận sai từ con số: bộ tứ Anscombe (Anscombe's quartet) là ví dụ kinh điển – bốn tập dữ liệu có cùng mean, phương sai, hệ số tương quan nhưng hình dạng hoàn toàn khác nhau khi vẽ ra.

Truyền đạt kết quả: biểu đồ giúp trình bày insight cho người không chuyên một cách dễ hiểu và thuyết phục.

3.1.2. Các loại biểu đồ phổ biến và trường hợp sử dụng

Loại biểu đồ	Mục đích sử dụng	Kiểu dữ liệu phù hợp
Histogram	Xem phân phối, hình dạng, độ lệch của một biến	1 biến số liên tục
Boxplot	Tóm tắt 5 số, phát hiện ngoại lai, so sánh giữa các nhóm	Biến số (có thể kèm biến phân loại)
Violin plot	Giống boxplot nhưng thể hiện thêm mật độ phân phối	Biến số theo nhóm
Bar chart / Countplot	So sánh số lượng hoặc giá trị giữa các nhóm	Biến phân loại
Pie chart	Thể hiện tỷ lệ các thành phần trong tổng thể (ít nhóm)	Biến phân loại, ít hạng mục
Scatter plot	Quan sát mối quan hệ giữa hai biến số	2 biến số
Line chart	Thể hiện xu hướng theo thời gian hoặc theo thứ tự	Dữ liệu chuỗi thời gian
Heatmap	Thể hiện ma trận tương quan hoặc bảng chéo	Nhiều biến số

Loại biểu đồ	Mục đích sử dụng	Kiểu dữ liệu phù hợp
Pairplot	Xem đồng thời mọi cặp quan hệ giữa nhiều biến	Nhiều biến số

Bảng 3.1. Các loại biểu đồ phổ biến trong EDA

3.1.3. Cách chọn loại biểu đồ phù hợp với đặc điểm dữ liệu

Việc chọn biểu đồ phụ thuộc vào hai yếu tố: kiểu dữ liệu của biến và câu hỏi phân tích cần trả lời. Một số nguyên tắc nhóm em rút ra:

Dữ liệu số (liên tục): dùng histogram, KDE, boxplot, violin plot để xem phân phối; scatter plot để xem quan hệ giữa hai biến số; heatmap tương quan khi có nhiều biến số.

Dữ liệu phân loại: dùng bar chart hoặc countplot để so sánh tần số; pie chart khi chỉ có 2 – 5 nhóm và muốn nhấn mạnh tỷ lệ; stacked bar chart hoặc crosstab heatmap cho quan hệ giữa hai biến phân loại.

Dữ liệu số theo nhóm phân loại: dùng boxplot, violin plot hoặc bar chart giá trị trung bình theo từng nhóm.

Dữ liệu thời gian: dùng line chart để thể hiện xu hướng, tính mùa vụ; có thể kết hợp bar chart trên trục phụ (twinx) để thể hiện thêm một đại lượng khác.

Câu hỏi phân tích: so sánh → bar chart; phân phối → histogram/boxplot; quan hệ → scatter/heatmap; thành phần → pie/stacked bar; xu hướng → line chart.

3.1.4. Sự khác biệt giữa Matplotlib, Seaborn và Plotly

Tiêu chí	Matplotlib	Seaborn	Plotly
Bản chất	Thư viện nền tảng, cấp thấp	Xây dựng trên Matplotlib, cấp cao	Thư viện độc lập, nền web (JavaScript)
Mức độ tùy biến	Rất cao, kiểm soát từng chi tiết	Cao, kế thừa từ Matplotlib	Cao, cấu hình qua figure/layout
Lượng code	Nhiều dòng	Ít dòng, làm việc trực tiếp với DataFrame	Ít dòng (plotly.express)
Tính tương tác	Tĩnh	Tĩnh	Tương tác: zoom, hover, lọc
Biểu đồ thống kê	Phải tự xử lý	Có sẵn: KDE, violin, pairplot, heatmap, hồi quy	Có sẵn nhiều loại

Tiêu chí	Matplotlib	Seaborn	Plotly
Định dạng xuất	PNG, PDF, SVG, JPG	Giống Matplotlib	HTML; ảnh tĩnh cần thêm kaleido
Phù hợp	Báo cáo in ấn, tùy chỉnh chi tiết	EDA nhanh, biểu đồ thống kê đẹp	Dashboard, trình bày trên web

Bảng 3.2. So sánh các thư viện trực quan hóa Matplotlib, Seaborn và Plotly

3.1.5. Nguyên tắc thiết kế biểu đồ trực quan, dễ hiểu và hiệu quả

Rõ ràng mục đích: mỗi biểu đồ chỉ nên trả lời một câu hỏi chính; tiêu đề nên nêu rõ nội dung.

Đầy đủ chú thích: có tiêu đề, nhãn trục kèm đơn vị, chú giải (legend) khi có nhiều nhóm màu.

Chọn đúng loại biểu đồ: không dùng pie chart cho quá nhiều nhóm, không dùng line chart cho dữ liệu phân loại không có thứ tự.

Trung thực với dữ liệu: trục y của bar chart nên bắt đầu từ 0; dùng thang log khi dữ liệu lệch mạnh nhưng phải ghi chú rõ.

Sử dụng màu sắc có chủ đích: màu dùng để phân biệt nhóm hoặc làm nổi bật thông tin quan trọng, hạn chế dùng quá nhiều màu; chú ý người mù màu.

Tối giản (data-ink ratio): loại bỏ các chi tiết trang trí thừa như đường lưới đậm, hiệu ứng 3D.

Sắp xếp hợp lý: sắp xếp cột theo giá trị giảm dần để dễ so sánh; gắn nhãn số liệu trực tiếp trên cột khi cần.

3.1.6. Tạo biểu đồ đơn giản (histogram, bar chart) bằng Matplotlib

Để vẽ một biểu đồ cơ bản bằng Matplotlib, nhóm em thực hiện theo các bước: tạo khung hình bằng plt.figure() hoặc plt.subplots(), gọi hàm vẽ tương ứng (plt.hist() cho histogram, plt.bar() cho bar chart), sau đó bổ sung tiêu đề, nhãn trục và hiển thị bằng plt.show(). Đoạn code minh họa dưới đây vẽ histogram nồng độ cồn và bar chart số lượng mẫu theo mức chất lượng của dữ liệu rượu đỏ:

Đoạn code minh họa:

```
import matplotlib.pyplot as plt

# Histogram: phân phối nồng độ cồn
plt.figure(figsize=(8, 5))
plt.hist(wine['alcohol'], bins=30, color='steelblue', edgecolor='black')
plt.title('Phân phối nồng độ cồn của rượu đỏ')
plt.xlabel('alcohol (% thể tích)')
plt.ylabel('Số lượng mẫu')
plt.show()

# Bar chart: số lượng mẫu theo mức chất lượng
q = wine['quality'].value_counts().sort_index()
plt.figure(figsize=(8, 5))
plt.bar(q.index.astype(str), q.values, color='darkred')
plt.title('Số lượng mẫu theo mức chất lượng')
plt.xlabel('quality')
plt.ylabel('Số lượng mẫu')
plt.show()
```

3.1.7. Xuất biểu đồ ra các định dạng PNG, PDF, HTML để dùng trong báo cáo

Với Matplotlib và Seaborn, biểu đồ được lưu bằng hàm plt.savefig() (hoặc fig.savefig()); định dạng file được xác định theo phần mở rộng. Tham số dpi quyết định độ phân giải, bbox_inches='tight' giúp cắt bỏ khoảng trắng thừa. Lưu ý phải gọi savefig() trước plt.show(), vì sau khi show() khung hình có thể bị xóa. Với Plotly, biểu đồ tương tác được lưu ra file HTML bằng write_html(). Đoạn code minh họa:

Đoạn code minh họa:

```
import os
os.makedirs('hinh_anh', exist_ok=True)

# Matplotlib / Seaborn
plt.savefig('hinh_anh/bieu_do.png', dpi=300, bbox_inches='tight')    # ảnh PNG
plt.savefig('hinh_anh/bieu_do.pdf', bbox_inches='tight')             # vector PDF
plt.savefig('hinh_anh/bieu_do.svg')                                   # vector SVG

# Plotly
import plotly.express as px
fig = px.histogram(wine, x='alcohol', color='quality')
fig.write_html('hinh_anh/bieu_do.html')      # biểu đồ tương tác
fig.write_image('hinh_anh/bieu_do.png')      # cần cài thêm thư viện kaleido
```

Trong bài thực hành, kỹ thuật này được áp dụng ở Biểu đồ 4 của Bài tập 1 (lưu heatmap tương quan vào file hinh_anh/heatmap_ruou_do.png).

3.2. Bài tập thực hành 1 – Trực quan hóa dữ liệu rượu đỏ

Bài tập này tiếp nối kết quả thống kê mô tả của dữ liệu rượu đỏ ở Chương 2 (dữ liệu đã loại 240 dòng trùng lặp, còn 1.359 mẫu và đã có biến quality_group). Nhóm em xây dựng 7 nhóm biểu đồ bằng Matplotlib và Seaborn để làm rõ phân phối, ngoại lai, tương quan và xu hướng của các đặc trưng theo chất lượng rượu.

3.2.1. Biểu đồ 1: Phân phối biến mục tiêu quality (Matplotlib & Seaborn)

Biểu đồ đầu tiên thể hiện phân phối biến mục tiêu, vẽ song song bằng Matplotlib (theo từng mức) và Seaborn (theo nhóm) để so sánh cách dùng hai thư viện:

```
q_counts = wine['quality'].value_counts().sort_index()

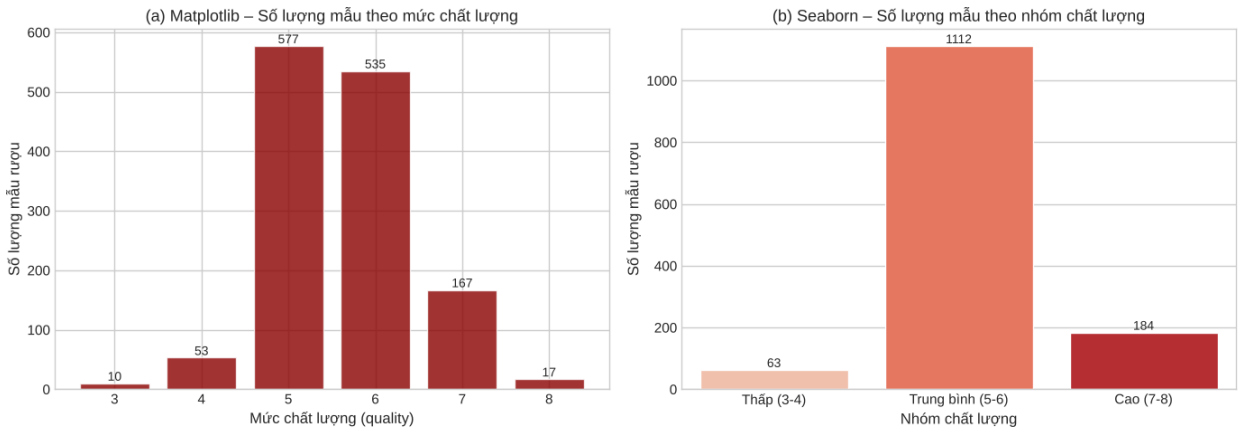
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

bars = axes[0].bar(q_counts.index.astype(str), q_counts.values, color='darkred',
alpha=0.8)
axes[0].bar_label(bars, fontsize=10)
axes[0].set_title('(a) Matplotlib - Số lượng mẫu theo mức chất lượng', fontsize=13)
axes[0].set_xlabel('Mức chất lượng (quality)')
axes[0].set_ylabel('Số lượng mẫu rượu')

sns.countplot(data=wine, x='quality_group', palette='Reds', ax=axes[1])
for c in axes[1].containers:
    axes[1].bar_label(c, fontsize=10)
axes[1].set_title('(b) Seaborn - Số lượng mẫu theo nhóm chất lượng', fontsize=13)
axes[1].set_xlabel('Nhóm chất lượng')
axes[1].set_ylabel('Số lượng mẫu rượu')

plt.tight_layout()
plt.show()
```

Kết quả thực thi:



Hình 3.1. Phân phối biến mục tiêu quality (Matplotlib và Seaborn)

Nhận xét:

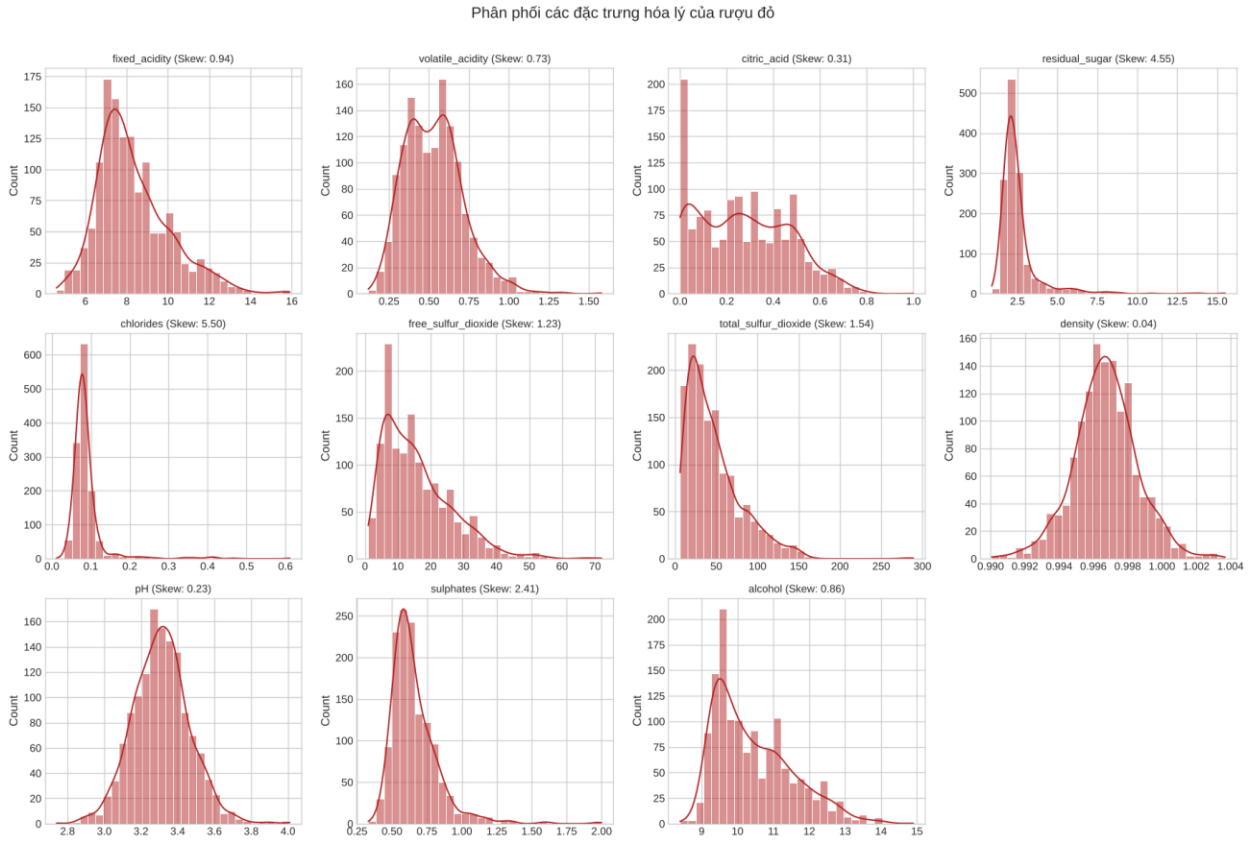
Thấy rõ dữ liệu tập trung ở mức 5–6 (nhóm Trung bình 1.112 mẫu), các mức cực đoan 3 và 8 rất ít – xác nhận tình trạng mất cân bằng lớp.

3.2.2. Biểu đồ 2: Histogram + KDE – phân phối của 11 đặc trưng hóa lý

Nhóm em vẽ histogram kết hợp đường KDE cho 11 đặc trưng trên lưới 3 × 4, tiêu đề mỗi ô kèm hệ số skewness:

```
fig, axes = plt.subplots(3, 4, figsize=(18, 12))
axes = axes.flatten()
for i, col in enumerate(wine_features):
    sns.histplot(wine[col], kde=True, bins=30, color='firebrick', ax=axes[i])
    axes[i].set_title(f"{col} (Skew: {wine[col].skew():.2f})", fontsize=11)
    axes[i].set_xlabel('')
axes[-1].axis('off')
plt.suptitle('Phân phối các đặc trưng hóa lý của rượu đỏ', fontsize=16, y=1.01)
plt.tight_layout()
plt.show()
```

Kết quả thực thi:



Hình 3.2. Histogram kết hợp KDE của 11 đặc trưng hóa lý của rượu đỏ

Nhận xét:

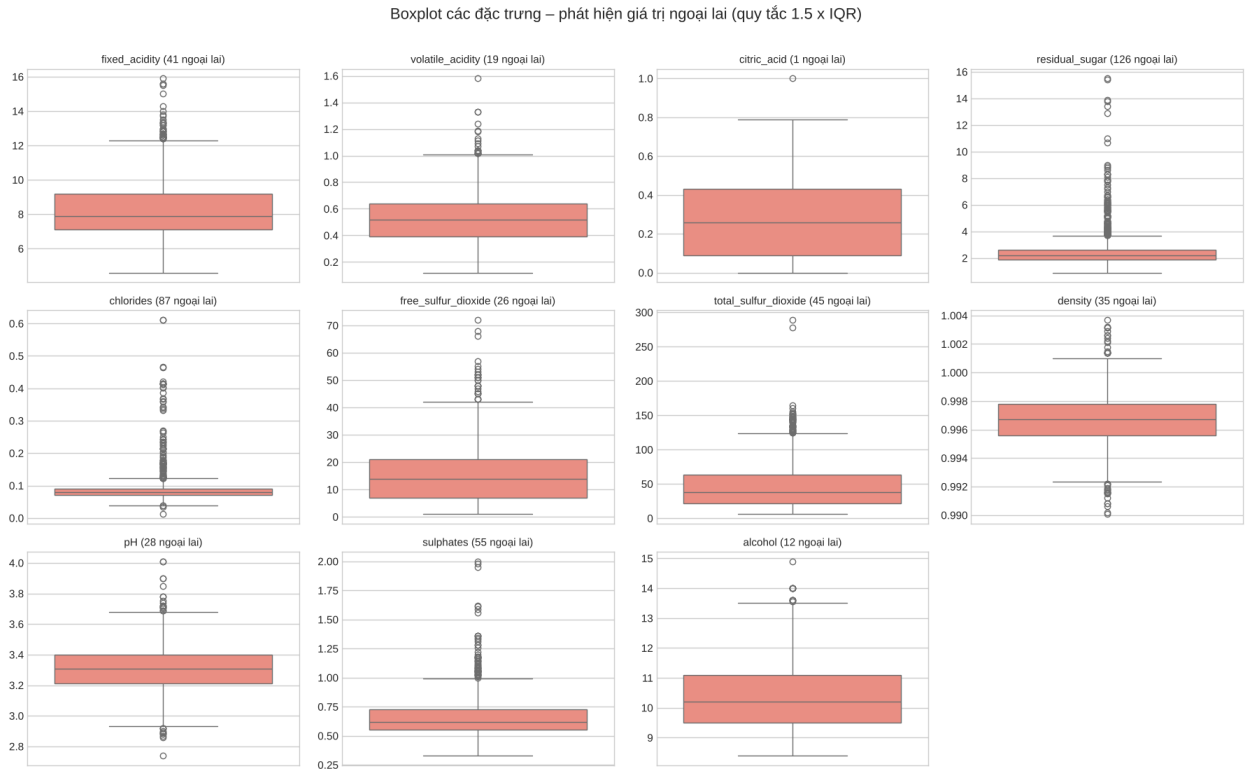
Các biến lệch phải mạnh nên được biến đổi log khi đưa vào các mô hình yêu cầu phân phối chuẩn.

3.2.3. Biểu đồ 3: Boxplot – phát hiện ngoại lai của các đặc trưng

Tương tự, nhóm em vẽ boxplot cho từng đặc trưng, tiêu đề kèm số lượng ngoại lai đã đếm được ở Chương 2:

```
fig, axes = plt.subplots(3, 4, figsize=(18, 11))
axes = axes.flatten()
for i, col in enumerate(wine_features):
    sns.boxplot(y=wine[col], color='salmon', ax=axes[i])
    axes[i].set_title(f"{col} ({int(nl_wine.loc[col, 'Số ngoại lai'])} ngoại lai)",
fontsize=11)
    axes[i].set_ylabel('')
axes[-1].axis('off')
plt.suptitle('Boxplot các đặc trưng – phát hiện giá trị ngoại lai (quy tắc 1.5 x
IQR)', fontsize=16, y=1.01)
plt.tight_layout()
plt.show()
```

Kết quả thực thi:



Hình 3.3. Boxplot phát hiện giá trị ngoại lai của các đặc trưng rượu đỏ

Nhận xét:

Residual_sugar, chlorides và sulphates có rất nhiều ngoại lai phía trên, khớp với bảng thống kê ở bài 1.1.3.

3.2.4. Biểu đồ 4: Ma trận tương quan Heatmap & xuất biểu đồ ra file PNG

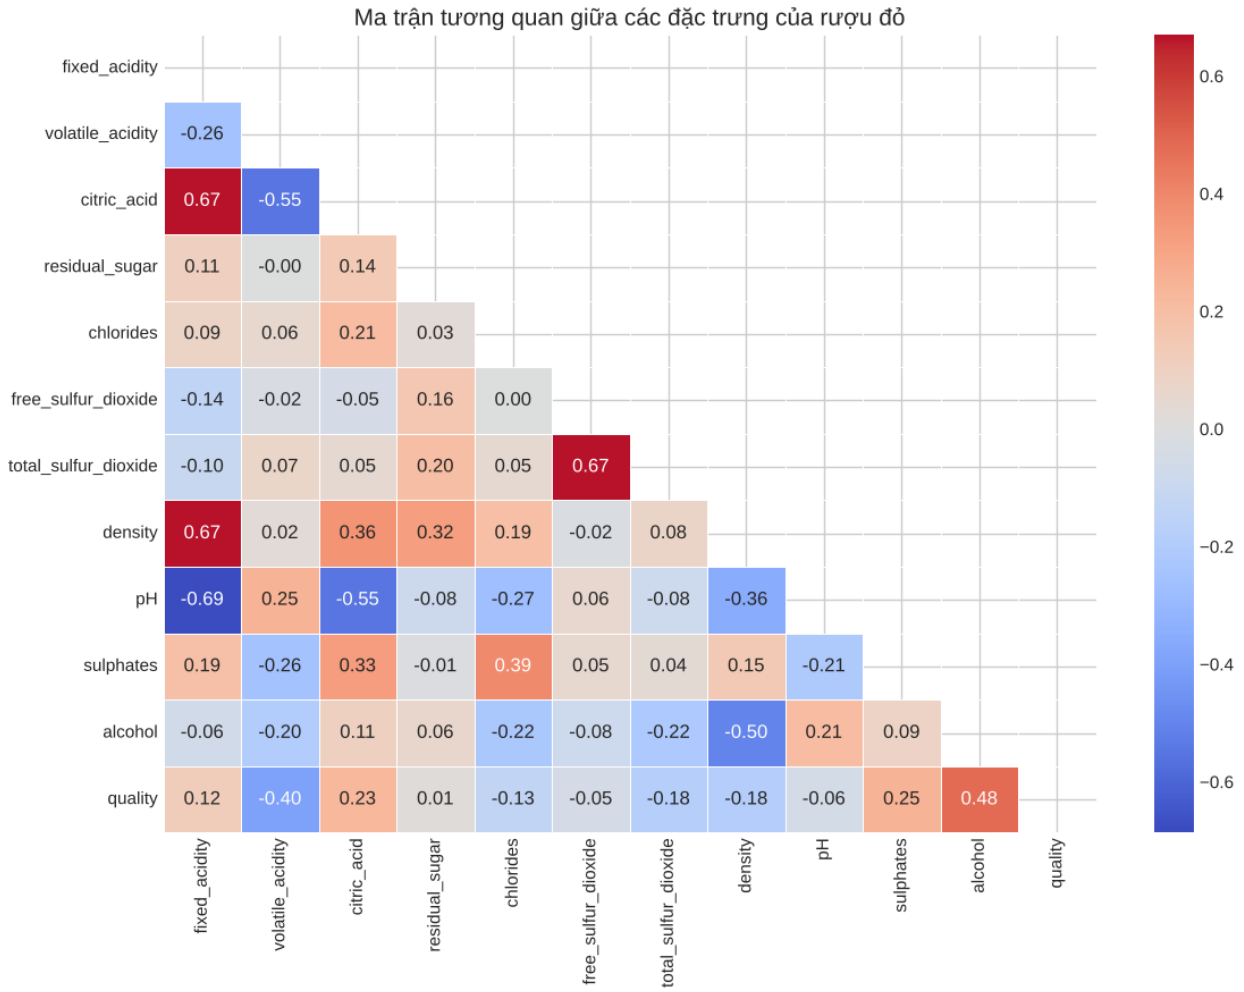
Heatmap được dùng để quan sát toàn bộ ma trận tương quan; nhóm em che nửa trên ma trận cho dễ đọc và lưu biểu đồ ra file PNG:

```
plt.figure(figsize=(12, 9))
corr_wine = wine[wine_features + ['quality']].corr()
mask = np.triu(np.ones_like(corr_wine, dtype=bool))
sns.heatmap(corr_wine, mask=mask, annot=True, fmt='.2f', cmap='coolwarm', center=0,
linewidths=.5)
plt.title('Ma trận tương quan giữa các đặc trưng của rượu đỏ', fontsize=15)
plt.tight_layout()

os.makedirs('hinh_anh', exist_ok=True)
plt.savefig('hinh_anh/heatmap_ruou_do.png', dpi=150, bbox_inches='tight')
print("Đã lưu biểu đồ vào: hinh_anh/heatmap_ruou_do.png")
plt.show()
```

Kết quả thực thi:

```
Đã lưu biểu đồ vào: hinh_anh/heatmap_ruou_do.png
```



Hình 3.4. Ma trận tương quan heatmap giữa các đặc trưng của rượu đỏ

Nhận xét:

Các cặp tương quan mạnh: fixed_acidity – citric_acid (0,67), fixed_acidity – density (0,67), fixed_acidity – pH (-0,69), free – total_sulfur_dioxide (0,67) → cần lưu ý đa cộng tuyến. Với quality, alcohol (0,48) và volatile_acidity (-0,40) nổi bật nhất.

3.2.5. Biểu đồ 5: Boxplot các đặc trưng quan trọng theo mức chất lượng

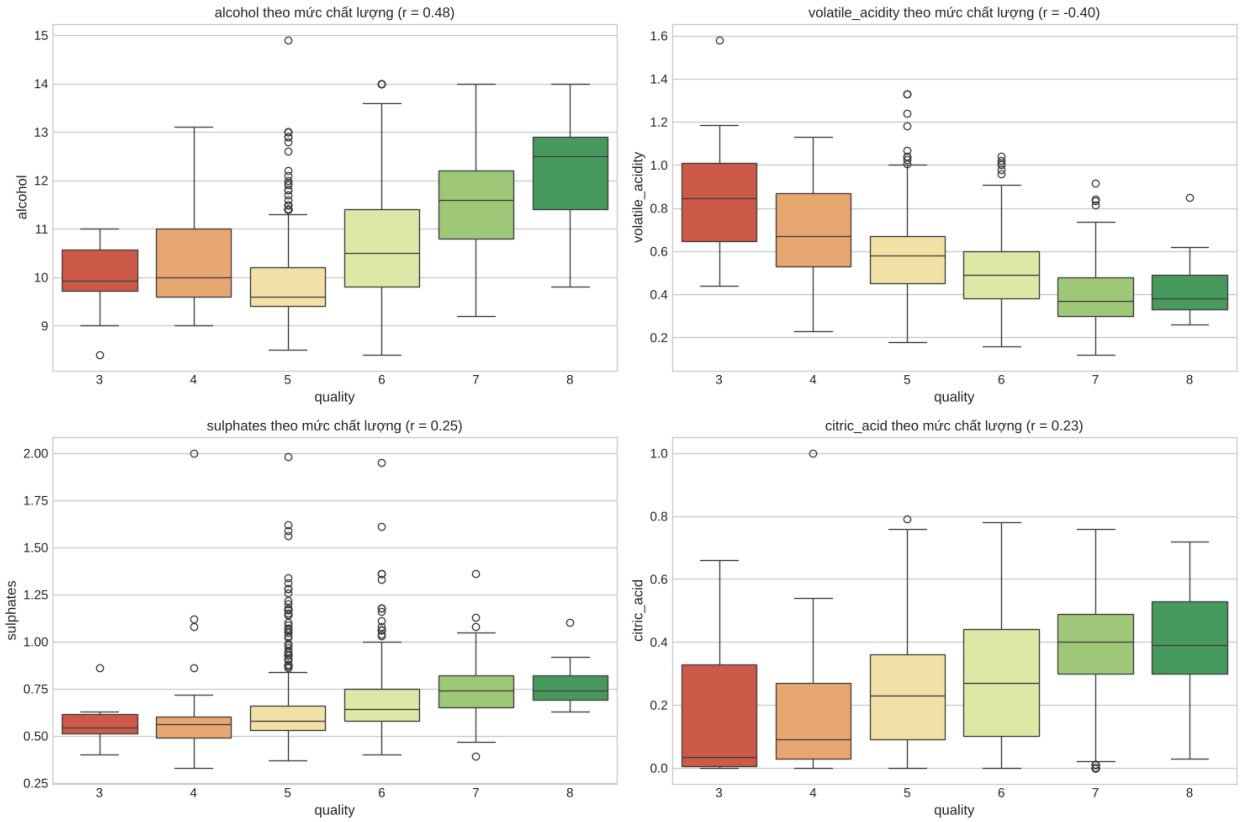
Với 4 đặc trưng có tương quan rõ nhất với quality, nhóm em vẽ boxplot theo từng mức chất lượng:

```
top_features = ['alcohol', 'volatile_acidity', 'sulphates', 'citric_acid']

fig, axes = plt.subplots(2, 2, figsize=(15, 10))
axes = axes.flatten()
for i, col in enumerate(top_features):
    sns.boxplot(data=wine, x='quality', y=col, palette='RdYlGn', ax=axes[i])
    axes[i].set_title(f'{col} theo mức chất lượng (r = {corr_quality[col]:.2f})',
```

```
fontsize=12)
    axes[i].set_xlabel('quality')
plt.tight_layout()
plt.show()
```

Kết quả thực thi:



Hình 3.5. Boxplot 4 đặc trưng quan trọng theo từng mức chất lượng

Nhận xét:

Mối quan hệ giữa các đặc trưng và chất lượng mang tính đơn điệu khá rõ, củng cố kết luận từ hệ số tương quan.

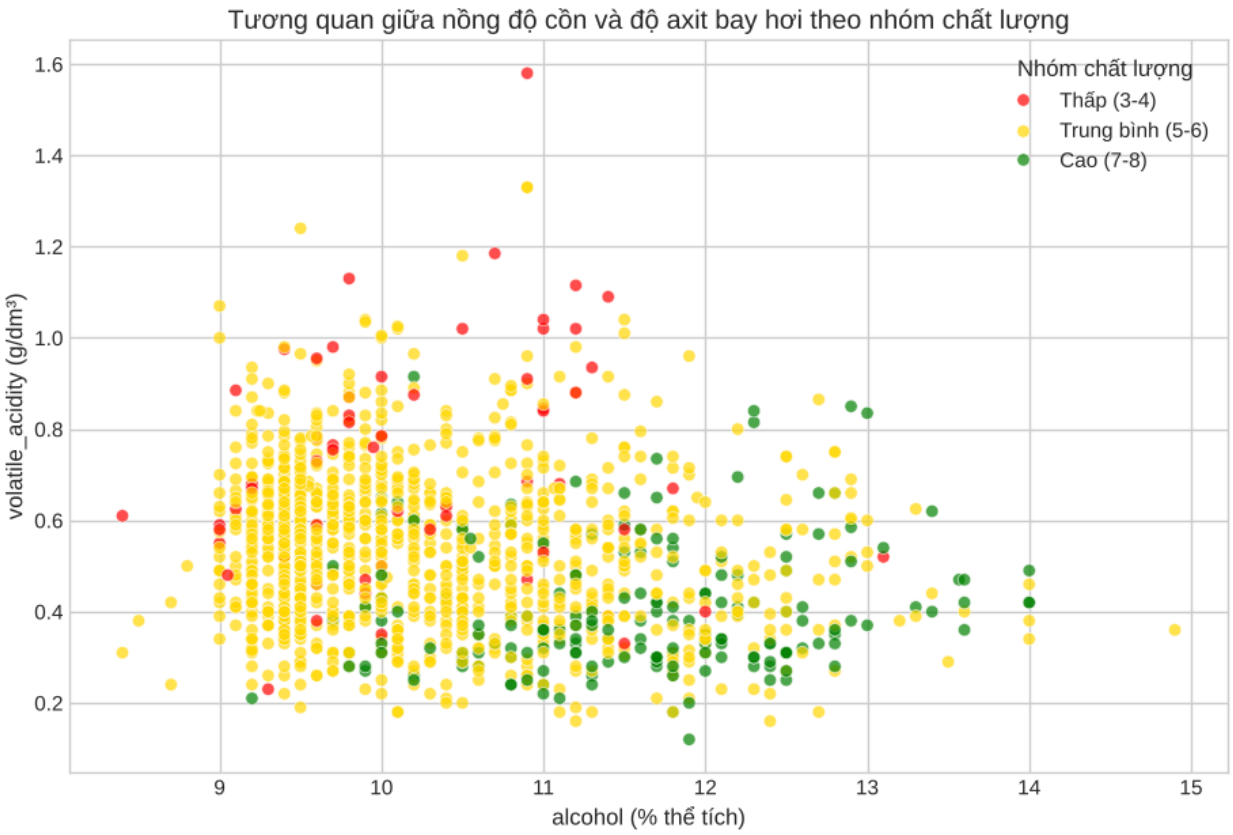
3.2.6. Biểu đồ 6: Scatter plot – alcohol vs volatile_acidity theo nhóm chất lượng

Nhóm em kết hợp hai đặc trưng quan trọng nhất (alcohol và volatile_acidity) trên cùng một scatter plot, tô màu theo nhóm chất lượng:

```
plt.figure(figsize=(11, 7))
sns.scatterplot(data=wine, x='alcohol', y='volatile_acidity', hue='quality_group',
                palette={'Thấp (3-4)': 'red', 'Trung bình (5-6)': 'gold', 'Cao (7-
8)': 'green'},
                alpha=0.7, s=45)
plt.title('Tương quan giữa nồng độ cồn và độ axit bay hơi theo nhóm chất lượng',
fontsize=14)
```

```
plt.xlabel('alcohol (% thể tích)')
plt.ylabel('volatile_acidity (g/dm³)')
plt.legend(title='Nhóm chất lượng')
plt.show()
```

Kết quả thực thi:



Hình 3.6. Scatter plot giữa alcohol và volatile_acidity theo nhóm chất lượng

Nhận xét:

Kết hợp hai đặc trưng này đã giúp tách tương đối nhóm rượu chất lượng cao, tuy nhiên nhóm Trung bình vẫn chồng lấn nhiều.

3.2.7. Biểu đồ 7: Biểu đồ đường – xu hướng trung bình các đặc trưng theo mức chất lượng

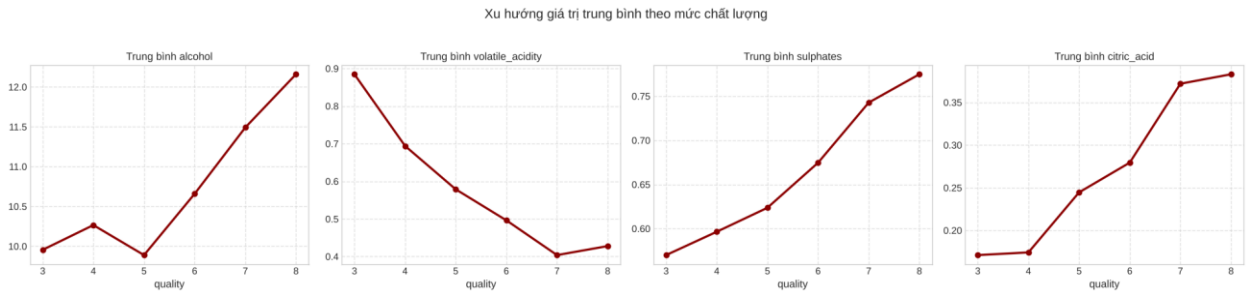
Biểu đồ đường thể hiện xu hướng giá trị trung bình của 4 đặc trưng khi chất lượng tăng dần:

```
xu_huong = wine.groupby('quality')[top_features].mean()

fig, axes = plt.subplots(1, 4, figsize=(20, 4.5))
for i, col in enumerate(top_features):
    axes[i].plot(xu_huong.index, xu_huong[col], marker='o', linewidth=2.5,
```

```
color='darkred')
    axes[i].set_title(f'Trung bình {col}', fontsize=12)
    axes[i].set_xlabel('quality')
    axes[i].grid(True, linestyle='--', alpha=0.6)
plt.suptitle('Xu hướng giá trị trung bình theo mức chất lượng', fontsize=15,
y=1.03)
plt.tight_layout()
plt.show()
```

Kết quả thực thi:



Hình 3.7. Xu hướng giá trị trung bình của 4 đặc trưng theo mức chất lượng

Nhận xét:

Biểu đồ đường giúp nhận diện nhanh chiều hướng tác động của từng đặc trưng lên chất lượng rượu.

3.3. Bài tập thực hành 2 – Phần A: Trực quan hóa dữ liệu bệnh tiểu đường

Phần A sử dụng dữ liệu tiểu đường đã được xử lý giá trị 0 bất hợp lý ở Chương 2 (điền trung vị theo nhóm Outcome). Nhóm em trực quan hóa cơ cấu biến mục tiêu, so sánh phân phối các chỉ số sức khỏe giữa hai nhóm và tìm hiểu tỷ lệ mắc bệnh theo nhóm tuổi, nhóm BMI.

3.3.1. Biểu đồ 1: Cơ cấu biến mục tiêu Outcome (Pie chart & Bar chart)

Nhóm em dùng biểu đồ tròn và biểu đồ cột để thể hiện cơ cấu biến mục tiêu Outcome:

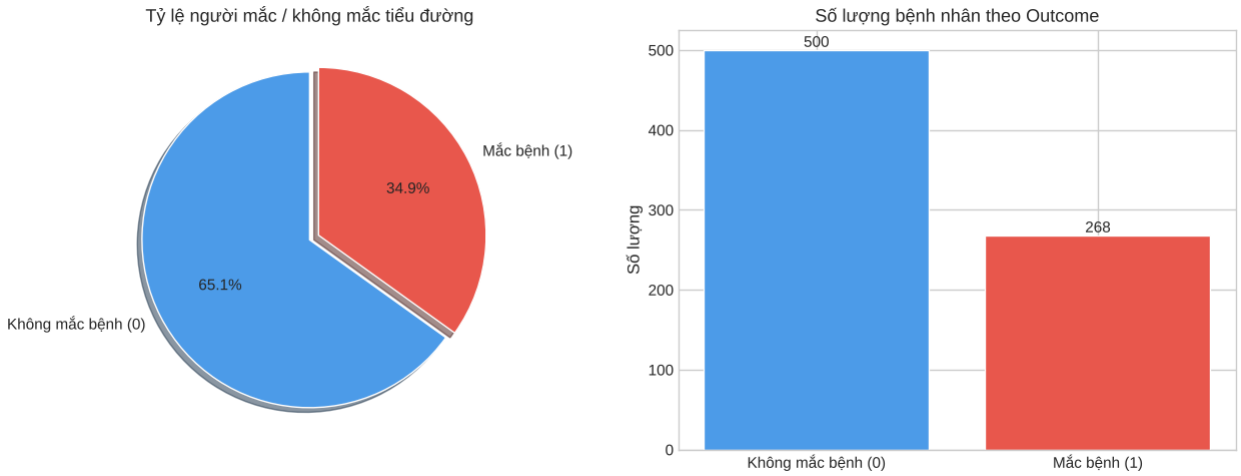
```
o_counts = diab['Outcome'].value_counts().sort_index()
nhan = ['Không mắc bệnh (0)', 'Mắc bệnh (1)']
mau = ['#4C9BE8', '#E8574C']

fig, axes = plt.subplots(1, 2, figsize=(13, 5))
axes[0].pie(o_counts, labels=nhan, colors=mau, autopct='%1.1f%%', startangle=90,
            explode=(0, 0.06), shadow=True, textprops={'fontsize': 11})
axes[0].set_title('Tỷ lệ người mắc / không mắc tiểu đường', fontsize=13)

bars = axes[1].bar(nhan, o_counts.values, color=mau)
axes[1].bar_label(bars, fontsize=11)
```

```
axes[1].set_title('Số lượng bệnh nhân theo Outcome', fontsize=13)
axes[1].set_ylabel('Số lượng')
plt.tight_layout()
plt.show()
```

Kết quả thực thi:



Hình 3.8. Cơ cấu biến mục tiêu Outcome (biểu đồ tròn và biểu đồ cột)

Nhận xét:

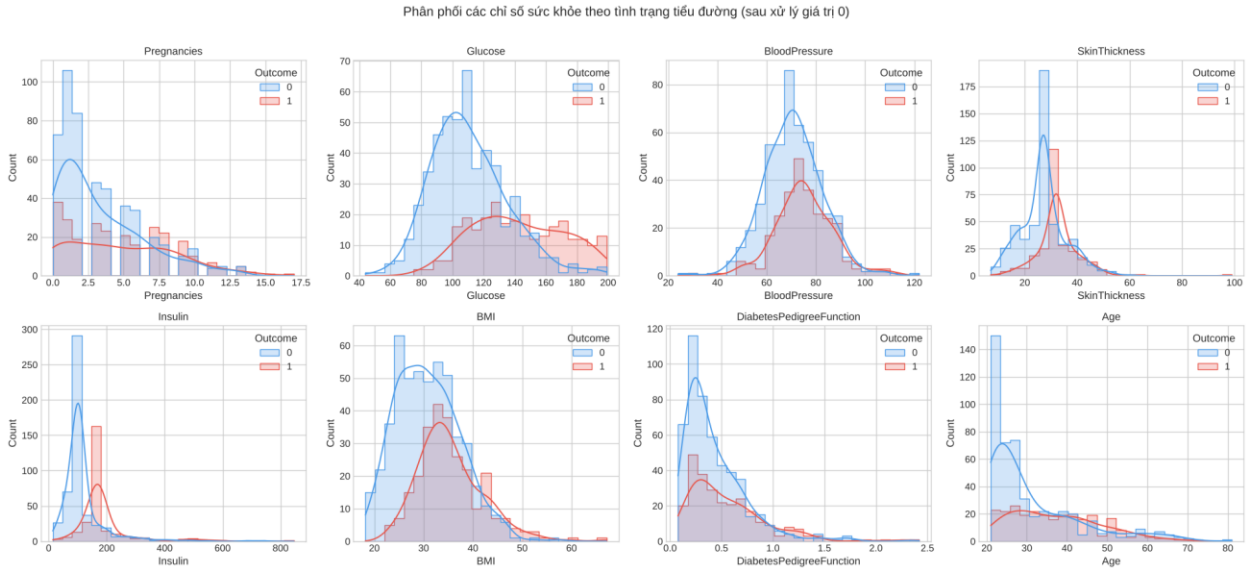
Hai dạng biểu đồ bổ sung cho nhau: biểu đồ tròn nhấn mạnh tỷ lệ, biểu đồ cột thuận tiện so sánh số lượng.

3.3.2. Biểu đồ 2: Histogram các đặc trưng phân theo Outcome

Histogram của 8 chỉ số sức khỏe được vẽ chồng theo hai nhóm Outcome để so sánh phân phối:

```
fig, axes = plt.subplots(2, 4, figsize=(20, 9))
axes = axes.flatten()
for i, col in enumerate(diab_features):
    sns.histplot(data=diab, x=col, hue='Outcome', kde=True, bins=25,
element='step',
                 palette={0: '#4C9BE8', 1: '#E8574C'}, ax=axes[i])
    axes[i].set_title(col, fontsize=12)
plt.suptitle('Phân phối các chỉ số sức khỏe theo tình trạng tiểu đường (sau xử lý
giá trị 0)', fontsize=15, y=1.01)
plt.tight_layout()
plt.show()
```

Kết quả thực thi:



Hình 3.9. Histogram các chỉ số sức khỏe phân theo Outcome

Nhận xét:

Glucose là biến phân tách hai nhóm rõ nhất; các đỉnh nhọn ở Insulin/SkinThickness là hệ quả của việc điền khuyết thiếu, cần lưu ý khi diễn giải.

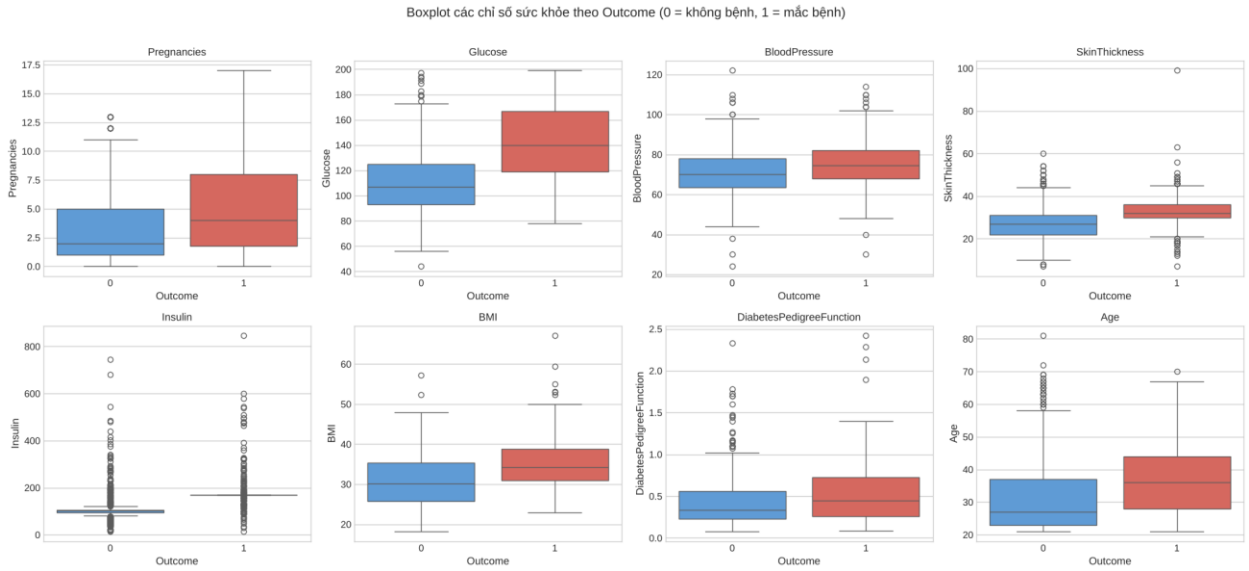
3.3.3. Biểu đồ 3: Boxplot & Violin plot các đặc trưng theo Outcome

Boxplot cho cả 8 chỉ số theo Outcome, kèm violin plot cho hai chỉ số Glucose và BMI:

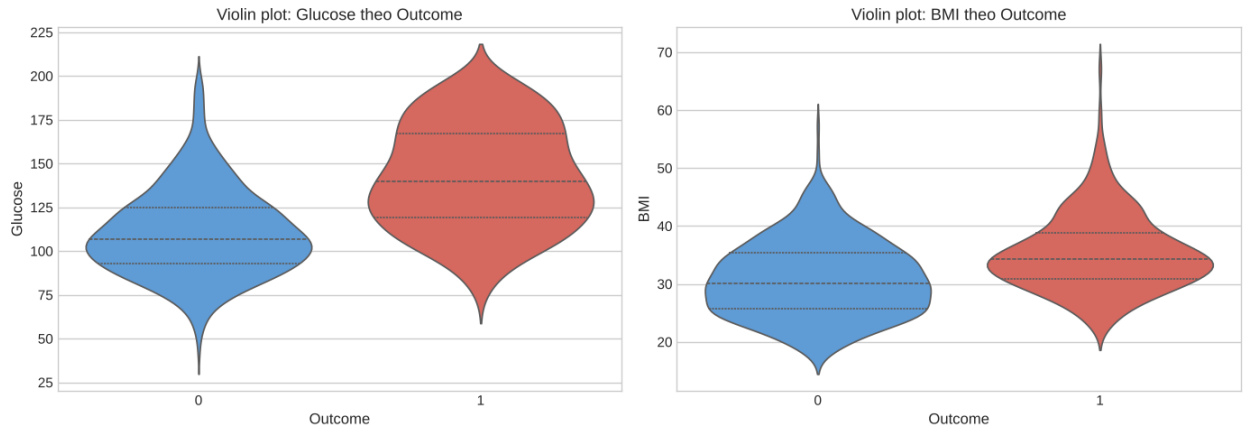
```
fig, axes = plt.subplots(2, 4, figsize=(20, 9))
axes = axes.flatten()
for i, col in enumerate(diab_features):
    sns.boxplot(data=diab, x='Outcome', y=col, palette=['#4C9BE8', '#E8574C'],
ax=axes[i])
    axes[i].set_title(col, fontsize=12)
plt.suptitle('Boxplot các chỉ số sức khỏe theo Outcome (0 = không bệnh, 1 = mắc
bệnh)', fontsize=15, y=1.01)
plt.tight_layout()
plt.show()

fig, axes = plt.subplots(1, 2, figsize=(14, 5))
for i, col in enumerate(['Glucose', 'BMI']):
    sns.violinplot(data=diab, x='Outcome', y=col, palette=['#4C9BE8', '#E8574C'],
inner='quartile', ax=axes[i])
    axes[i].set_title(f'Violin plot: {col} theo Outcome', fontsize=13)
plt.tight_layout()
plt.show()
```

Kết quả thực thi:



Hình 3.10. Boxplot các chỉ số sức khỏe theo Outcome



Hình 3.11. Violin plot của Glucose và BMI theo Outcome

Nhận xét:

Glucose, BMI, Age và Pregnancies đều cao hơn ở nhóm mắc bệnh; Violin plot cung cấp nhiều thông tin hơn Boxplot về hình dạng phân phối.

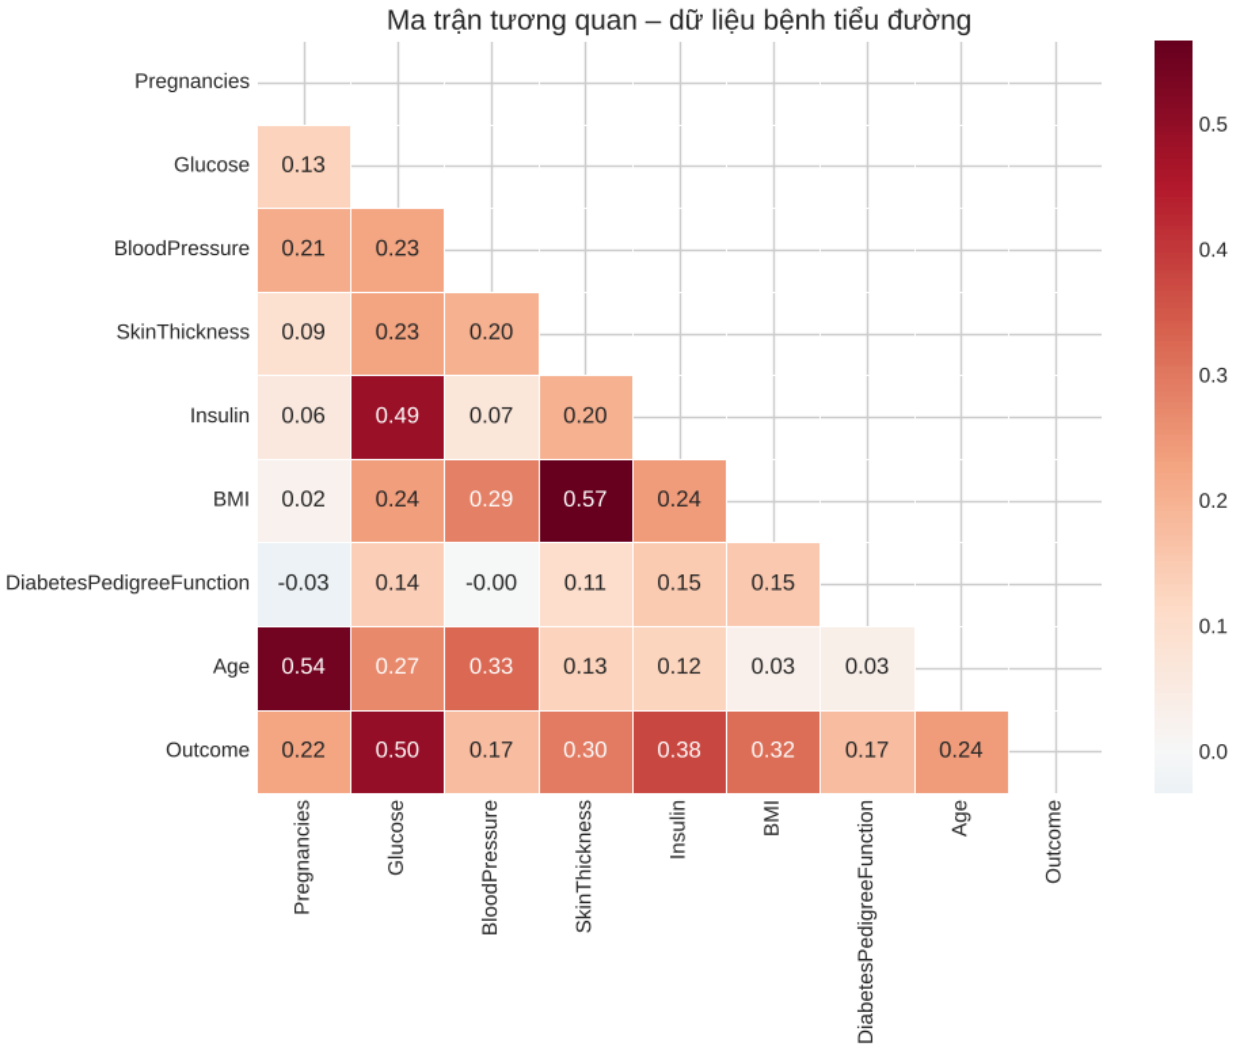
3.3.4. Biểu đồ 4: Heatmap ma trận tương quan

Nhóm em vẽ heatmap ma trận tương quan của dữ liệu tiểu đường sau xử lý:

```
plt.figure(figsize=(10, 8))
corr_diab = diab.corr()
mask = np.triu(np.ones_like(corr_diab, dtype=bool))
sns.heatmap(corr_diab, mask=mask, annot=True, fmt='.2f', cmap='RdBu_r', center=0,
linewidths=.5)
plt.title('Ma trận tương quan - dữ liệu bệnh tiểu đường', fontsize=15)
```

```
plt.tight_layout()
plt.show()
```

Kết quả thực thi:



Hình 3.12. Heatmap ma trận tương quan dữ liệu bệnh tiểu đường

Nhận xét:

Không có cặp biến nào tương quan quá cao (> 0,8) nên mức độ đa cộng tuyến thấp, có thể giữ đủ các biến khi xây dựng mô hình.

3.3.5. Biểu đồ 5: Scatter plot – Glucose vs BMI và Age vs Pregnancies

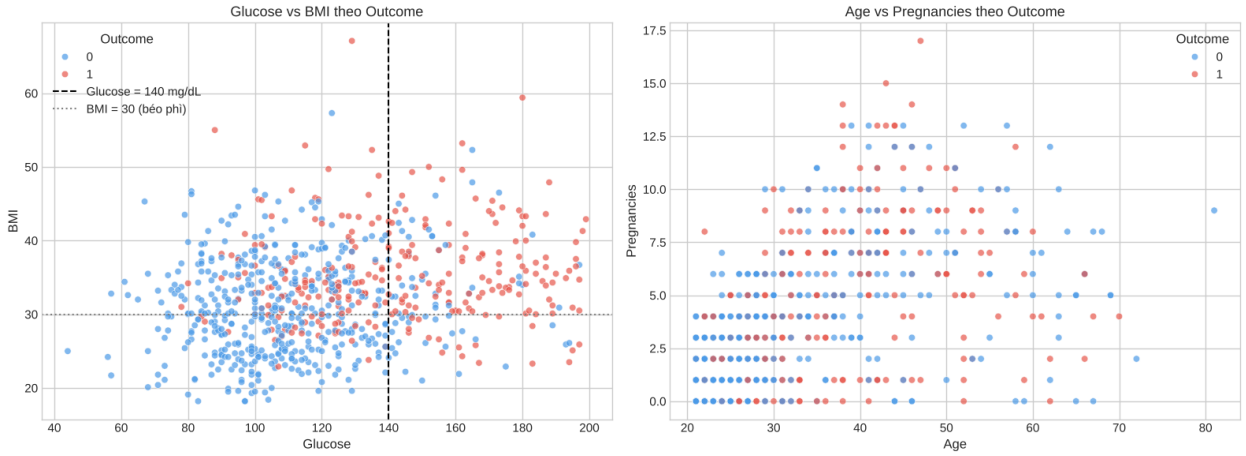
Hai scatter plot thể hiện quan hệ Glucose – BMI (kèm các ngưỡng tham chiếu) và Age – Pregnancies:

```
fig, axes = plt.subplots(1, 2, figsize=(16, 6))
```

```
sns.scatterplot(data=diab, x='Glucose', y='BMI', hue='Outcome', palette={0:
'#4C9BE8', 1: '#E8574C'},
                alpha=0.7, ax=axes[0])
axes[0].axvline(140, color='black', linestyle='--', label='Glucose = 140 mg/dL')
axes[0].axhline(30, color='gray', linestyle=':', label='BMI = 30 (béo phì)')
axes[0].legend(title='Outcome')
axes[0].set_title('Glucose vs BMI theo Outcome', fontsize=13)

sns.scatterplot(data=diab, x='Age', y='Pregnancies', hue='Outcome', palette={0:
'#4C9BE8', 1: '#E8574C'},
                alpha=0.7, ax=axes[1])
axes[1].set_title('Age vs Pregnancies theo Outcome', fontsize=13)
plt.tight_layout()
plt.show()
```

Kết quả thực thi:



Hình 3.13. Scatter plot Glucose – BMI và Age – Pregnancies theo Outcome

Nhận xét:

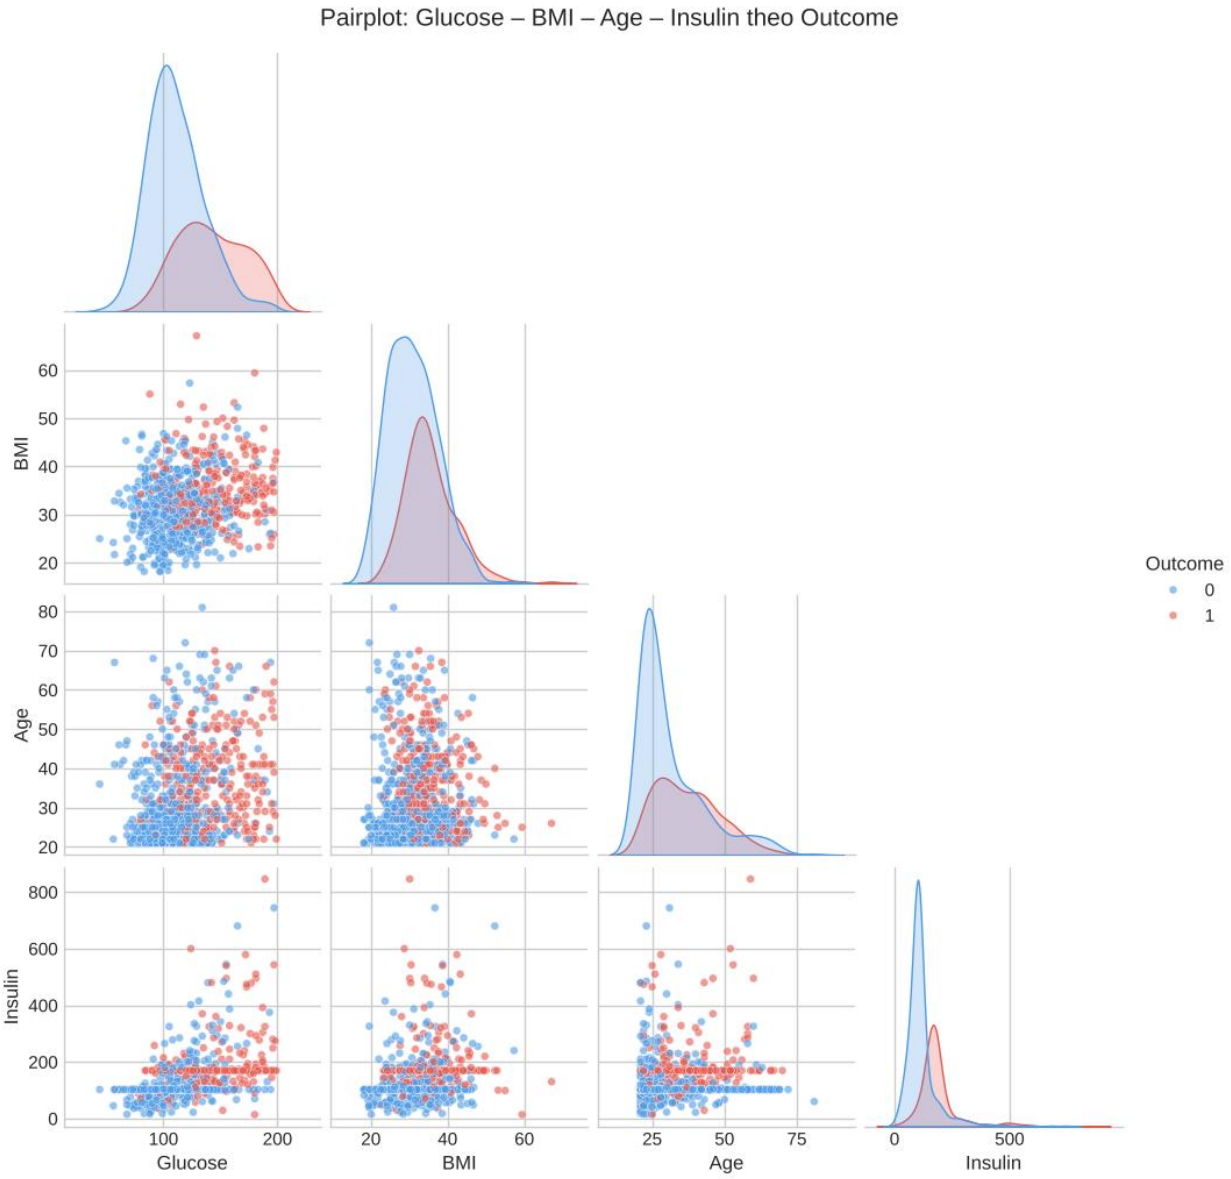
Nhóm có đồng thời Glucose cao và BMI ≥ 30 là nhóm nguy cơ cao nhất.

3.3.6. Biểu đồ 6: Pairplot các biến quan trọng

Pairplot giúp quan sát đồng thời mọi cặp quan hệ giữa 4 biến quan trọng:

```
sns.pairplot(diab[['Glucose', 'BMI', 'Age', 'Insulin', 'Outcome']], hue='Outcome',
             palette={0: '#4C9BE8', 1: '#E8574C'}, corner=True, plot_kws={'alpha':
0.6, 's': 25})
plt.suptitle('Pairplot: Glucose - BMI - Age - Insulin theo Outcome', fontsize=15,
y=1.02)
plt.show()
```

Kết quả thực thi:



Hình 3.14. Pairplot giữa Glucose, BMI, Age và Insulin theo Outcome

Nhận xét:

Glucose tách hai nhóm tốt nhất; trong các ô có Insulin xuất hiện 2 dải ngang do giá trị đã điền – một hạn chế của việc điền khuyết thiếu khi tỷ lệ thiếu lên tới 48,7%.

3.3.7. Biểu đồ 7: Tỷ lệ mắc bệnh theo nhóm tuổi và nhóm BMI

Nhóm em chia tuổi và BMI (theo chuẩn WHO) thành các nhóm, sau đó tính tỷ lệ mắc bệnh của từng nhóm:

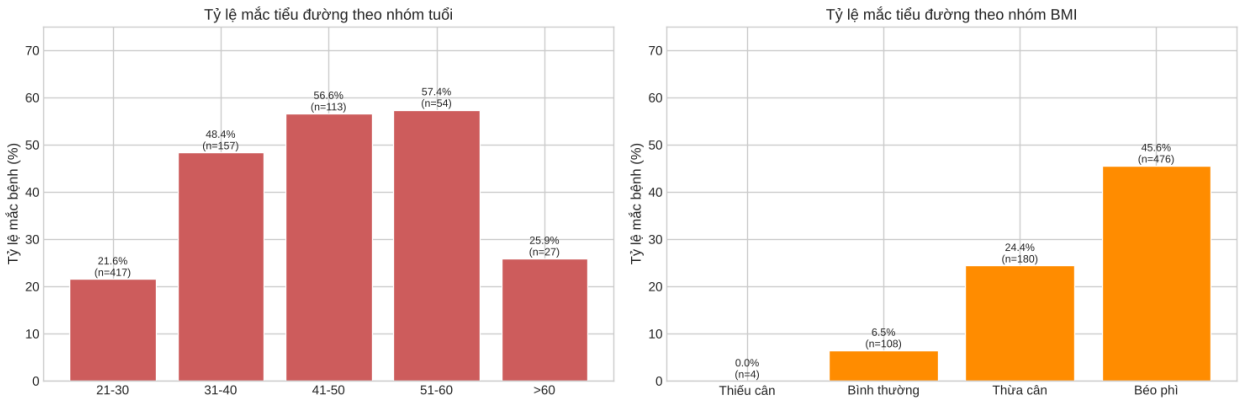
```
diab['Age_group'] = pd.cut(diab['Age'], bins=[20, 30, 40, 50, 60, 90],
                           labels=['21-30', '31-40', '41-50', '51-60', '>60'])
diab['BMI_group'] = pd.cut(diab['BMI'], bins=[0, 18.5, 25, 30, 100],
                           labels=['Thiếu cân', 'Bình thường', 'Thừa cân', 'Béo
phì'])

ty_le_tuoi = diab.groupby('Age_group', observed=True)['Outcome'].agg(['count',
'mean'])
ty_le_bmi = diab.groupby('BMI_group', observed=True)['Outcome'].agg(['count',
'mean'])

fig, axes = plt.subplots(1, 2, figsize=(15, 5))
b1 = axes[0].bar(ty_le_tuoi.index.astype(str), ty_le_tuoi['mean'] * 100,
color='indianred')
axes[0].bar_label(b1, labels=[f"{v*100:.1f}%\n(n={n})" for v, n in
zip(ty_le_tuoi['mean'], ty_le_tuoi['count'])], fontsize=9)
axes[0].set_title('Tỷ lệ mắc tiểu đường theo nhóm tuổi', fontsize=13)
axes[0].set_ylabel('Tỷ lệ mắc bệnh (%)'); axes[0].set_ylim(0, 75)

b2 = axes[1].bar(ty_le_bmi.index.astype(str), ty_le_bmi['mean'] * 100,
color='darkorange')
axes[1].bar_label(b2, labels=[f"{v*100:.1f}%\n(n={n})" for v, n in
zip(ty_le_bmi['mean'], ty_le_bmi['count'])], fontsize=9)
axes[1].set_title('Tỷ lệ mắc tiểu đường theo nhóm BMI', fontsize=13)
axes[1].set_ylabel('Tỷ lệ mắc bệnh (%)'); axes[1].set_ylim(0, 75)
plt.tight_layout()
plt.show()
```

Kết quả thực thi:



Hình 3.15. Tỷ lệ mắc tiểu đường theo nhóm tuổi và nhóm BMI

Nhận xét:

Tuổi trung niên và béo phì là các yếu tố nguy cơ rõ rệt; kết quả nhóm > 60 tuổi và nhóm Thiếu cân (n = 4) chưa đủ tin cậy do quá ít mẫu.

3.4. Bài tập thực hành 2 – Phần B: EDA dữ liệu mua sắm Online Retail

Phần B thực hiện một quy trình EDA hoàn chỉnh trên dữ liệu giao dịch của một cửa hàng bán lẻ trực tuyến tại Anh trong giai đoạn 01/12/2010 – 09/12/2011. Đây là bộ dữ

liệu lớn (hơn 540 nghìn dòng) và có nhiều vấn đề về chất lượng, nên trọng tâm của phần này là làm sạch dữ liệu trước khi phân tích doanh thu, sản phẩm và khách hàng.

3.4.1. Bước 1: Nạp dữ liệu & kiểm tra tổng quan

Dữ liệu được đọc từ file Excel, trong đó InvoiceNo và StockCode được ép kiểu chuỗi:

```
retail_raw = pd.read_excel(tim_file("Online Retail.xlsx"),
                           dtype={'InvoiceNo': str, 'StockCode': str})
retail = retail_raw.copy()
print(f"Kích thước dữ liệu: {retail.shape[0]:,} dòng, {retail.shape[1]} cột")
retail.head()
```

Kết quả thực thi:

```
Đã tìm thấy file dữ liệu tại: ./Lab_Phan_tich_kham_pha_du_lieu/online-retail/Online
Retail.xlsx
Kích thước dữ liệu: 541,909 dòng, 8 cột
```

Nhận xét:

Dữ liệu có 541.909 dòng, 8 cột – mỗi dòng là một sản phẩm trong một hóa đơn.

Kiểm tra kiểu dữ liệu và số giá trị non-null

Nhóm em kiểm tra kiểu dữ liệu và số giá trị non-null của 8 cột:

```
retail.info()
```

Kết quả thực thi:

```
<class 'pandas.DataFrame'>
RangeIndex: 541909 entries, 0 to 541908
Data columns (total 8 columns):
 #   Column       Non-Null Count   Dtype
---  ------       --------------   -----
 0   InvoiceNo    541909 non-null  str
 1   StockCode    541909 non-null  str
 2   Description  540455 non-null  object
 3   Quantity     541909 non-null  int64
 4   InvoiceDate  541909 non-null  datetime64[us]
 5   UnitPrice    541909 non-null  float64
 6   CustomerID   406829 non-null  float64
 7   Country      541909 non-null  str
dtypes: datetime64[us](1), float64(2), int64(1), object(1), str(3)
memory usage: 33.1+ MB
```

Nhận xét:

InvoiceDate đúng kiểu thời gian nên phân tích được theo tháng/ngày/giờ; mức độ thiếu cụ thể sẽ được thống kê ở Bước 2.

3.4.2. Bước 2: Kiểm tra khuyết thiếu, trùng lặp & giá trị bất thường

Nhóm em thống kê giá trị khuyết thiếu, dòng trùng lặp và các giá trị bất thường như hóa đơn hủy, số lượng hoặc đơn giá không dương, mã phí dịch vụ:

```
miss_rt = pd.DataFrame({'Số lượng thiếu': retail.isnull().sum(),
                        'Tỷ lệ %': (retail.isnull().mean() * 100).round(2)})
display(miss_rt[miss_rt['Số lượng thiếu'] > 0])

print(f"Số dòng trùng lặp hoàn toàn: {retail.duplicated().sum():,}")

huy_don = retail['InvoiceNo'].str.startswith('C')
print(f"Số dòng thuộc hóa đơn bị hủy (InvoiceNo bắt đầu bằng 'C'):
{huy_don.sum():,}")
print(f"Số dòng có Quantity <= 0: {(retail['Quantity'] <= 0).sum():,}")
print(f"Số dòng có UnitPrice <= 0: {(retail['UnitPrice'] <= 0).sum():,}")
print(f"Số dòng thuộc mã phí/dịch vụ (POST, DOT, M, D, BANK CHARGES...):
{retail['StockCode'].isin(['POST','DOT','M','m','D','C2','BANK
CHARGES','PADS','CRUK','AMAZONFEE','S','B']).sum():,}")
```

Kết quả thực thi:

	Số lượng thiếu	Tỷ lệ %
Description	1454	0.27
CustomerID	135080	24.93

Bảng 3.3. Thống kê giá trị khuyết thiếu của dữ liệu Online Retail

```
Số dòng trùng lặp hoàn toàn: 5,268
Số dòng thuộc hóa đơn bị hủy (InvoiceNo bắt đầu bằng 'C'): 9,288
Số dòng có Quantity <= 0: 10,624
Số dòng có UnitPrice <= 0: 2,517
Số dòng thuộc mã phí/dịch vụ (POST, DOT, M, D, BANK CHARGES...): 2,916
```

Nhận xét:

Dữ liệu thô có nhiều vấn đề cần làm sạch trước khi phân tích, đặc biệt là đơn hủy và giao dịch không xác định khách hàng.

3.4.3. Bước 3: Thống kê mô tả dữ liệu thô

Thống kê mô tả trên dữ liệu thô cho thấy rõ mức độ bất thường của Quantity và UnitPrice:

```
retail[['Quantity', 'UnitPrice']].describe().T
```

Kết quả thực thi:

	count	mean	std	min	25%	50%	75%	max
Quantity	541909.0	9.552250	218.081158	-80995.00	1.00	3.00	10.00	80995.0
UnitPrice	541909.0	4.611114	96.759853	-11062.06	1.25	2.08	4.13	38970.0

Bảng 3.4. Thống kê mô tả Quantity và UnitPrice trên dữ liệu thô

Nhận xét:

Giá trị âm và các cặp đặt – hủy cực lớn chứng minh việc làm sạch là bắt buộc, nếu không mọi chỉ số doanh thu sẽ bị sai lệch.

3.4.4. Bước 4a: Làm sạch dữ liệu – 4 bước cơ bản

Từ các vấn đề đã phát hiện, nhóm em thực hiện 4 bước làm sạch cơ bản (đồng thời lưu lại các dòng hủy đơn để dùng ở bước sau):

```
n0 = len(retail)
huy = retail[retail['InvoiceNo'].str.startswith('C')].dropna(subset=['CustomerID'])
retail = retail.drop_duplicates()
retail = retail[~retail['InvoiceNo'].str.startswith('C')]
retail = retail[(retail['Quantity'] > 0) & (retail['UnitPrice'] > 0)]
retail = retail.dropna(subset=['CustomerID'])
print(f"Số dòng sau 4 bước làm sạch cơ bản: {len(retail):,}")
```

Kết quả thực thi:

```
Số dòng sau 4 bước làm sạch cơ bản: 392,692
```

Nhận xét:

Dữ liệu giảm từ 541.909 xuống khoảng 392 nghìn dòng, chỉ còn các giao dịch mua hợp lệ của khách hàng xác định được.

3.4.5. Bước 4b: Loại các đơn mua đã bị hủy sau đó & các mã phí không phải hàng hóa

Tiếp theo, nhóm em loại các dòng mua đã bị hủy ngay sau đó và các mã không phải hàng hóa:

```
khoa_huy = set(zip(huy['CustomerID'], huy['StockCode'], -huy['Quantity']))
bi_huy = [k in khoa_huy for k in zip(retail['CustomerID'], retail['StockCode'],
retail['Quantity'])]
print(f"Số dòng mua bị hủy sau đó được loại bỏ: {sum(bi_huy):,}")
retail = retail[~pd.Series(bi_huy, index=retail.index)]

ma_phi = ['POST', 'DOT', 'M', 'm', 'D', 'C2', 'BANK CHARGES', 'PADS', 'CRUK',
'AMAZONFEE', 'S', 'B']
retail = retail[~retail['StockCode'].isin(ma_phi)]

print(f"Số dòng sau khi bỏ mã phí: {len(retail):,}")
```

Kết quả thực thi:

```
Số dòng mua bị hủy sau đó được loại bỏ: 5,472
Số dòng sau khi bỏ mã phí: 385,929
```

Nhận xét:

Bước này giúp Top sản phẩm và doanh thu phản ánh đúng hàng hóa thực bán. Cách so khớp là gần đúng: nếu khách mua cùng một mặt hàng nhiều lần với cùng số lượng thì có thể loại dư một vài dòng.

3.4.6. Bước 4c: Tạo đặc trưng mới & tổng hợp kết quả làm sạch

Sau khi làm sạch, nhóm em tạo thêm các đặc trưng mới phục vụ phân tích và tổng hợp lại kết quả:

```
retail['CustomerID'] = retail['CustomerID'].astype(int)

# Tạo đặc trưng mới
retail['TotalPrice'] = retail['Quantity'] * retail['UnitPrice']
retail['YearMonth'] = retail['InvoiceDate'].dt.to_period('M').astype(str)
retail['DayOfWeek'] = retail['InvoiceDate'].dt.dayofweek
retail['Hour'] = retail['InvoiceDate'].dt.hour

retail = retail.reset_index(drop=True)
print(f"Số dòng ban đầu: {n0:,} -> sau làm sạch: {len(retail):,} (giữ lại
{len(retail)/n0*100:.1f}%)")
print(f"Số khách hàng: {retail['CustomerID'].nunique():,} | Số hóa đơn:
{retail['InvoiceNo'].nunique():,} | "
      f"Số sản phẩm: {retail['StockCode'].nunique():,} | Số quốc gia:
{retail['Country'].nunique()}")
print(f"Thời gian: {retail['InvoiceDate'].min()} -> {retail['InvoiceDate'].max()}")
print(f"Tổng doanh thu: £{retail['TotalPrice'].sum():,.2f}")
```

Kết quả thực thi:

```
Số dòng ban đầu: 541,909 -> sau làm sạch: 385,929 (giữ lại 71.2%)
Số khách hàng: 4,321 | Số hóa đơn: 18,162 | Số sản phẩm: 3,644 | Số quốc gia: 37
Thời gian: 2010-12-01 08:26:00 -> 2011-12-09 12:50:00
Tổng doanh thu: £8,199,423.90
```

Nhận xét:

Còn 385.929 dòng (71,2%) với 4.321 khách hàng, 18.162 hóa đơn, 3.644 sản phẩm, 37 quốc gia; tổng doanh thu ≈ £8,20 triệu trong giai đoạn 01/12/2010 – 09/12/2011.

3.4.7. Bước 5: Thống kê mô tả sau làm sạch & phân phối giá trị giao dịch

Nhóm em lập bảng thống kê mô tả sau làm sạch và trực quan hóa phân phối giá trị giao dịch trên thang log:

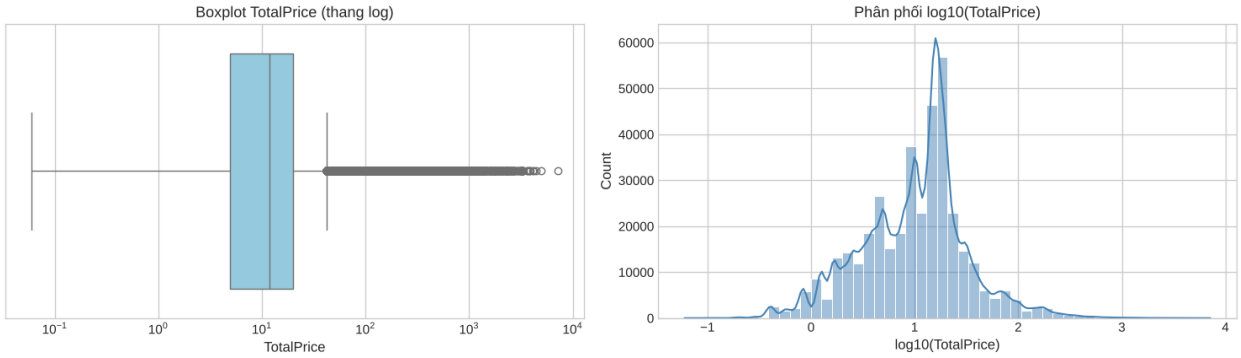
```
display(bang_thong_ke_mo_ta(retail, ['Quantity', 'UnitPrice', 'TotalPrice'])
        [['Mean', 'Median', 'Std', 'Min', 'Q1', 'Q3', 'Max', 'Skewness']].round(3))

fig, axes = plt.subplots(1, 2, figsize=(15, 4.5))
sns.boxplot(x=retail['TotalPrice'], color='skyblue', ax=axes[0])
axes[0].set_xscale('log')
axes[0].set_title('Boxplot TotalPrice (thang log)', fontsize=13)
sns.histplot(np.log10(retail['TotalPrice']), bins=50, kde=True, color='steelblue',
ax=axes[1])
axes[1].set_title('Phân phối log10(TotalPrice)', fontsize=13)
axes[1].set_xlabel('log10(TotalPrice)')
plt.tight_layout()
plt.show()
```

Kết quả thực thi:

Biến	Mean	Median	Std	Min	Q1	Q3	Max	Skewness
Quantity	12.598	6.00	41.456	1.00	2.00	12.00	4800.00	29.935
UnitPrice	2.845	1.85	3.969	0.04	1.25	3.75	649.50	29.211
TotalPrice	21.246	11.90	66.310	0.06	4.95	19.80	7144.72	26.915

Bảng 3.5. Thống kê mô tả Quantity, UnitPrice và TotalPrice sau làm sạch



Hình 3.16. Boxplot và phân phối log10(TotalPrice) sau làm sạch

Nhận xét:

Dữ liệu vẫn lệch phải rất mạnh do các đơn hàng sỉ số lượng lớn; trên thang log, TotalPrice có dạng gần chuẩn, tập trung quanh £10–£20 mỗi dòng.

3.4.8. Bước 6: Doanh thu theo quốc gia

Doanh thu được tổng hợp theo quốc gia, vẽ Top 10 có và không tính thị trường Anh:

```
dt_qg = retail.groupby('Country')['TotalPrice'].sum().sort_values(ascending=False)
ty_le_uk = dt_qg['United Kingdom'] / dt_qg.sum() * 100
print(f"United Kingdom chiếm {ty_le_uk:.1f}% tổng doanh thu")

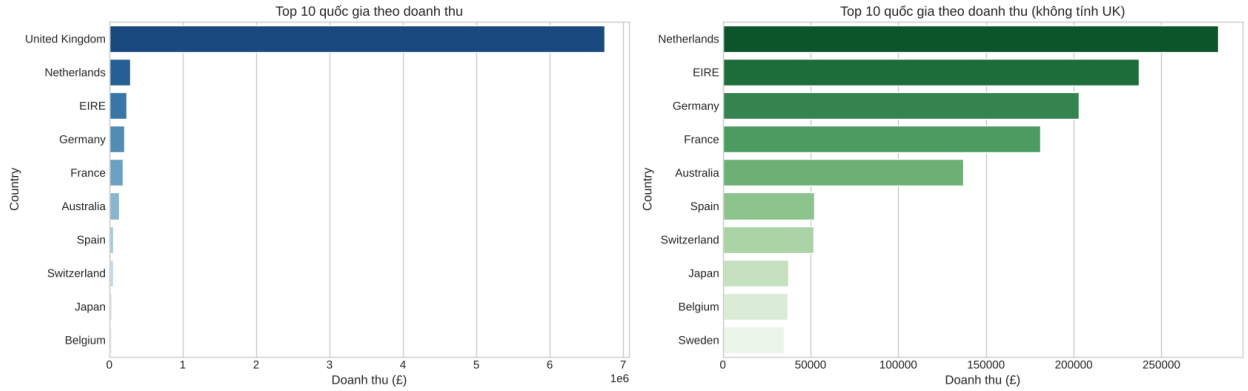
fig, axes = plt.subplots(1, 2, figsize=(17, 5.5))
top10 = dt_qg.head(10)
sns.barplot(x=top10.values, y=top10.index, palette='Blues_r', ax=axes[0])
axes[0].set_title('Top 10 quốc gia theo doanh thu', fontsize=13)
axes[0].set_xlabel('Doanh thu (£)')

top10_ngoai = dt_qg.drop('United Kingdom').head(10)
sns.barplot(x=top10_ngoai.values, y=top10_ngoai.index, palette='Greens_r',
ax=axes[1])
```

```
axes[1].set_title('Top 10 quốc gia theo doanh thu (không tính UK)', fontsize=13)
axes[1].set_xlabel('Doanh thu (£)')
plt.tight_layout()
plt.show()
```

Kết quả thực thi:

```
United Kingdom chiếm 82.2% tổng doanh thu
```



Hình 3.17. Top 10 quốc gia theo doanh thu (có và không tính United Kingdom)

Nhận xét:

Doanh nghiệp phụ thuộc rất lớn vào thị trường nội địa Anh; các nước châu Âu lân cận là thị trường xuất khẩu tiềm năng nhất.

3.4.9. Bước 7: Xu hướng doanh thu theo tháng

Nhóm em tổng hợp doanh thu, số hóa đơn, số khách hàng theo tháng và vẽ biểu đồ kết hợp hai trục:

```
dt_thang = retail.groupby('YearMonth').agg(DoanhThu=('TotalPrice', 'sum'),
                                           SoHoaDon=('InvoiceNo', 'nunique'),
                                           SoKhach=('CustomerID', 'nunique'))
display(dt_thang.round(0))

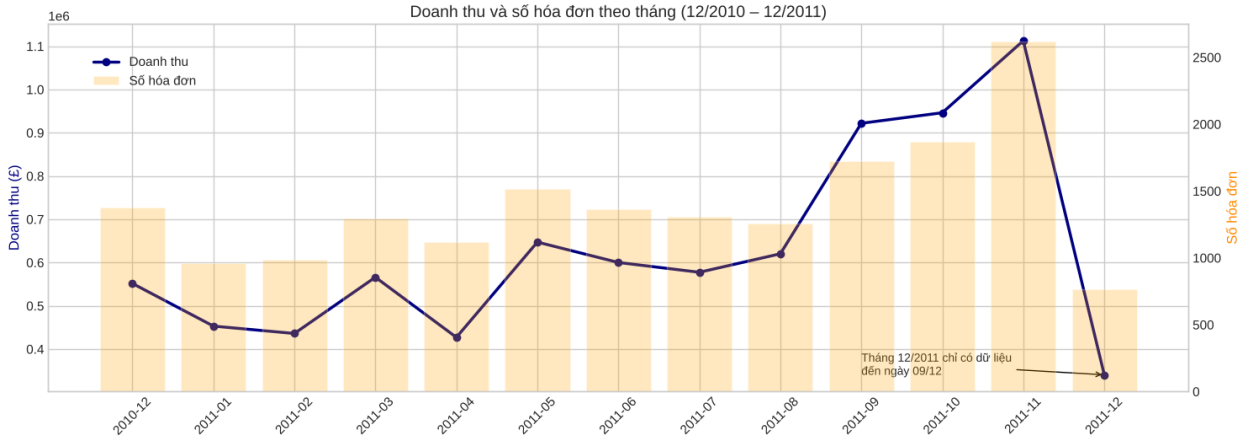
fig, ax1 = plt.subplots(figsize=(15, 5.5))
ax1.plot(dt_thang.index, dt_thang['DoanhThu'], marker='o', linewidth=2.5,
color='navy', label='Doanh thu')
ax1.set_ylabel('Doanh thu (£)', color='navy')
ax1.tick_params(axis='x', rotation=45)
ax2 = ax1.twinx()
ax2.bar(dt_thang.index, dt_thang['SoHoaDon'], alpha=0.25, color='orange', label='Số
hóa đơn')
ax2.set_ylabel('Số hóa đơn', color='darkorange')
ax2.grid(False)
ax1.set_title('Doanh thu và số hóa đơn theo tháng (12/2010 - 12/2011)',
fontsize=14)
ax1.annotate('Tháng 12/2011 chỉ có dữ liệu\nđến ngày 09/12',
             xy=(len(dt_thang) - 1, dt_thang['DoanhThu'].iloc[-1]),
xytext=(len(dt_thang) - 4, dt_thang['DoanhThu'].iloc[-1]),
             arrowprops=dict(arrowstyle='->', color='black'), fontsize=10)
```

```
fig.legend(loc='upper left', bbox_to_anchor=(0.07, 0.88))
plt.tight_layout()
plt.show()
```

Kết quả thực thi:

YearMonth	DoanhThu	SoHoaDon	SoKhach
2010-12	551592.0	1378	882
2011-01	453016.0	963	733
2011-02	435946.0	984	753
2011-03	565995.0	1296	968
2011-04	427055.0	1120	846
2011-05	647181.0	1517	1050
2011-06	600076.0	1365	982
2011-07	577445.0	1308	942
2011-08	620151.0	1258	930
2011-09	921786.0	1721	1250
2011-10	946162.0	1866	1353
2011-11	1112575.0	2618	1653
2011-12	340446.0	768	610

Bảng 3.6. Doanh thu, số hóa đơn và số khách hàng theo tháng



Hình 3.18. Doanh thu và số hóa đơn theo tháng (12/2010 – 12/2011)

Nhận xét:

Dữ liệu có tính mùa vụ rõ rệt vào mùa mua sắm cuối năm. Doanh thu tháng 12/2011 thấp vì dữ liệu chỉ có đến ngày 09/12, không phải doanh số sụt giảm.

3.4.10. Bước 8: Hành vi mua sắm theo ngày trong tuần và theo giờ

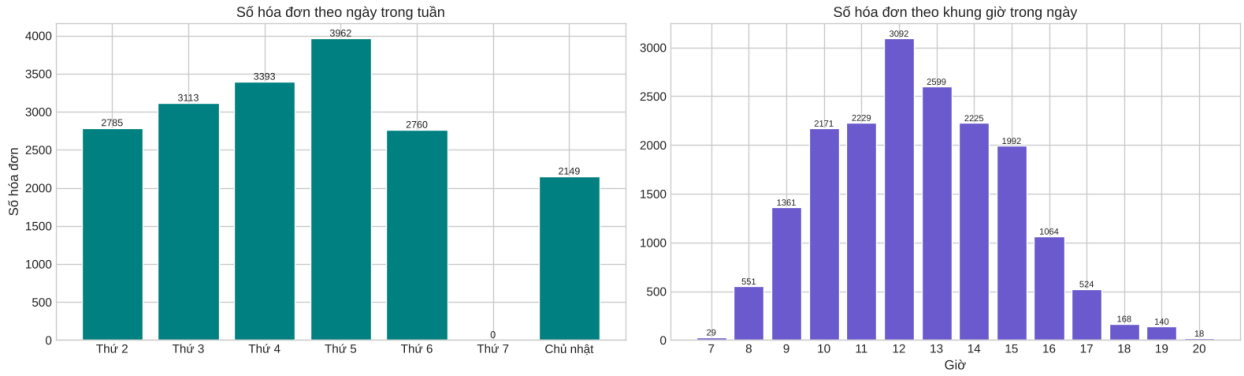
Để tìm hiểu hành vi mua sắm, nhóm em đếm số hóa đơn theo ngày trong tuần và theo giờ:

```
ten_thu = {0: 'Thứ 2', 1: 'Thứ 3', 2: 'Thứ 4', 3: 'Thứ 5', 4: 'Thứ 6', 5: 'Thứ 7',
6: 'Chủ nhật'}
hd_thu = retail.groupby('DayOfWeek')['InvoiceNo'].nunique().reindex(range(7),
fill_value=0)
hd_gio = retail.groupby('Hour')['InvoiceNo'].nunique()

fig, axes = plt.subplots(1, 2, figsize=(16, 5))
b = axes[0].bar([ten_thu[i] for i in hd_thu.index], hd_thu.values, color='teal')
axes[0].bar_label(b, fontsize=9)
axes[0].set_title('Số hóa đơn theo ngày trong tuần', fontsize=13)
axes[0].set_ylabel('Số hóa đơn')

b = axes[1].bar(hd_gio.index, hd_gio.values, color='slateblue')
axes[1].bar_label(b, fontsize=8)
axes[1].set_title('Số hóa đơn theo khung giờ trong ngày', fontsize=13)
axes[1].set_xlabel('Giờ')
axes[1].set_xticks(hd_gio.index)
plt.tight_layout()
plt.show()
```

Kết quả thực thi:



Hình 3.19. Số hóa đơn theo ngày trong tuần và theo khung giờ trong ngày

Nhận xét:

Khách hàng chủ yếu là doanh nghiệp/nhà bán sỉ mua trong giờ hành chính; việc không có giao dịch Thứ 7 cho thấy cửa hàng không xử lý đơn vào ngày này.

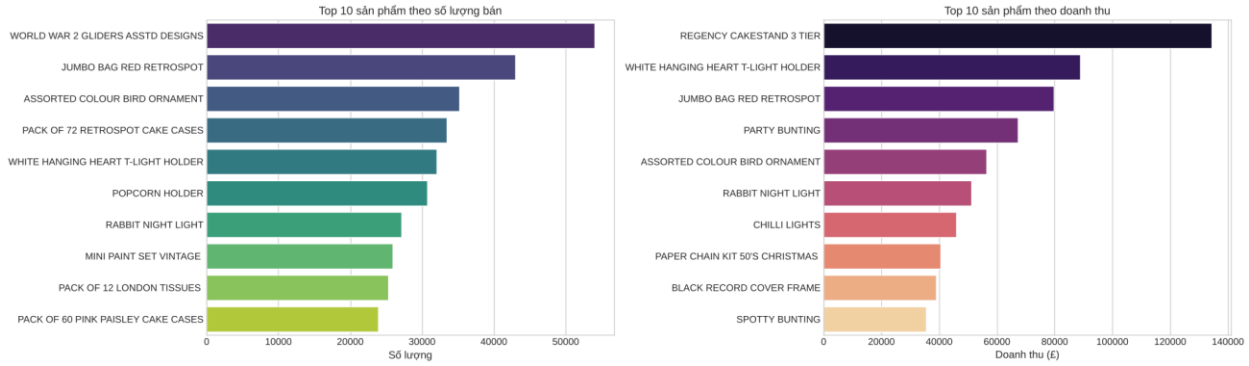
3.4.11. Bước 9: Top sản phẩm bán chạy

Nhóm em xác định Top 10 sản phẩm theo số lượng bán và theo doanh thu:

```
top_sl = retail.groupby('Description')['Quantity'].sum().nlargest(10)
top_dt = retail.groupby('Description')['TotalPrice'].sum().nlargest(10)

fig, axes = plt.subplots(1, 2, figsize=(20, 6))
sns.barplot(x=top_sl.values, y=top_sl.index, palette='viridis', ax=axes[0])
axes[0].set_title('Top 10 sản phẩm theo số lượng bán', fontsize=13)
axes[0].set_xlabel('Số lượng'); axes[0].set_ylabel('')
sns.barplot(x=top_dt.values, y=top_dt.index, palette='magma', ax=axes[1])
axes[1].set_title('Top 10 sản phẩm theo doanh thu', fontsize=13)
axes[1].set_xlabel('Doanh thu (£)'); axes[1].set_ylabel('')
plt.tight_layout()
plt.show()
```

Kết quả thực thi:



Hình 3.20. Top 10 sản phẩm theo số lượng bán và theo doanh thu

Nhận xét:

Sản phẩm bán nhiều chưa chắc mang lại nhiều doanh thu (giá thấp). Nhờ loại các đơn đặt – hủy, bảng xếp hạng không còn bị sai lệch bởi đơn 80.995 sản phẩm PAPER CRAFT, LITTLE BIRDIE.

3.4.12. Bước 10: Phân tích khách hàng – tần suất mua & nguyên lý Pareto

Cuối cùng, nhóm em tổng hợp dữ liệu theo khách hàng để phân tích tần suất mua và kiểm tra nguyên lý Pareto:

```
kh = retail.groupby('CustomerID').agg(SoHoaDon=('InvoiceNo', 'nunique'),
DoanhThu=('TotalPrice', 'sum'))
display(kh.describe().T.round(2))

# Tỷ trọng doanh thu của 20% khách hàng chi tiêu nhiều nhất
kh_sorted = kh['DoanhThu'].sort_values(ascending=False)
top20 = kh_sorted.head(int(len(kh_sorted) * 0.2)).sum() / kh_sorted.sum() * 100
mua_1_lan = (kh['SoHoaDon'] == 1).mean() * 100
print(f"20% khách hàng chi tiêu nhiều nhất đóng góp {top20:.1f}% tổng doanh thu")
print(f"Tỷ lệ khách hàng chỉ mua 1 lần: {mua_1_lan:.1f}%")

fig, axes = plt.subplots(1, 2, figsize=(16, 5))
so_hd = kh['SoHoaDon'].clip(upper=20)
sns.histplot(so_hd, bins=20, discrete=True, color='seagreen', ax=axes[0])
axes[0].set_title('Phân phối số hóa đơn mỗi khách hàng (>=20 gộp vào cột 20)',
```

```
fontsize=12)
axes[0].set_xlabel('Số hóa đơn')

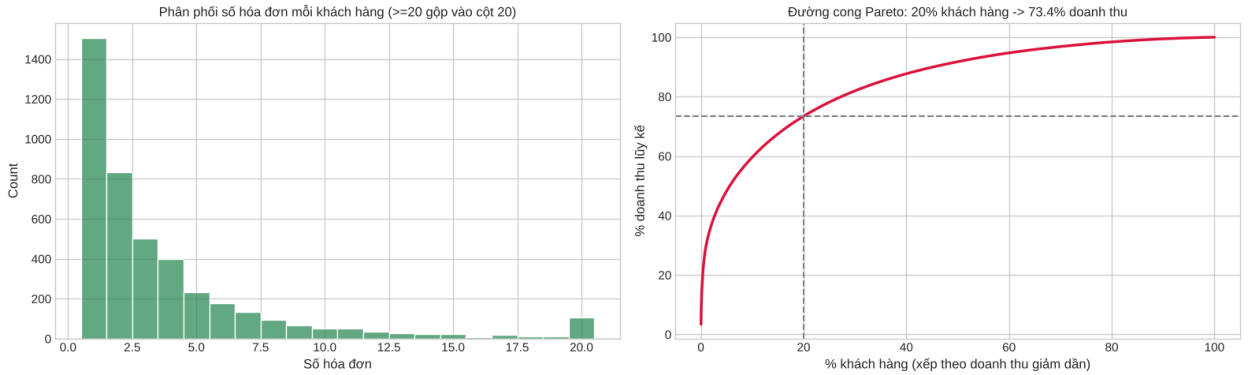
luy_ke = kh_sorted.cumsum() / kh_sorted.sum() * 100
axes[1].plot(np.arange(1, len(luy_ke) + 1) / len(luy_ke) * 100, luy_ke.values,
color='crimson', linewidth=2.5)
axes[1].axvline(20, color='gray', linestyle='--')
axes[1].axhline(top20, color='gray', linestyle='--')
axes[1].set_title(f'Đường cong Pareto: 20% khách hàng -> {top20:.1f}% doanh thu',
fontsize=12)
axes[1].set_xlabel('% khách hàng (xếp theo doanh thu giảm dần)')
axes[1].set_ylabel('% doanh thu lũy kế')
plt.tight_layout()
plt.show()
```

Kết quả thực thi:

	count	mean	std	min	25%	50%	75%	max
SoHoaDon	4321.0	4.20	7.51	1.0	1.00	2.00	5.0	202.00
DoanhThu	4321.0	1897.58	8190.55	2.9	301.29	653.75	1608.1	277460.42

Bảng 3.7. Thống kê mô tả số hóa đơn và doanh thu theo khách hàng

```
20% khách hàng chi tiêu nhiều nhất đóng góp 73.4% tổng doanh thu
Tỷ lệ khách hàng chỉ mua 1 lần: 34.9%
```



Hình 3.21. Phân phối số hóa đơn mỗi khách hàng và đường cong Pareto doanh thu

Nhận xét:

Doanh thu tập trung cao vào nhóm khách hàng lớn, gần đúng quy luật 80/20 → nên ưu tiên chăm sóc nhóm khách hàng giá trị cao và có chiến lược kích thích mua lại cho nhóm mua 1 lần (có thể phân khúc tiếp bằng RFM).

3.5. Tổng kết kết quả phân tích khám phá dữ liệu

1. **Bài tập 1.2.2 – Trực quan hóa rượu đỏ:** 7 nhóm biểu đồ (bar, histogram, boxplot, heatmap, scatter, line) làm rõ phân phối, ngoại lai, đa cộng tuyến và xu hướng các đặc trưng theo chất lượng.
2. **Bài tập 1.2.3 – Tiểu đường:** Glucose, BMI, Age phân tách rõ hai nhóm; tỷ lệ mắc bệnh tăng theo tuổi (21,6% → 57,4%) và theo BMI (6,5% → 45,6%).
3. **Bài tập 1.2.3 – Online Retail:** Làm sạch 541.909 → 385.929 dòng; UK chiếm 82,2% doanh thu; doanh thu đạt đỉnh tháng 11/2011; không có giao dịch Thứ 7; 20% khách hàng tạo ra 73,4% doanh thu.

Nhận xét :

Mục đích: Tổng hợp các kết quả chính sau khi thực hiện 4 bài tập thực hành của Lab Phân tích khám phá dữ liệu.

Tác dụng: Vận dụng đầy đủ quy trình EDA: nạp dữ liệu → kiểm tra chất lượng (khuyết thiếu, trùng lặp, ngoại lai, giá trị bất hợp lý) → thống kê mô tả → trực quan hóa đơn biến, hai biến, đa biến → rút ra nhận định.

Đánh giá: Các tập dữ liệu đã được làm sạch và hiểu rõ đặc điểm, xác định được các đặc trưng quan trọng của từng bài toán, làm nền tảng cho bước xây dựng mô hình khai thác dữ liệu tiếp theo.

Chương 4. PHÂN TÍCH ĐƠN BIẾN VÀ HAI BIẾN

4.1. Cơ sở lý thuyết về phân tích đơn biến và hai biến

4.1.1. Phân tích đơn biến là gì và khác gì với phân tích hai biến?

Phân tích đơn biến (Univariate Analysis) là phân tích từng biến một cách độc lập nhằm mô tả đặc điểm của chính biến đó: giá trị trung tâm, độ phân tán, hình dạng phân phối, giá trị thiếu và ngoại lai. Đây là dạng phân tích đơn giản nhất, không xét đến quan hệ giữa các biến.

Tiêu chí	Phân tích đơn biến	Phân tích hai biến
Số biến	1 biến	2 biến
Câu hỏi trả lời	Biến này phân phối như thế nào?	Hai biến có liên quan với nhau không?
Thước đo	Mean, median, mode, std, IQR, skewness, tần số	Covariance, hệ số tương quan, bảng chéo, chi-square
Biểu đồ	Histogram, boxplot, violin, bar chart, pie chart	Scatter plot, heatmap, boxplot theo nhóm, stacked bar
Ví dụ	Phân phối Income của khách hàng	Income khác nhau thế nào giữa Response = 0 và 1

Bảng 4.1. So sánh phân tích đơn biến và phân tích hai biến

4.1.2. Các thước đo thống kê thường dùng trong phân tích đơn biến

Tùy vào kiểu dữ liệu mà các thước đo được sử dụng khác nhau:

Với biến số: các thước đo xu hướng trung tâm (trung bình, trung vị, yếu vị), các thước đo phân tán (min, max, range, phương sai, độ lệch chuẩn, IQR, hệ số biến thiên), các thước đo hình dạng (skewness, kurtosis) và các bách phân vị. Trong Pandas, hàm describe() cung cấp nhanh count, mean, std, min, Q1, median, Q3, max.

Với biến phân loại: tần số (value_counts), tần suất tương đối (tỷ lệ %), yếu vị (giá trị phổ biến nhất) và số lượng giá trị khác nhau (nunique).

Thông tin chất lượng dữ liệu: số giá trị thiếu, số giá trị bằng 0, số giá trị khác nhau, số ngoại lai – các công cụ EDA tự động như SweetViz cũng hiển thị đầy đủ các chỉ số này cho từng biến.

4.1.3. Xác định mối quan hệ giữa hai biến: tương quan và nhân quả

Cách xác định mối quan hệ phụ thuộc vào kiểu của hai biến:

Số – Số: vẽ scatter plot để quan sát hình dạng quan hệ; tính hệ số tương quan Pearson (quan hệ tuyến tính) hoặc Spearman/Kendall (quan hệ đơn điệu, dữ liệu có ngoại lai hoặc dạng thứ bậc).

Số – Phân loại: so sánh thống kê (mean, median) của biến số theo từng nhóm bằng groupby; trực quan hóa bằng boxplot, violin plot; kiểm định t-test (2 nhóm) hoặc ANOVA (nhiều nhóm).

Phân loại – Phân loại: lập bảng chéo (pd.crosstab) hoặc pivot_table, vẽ stacked bar chart hoặc heatmap; kiểm định Chi-square và hệ số Cramér's V.

Cần phân biệt rõ **tương quan (correlation)** và **nhân quả (causation)**. Tương quan chỉ cho biết hai biến có xu hướng biến đổi cùng nhau, nhưng không chứng minh biến này gây ra biến kia. Mối tương quan có thể đến từ một biến ẩn thứ ba (biến gây nhiễu – confounder) hoặc do ngẫu nhiên.

4.1.4. Sự khác biệt giữa tương quan (correlation) và hiệp biến (covariance)

Hiệp phương sai (covariance) đo mức độ biến thiên cùng nhau của hai biến:

$$Cov(X, Y) = \Sigma(x_i - \bar{x})(y_i - \bar{y}) / (n - 1)$$

Hệ số tương quan Pearson là hiệp phương sai đã được chuẩn hóa bởi độ lệch chuẩn của hai biến:

$$r = Cov(X, Y) / (s_X \cdot s_Y), \quad -1 \leq r \leq 1$$

Tiêu chí	Hiệp biến (Covariance)	Tương quan (Correlation)
Miền giá trị	Từ $-\infty$ đến $+\infty$	Từ -1 đến $+1$
Đơn vị	Bằng tích đơn vị của hai biến	Không có đơn vị
Thông tin cung cấp	Chỉ cho biết chiều của quan hệ (dấu + / −)	Cho biết cả chiều và độ mạnh của quan hệ
Ảnh hưởng của thang đo	Thay đổi khi đổi đơn vị (ví dụ $ sang nghìn $)	Không đổi khi đổi đơn vị
So sánh giữa các cặp biến	Không so sánh được	So sánh được
Hàm trong Pandas	df.cov()	df.corr()

Bảng 4.2. So sánh hiệp biến (covariance) và hệ số tương quan (correlation)

Thông thường $|r| \geq 0,7$ được xem là tương quan mạnh, 0,3 – 0,7 là trung bình và < 0,3 là yếu. Vì có thể so sánh được giữa các cặp biến, trong thực hành nhóm em sử dụng ma trận tương quan (heatmap) thay vì ma trận hiệp phương sai.

4.1.5. Khi nào nên sử dụng biểu đồ trong phân tích đơn biến so với hai biến?

Biểu đồ đơn biến được dùng ở giai đoạn đầu của EDA khi mục tiêu là hiểu từng biến: kiểm tra phân phối có lệch không, có ngoại lai không, giá trị nào phổ biến, có giá trị bất thường như đỉnh nhọn tại 0 không. Các biểu đồ thường dùng là histogram, KDE, boxplot, violin plot (biến số) và bar chart, countplot, pie chart (biến phân loại).

Biểu đồ hai biến được dùng khi đã hiểu từng biến và cần trả lời câu hỏi về mối quan hệ, đặc biệt là quan hệ giữa các đặc trưng với biến mục tiêu – bước quan trọng để chọn đặc trưng cho mô hình. Các biểu đồ thường dùng là scatter plot (số – số), boxplot/violin plot theo nhóm (số – phân loại), stacked bar hoặc heatmap của bảng chéo (phân loại – phân loại), heatmap tương quan và pairplot khi muốn xem nhiều cặp cùng lúc. Trong thực tế, hai loại biểu đồ này bổ sung cho nhau: phân tích đơn biến giúp chọn đúng cách xử lý dữ liệu, phân tích hai biến giúp tìm ra insight.

4.1.6. Code mẫu tạo scatter plot và heatmap để phân tích mối quan hệ giữa hai biến

Đoạn code minh họa dưới đây vẽ scatter plot giữa thu nhập và tổng chi tiêu, tô màu theo biến Response, và heatmap ma trận tương quan cho một nhóm biến số của dữ liệu Marketing Campaign:

Đoạn code minh họa:

```
import matplotlib.pyplot as plt
import seaborn as sns

# Scatter plot: quan hệ giữa Income và Total_Mnt
plt.figure(figsize=(10, 6))
sns.scatterplot(data=df_clean, x='Income', y='Total_Mnt', hue='Response',
alpha=0.6)
plt.title('Quan hệ giữa thu nhập và tổng chi tiêu')
plt.show()

# Heatmap: ma trận tương quan giữa các biến số
cols = ['Income', 'Age', 'Total_Mnt', 'Recency', 'Response']
```

```
plt.figure(figsize=(8, 6))
sns.heatmap(df_clean[cols].corr(), annot=True, fmt='.2f', cmap='coolwarm',
center=0)
plt.title('Ma trận tương quan')
plt.show()
```

4.1.7. Trực quan hóa quan hệ giữa biến số và biến phân loại bằng boxplot, violin plot

Để so sánh phân phối của một biến số giữa các nhóm của biến phân loại, đặt biến phân loại ở trục x và biến số ở trục y. Boxplot cho thấy trung vị, IQR và ngoại lai của từng nhóm; violin plot bổ sung thêm hình dạng mật độ phân phối (với inner='quartile' sẽ vẽ thêm các đường tứ phân vị bên trong):

Đoạn code minh họa:

```
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

# Boxplot: Income theo trình độ học vấn
sns.boxplot(data=df_clean, x='Education', y='Income', ax=axes[0])
axes[0].set_title('Boxplot: Income theo Education')

# Violin plot: Total_Mnt theo Response
sns.violinplot(data=df_clean, x='Response', y='Total_Mnt', inner='quartile',
ax=axes[1])
axes[1].set_title('Violin plot: Total_Mnt theo Response')

plt.tight_layout()
plt.show()
```

4.1.8. Các công cụ hỗ trợ EDA tự động

Bên cạnh việc tự viết code, hiện nay có nhiều thư viện giúp tự động hóa quá trình EDA. Chỉ với vài dòng lệnh, các công cụ này sinh ra báo cáo gồm thống kê đơn biến, ma trận tương quan, cảnh báo chất lượng dữ liệu. Tài liệu thực hành giới thiệu ydata-profiling và D-Tale trong bài làm mẫu; trong hai bài tập, nhóm em tìm hiểu thêm SweetViz và AutoViz.

Công cụ	Đầu ra	Điểm mạnh	Hạn chế
ydata-profiling	Báo cáo HTML	Rất chi tiết: cảnh báo, tương quan, missing, mẫu dữ liệu	Chậm với dữ liệu lớn
D-Tale	Giao diện web tương tác	Lọc, sắp xếp, chỉnh sửa dữ liệu dạng bảng, vẽ biểu đồ trực tiếp	Cần chạy server, khó đưa vào báo cáo tĩnh

Công cụ	Đầu ra	Điểm mạnh	Hạn chế
SweetViz	Báo cáo HTML dạng dashboard	Phân tích theo biến mục tiêu, so sánh 2 tập dữ liệu hoặc 2 nhóm	Ít tùy chỉnh biểu đồ
AutoViz	Biểu đồ Matplotlib/Seaborn inline (hoặc HTML)	Tự phân loại biến, tự sinh nhiều nhóm biểu đồ, báo cáo chất lượng dữ liệu	Nhiều biểu đồ, cần chọn lọc khi diễn giải

Bảng 4.3. So sánh một số công cụ EDA tự động trong Python

4.2. Bài tập thực hành 1 – Ứng dụng thư viện SweetViz

SweetViz là thư viện mã nguồn mở giúp tạo báo cáo EDA dạng HTML chỉ với vài dòng lệnh. Điểm nổi bật của SweetViz là khả năng phân tích theo biến mục tiêu (target analysis) và so sánh hai tập dữ liệu. Trong bài tập này, nhóm em áp dụng SweetViz trên dữ liệu Marketing Campaign với ba chức năng chính: sv.analyze(), sv.compare_intra() và sv.compare().

Mục tiêu:

1. Khám phá các tính năng tự động EDA của thư viện SweetViz.
2. Cài đặt môi trường execution thích hợp trên Kaggle Notebook.

4.2.1. Khởi tạo môi trường & khám phá thư viện SweetViz

1. Cài đặt và Import

Nhóm em cài đặt thư viện SweetViz trên Kaggle Notebook và nạp các thư viện cần thiết:

```
!pip install sweetviz -q

import pandas as pd
import numpy as np
import sweetviz as sv
from sklearn.model_selection import train_test_split
import warnings
warnings.filterwarnings('ignore')

print(f"--> Đã cài đặt thành công Sweetviz phiên bản: {sv.__version__}")
```

Kết quả thực thi:

```
--> Đã cài đặt thành công Sweetviz phiên bản: 2.3.3
```

Nhận xét:

Thư viện SweetViz là một công cụ Automated EDA mã nguồn mở bằng Python, tạo ra các báo cáo đồ họa tương tác cao dưới dạng file HTML.

SweetViz có tốc độ render nhanh và hỗ trợ phân tích biến mục tiêu (Target Analysis) vượt trội hơn so với các thư viện truyền thống.

4.2.2. Nạp dữ liệu & mở rộng tạo đặc trưng mới

Mục tiêu: nạp dữ liệu , xử lý giá trị thiếu (Missing Values) và tạo ra các đặc trưng có ý nghĩa kinh doanh (Age,Total_Mnt, Is_Parent) để SweetViz phân tích sâu hơn.

1. Đường dẫn dữ liệu chuẩn

Dữ liệu marketing_campaign.csv sử dụng ký tự tab làm dấu phân tách; nhóm em dùng khối try – except để đọc được file ở cả hai đường dẫn:

```
file_path = "/kaggle/input/customer-personality-analysis/marketing_campaign.csv"

try:
    df_raw = pd.read_csv(file_path, sep='\t')
except FileNotFoundError:
    df_raw =
pd.read_csv("/kaggle/input/datasets/ngochancao/mmmmmmmm/marketing_campaign
(1).csv", sep='\t')

df = df_raw.copy()
```

2. Điền giá trị khuyết cho cột Income bằng trung vị (Median)

Cột Income có giá trị thiếu nên được điền bằng trung vị:

```
df['Income'] = df['Income'].fillna(df['Income'].median())
```

3. Tạo các đặc trưng mở rộng (Feature Engineering)

Nhóm em tạo thêm các đặc trưng có ý nghĩa kinh doanh từ các cột gốc:

```
CURRENT_YEAR = 2024
df['Age'] = CURRENT_YEAR - df['Year_Birth']
df['Total_Mnt'] = df[['MntWines', 'MntFruits', 'MntMeatProducts',
'MntFishProducts', 'MntSweetProducts', 'MntGoldProds']].sum(axis=1)
df['Total_Children'] = df['Kidhome'] + df['Teenhome']
df['Is_Parent'] = (df['Total_Children'] > 0).astype(int)
df['Total_Purchases'] = df[['NumWebPurchases', 'NumCatalogPurchases',
'NumStorePurchases']].sum(axis=1)
```

4. Lọc bỏ Outliers phi lý

Cuối cùng, các bản ghi có tuổi hoặc thu nhập phi lý được lọc bỏ:

```
df_clean = df[(df['Age'] < 100) & (df['Income'] < 200000)].copy()

print(f"Kích thước dữ liệu ban đầu: {df_raw.shape}")
print(f"Kích thước dữ liệu sau khi xử lý: {df_clean.shape}")
df_clean[['Age', 'Income', 'Total_Mnt', 'Is_Parent', 'Response']].head()
```

Kết quả thực thi:

```
Kích thước dữ liệu ban đầu: (2240, 29)
Kích thước dữ liệu sau khi xử lý: (2236, 34)
```

	Age	Income	Total_Mnt	Is_Parent	Response
0	67	58138.0	1617	0	1
1	70	46344.0	27	1	0
2	59	71613.0	776	0	0
3	40	26646.0	53	1	0
4	43	58293.0	422	1	0

Bảng 4.4. Năm dòng đầu của các đặc trưng chính sau tiền xử lý

Nhận xét:

Xử lý khuyết thiếu: cột Income ban đầu có 24 giá trị thiếu (~1.07%), đã được điền bằng giá trị trung vị (Median) để giữ nguyên kích thước tập dữ liệu mà không làm lệch phân bố.
Biến mở rộng mới:

Age: thay thế cho Year_Birth giúp trực quan hóa phân bố độ tuổi trực quan hơn.
Total_Mnt: tổng chi tiêu của khách hàng qua 6 nhóm mặt hàng, làm thước đo giá trị khách hàng.
Is_Parent: biến phân loại cờ (1: Có con, 0: Chưa có con) dùng cho bài toán phân khúc.

Làm sạch Outliers: bỏ các bản ghi có độ tuổi > 100 hoặc thu nhập dị biệt > 200,000$ giúp ma trận tương quan không bị méo mó.

4.2.3. Phân tích đơn biến & hai biến tương quan với biến mục tiêu (Response)

Mục tiêu: cấu hình ép kiểu dữ liệu bằng sv.FeatureConfig và tiến hành phân tích mối quan hệ giữa tất cả các thuộc tính với biến mục tiêu Response (Chấp nhận chiến dịch tiếp thị).

1. Cấu hình danh sách biến để Sweetviz xử lý chính xác

SweetViz cho phép cấu hình bỏ qua các cột không mang thông tin và ép một số cột số về kiểu phân loại thông qua sv.FeatureConfig:

```
feature_config = sv.FeatureConfig(
    skip=['ID', 'Z_CostContact', 'Z_Revenue'],
    force_cat=['Education', 'Marital_Status', 'Kidhome', 'Teenhome', 'Is_Parent',
               'AcceptedCmp1', 'AcceptedCmp2', 'AcceptedCmp3', 'AcceptedCmp4',
'AcceptedCmp5', 'Complain']
)
```

2. Chạy báo cáo Sweetviz Analyze

Nhóm em chạy hàm sv.analyze() với biến mục tiêu Response:

```
report_analyze = sv.analyze(
    source=df_clean,
    target_feat='Response',
    feat_cfg=feature_config
)
```

Kết quả thực thi:

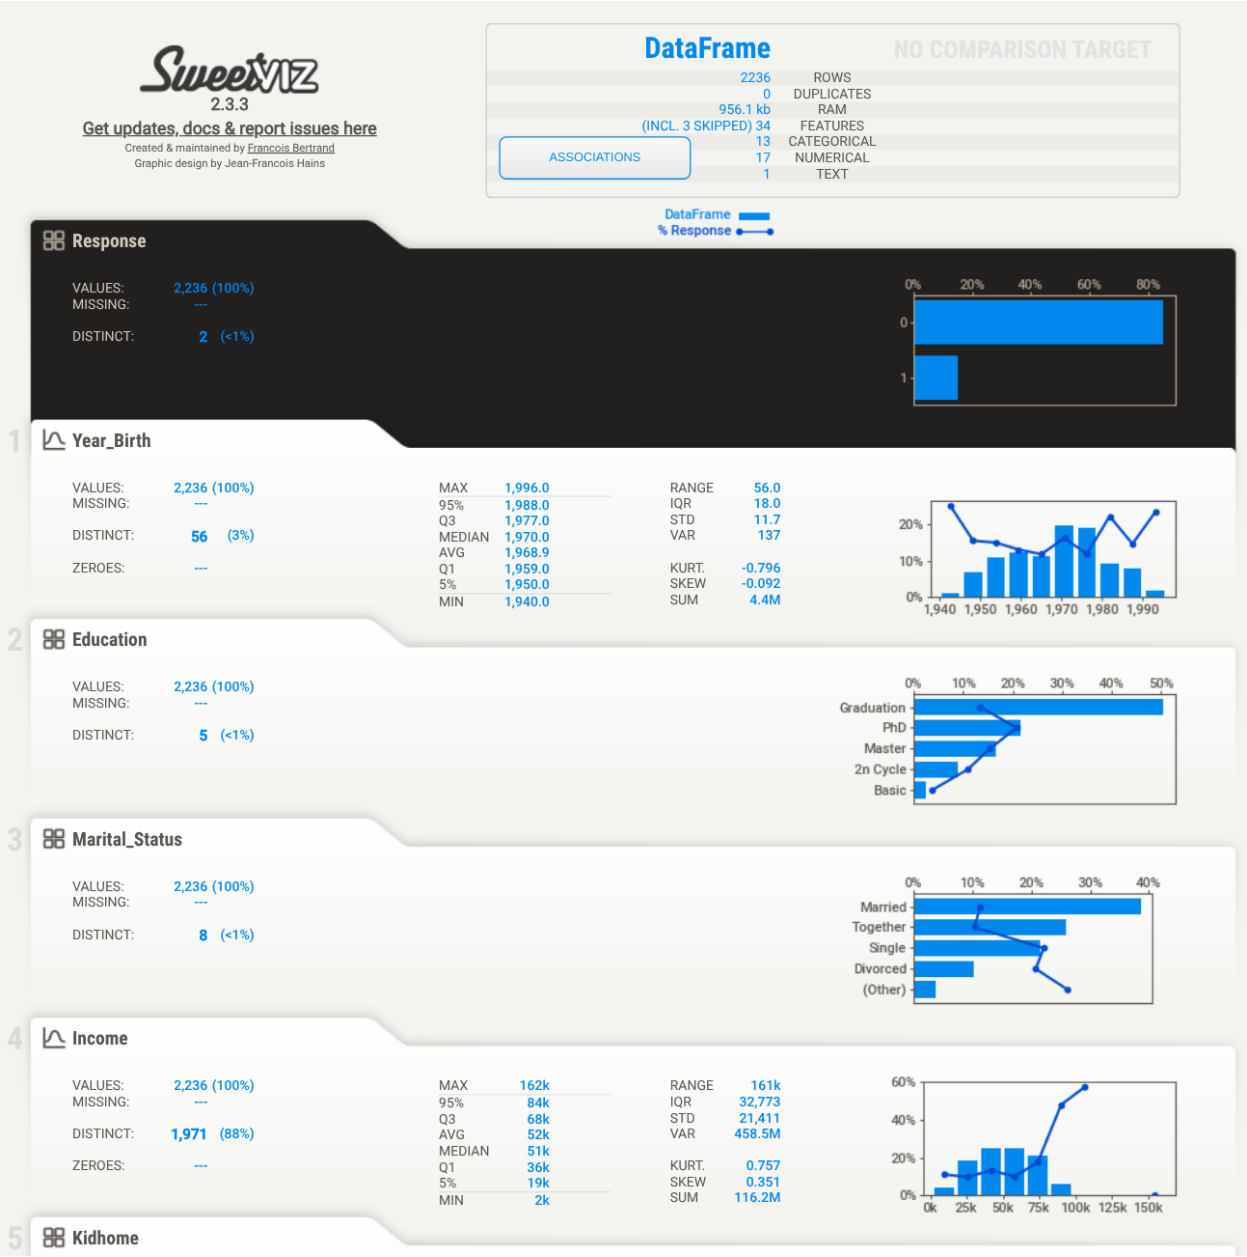
```
                                             |          | [  0%]   00:00 -> (? left)
```

3. Hiển thị tương tác

Báo cáo được hiển thị trực tiếp trong notebook bằng show_notebook():

```
report_analyze.show_notebook(w="100%", h="750px", scale=0.85)
```

Kết quả thực thi:



Hình 4.1. Báo cáo SweetViz sv.analyze() với biến mục tiêu Response

Nhận xét & Insight:

1. Phân tích đơn biến (Univariate Insights):

Mức Thu nhập (Income): phân bố lệch phải nhẹ (Right-skewed), trung bình đạt ~52,200$.

Mức Chi tiêu (Total_Mnt): sản phẩm rượu (MntWines) và thịt (MntMeatProducts) đóng góp tỷ trọng lớn nhất vào tổng doanh thu từ khách hàng.

2. Phân tích hai biến tương quan với Target (Response):

Yếu tố Kinh tế: khách hàng chấp nhận chiến dịch (Response = 1) có thu nhập trung bình ~69,000$ cao vượt trội so với nhóm từ chối (~50,000$).

Mức độ trung thành/Chi tiêu: biến Total_Mnt và MntWines có mối tương quan thuận mạnh nhất với Response.

Kênh bán hàng: nhóm khách hàng đặt mua qua Catalog (NumCatalogPurchases) có tỷ lệ phản hồi chiến dịch cao hơn nhiều so với nhóm mua trực tiếp tại cửa hàng.

4.2.4. Mở rộng 1 – So sánh phân khúc khách hàng

Mục tiêu: sử dụng tính năng nâng cao compare_intra để so sánh hành vi chi tiêu (Total_Mnt) giữa nhóm khách hàng có con (Is_Parent = 1) và chưa có con (Is_Parent = 0).

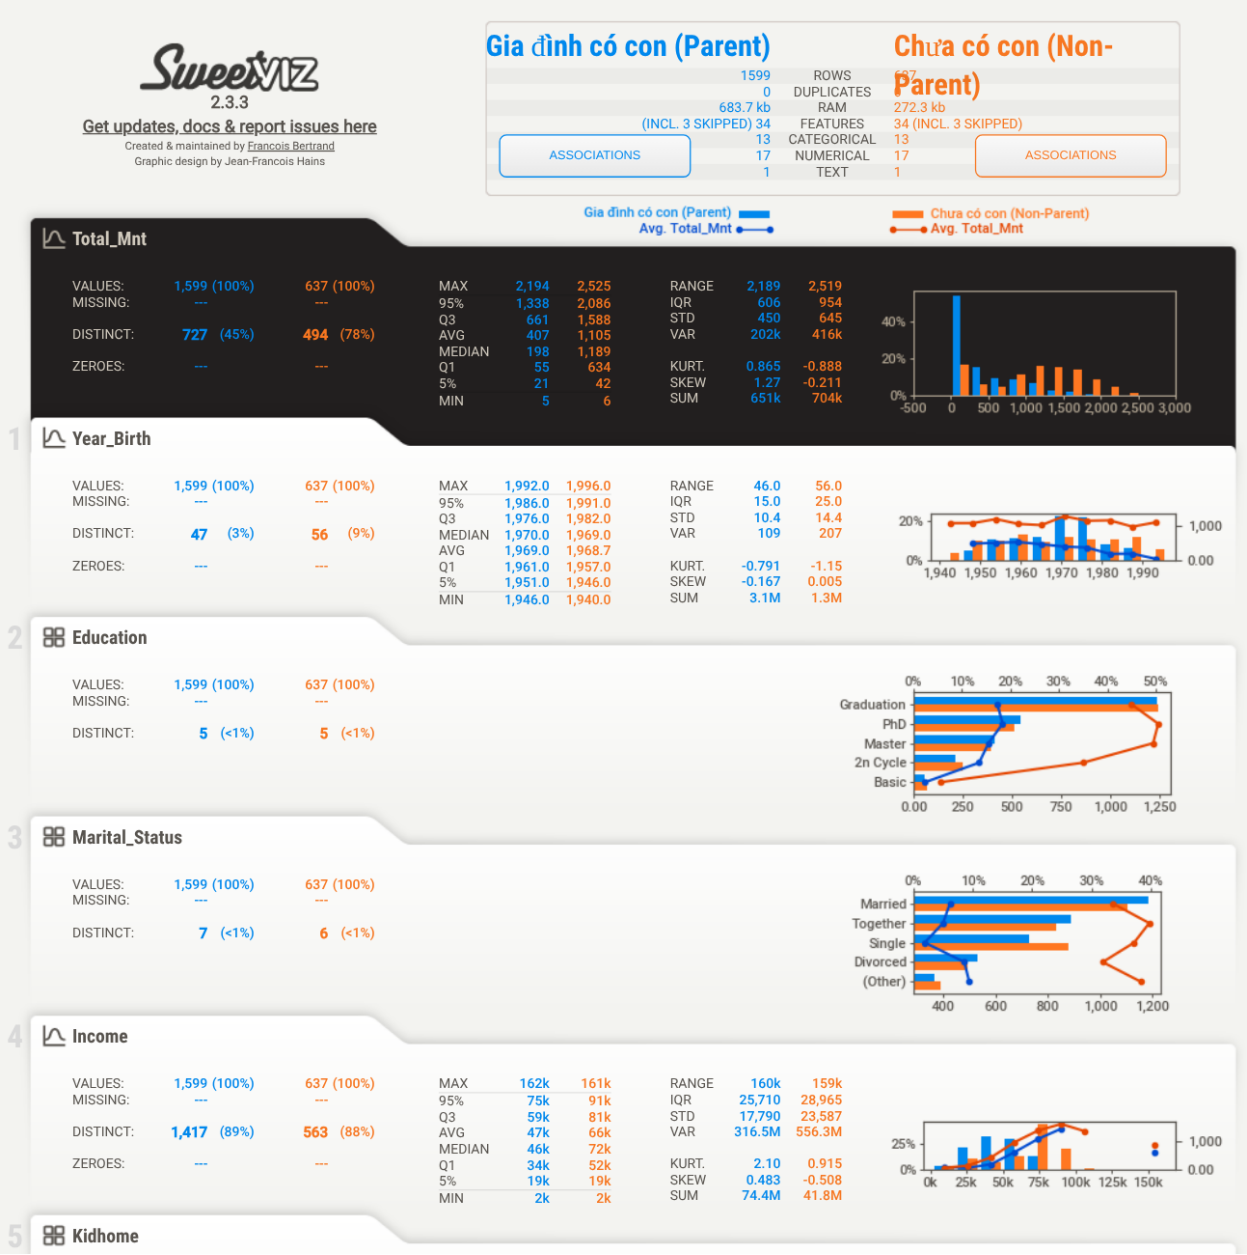
Hàm sv.compare_intra() so sánh hai nhóm con trong cùng một tập dữ liệu theo một điều kiện, ở đây là Is_Parent == 1, với biến mục tiêu là Total_Mnt:

```
# So sánh nội bộ tập dữ liệu dựa trên điều kiện Is_Parent == 1
report_intra = sv.compare_intra(
    source_df=df_clean,
    condition_series=(df_clean['Is_Parent'] == 1),
    names=["Gia đình có con (Parent)", "Chưa có con (Non-Parent)"],
    target_feat='Total_Mnt',
    feat_cfg=feature_config
)

report_intra.show_notebook(w="100%", h="750px", scale=0.85)
```

Kết quả thực thi:

```
                                          |          | [  0%]   00:00 -> (? left)
```



Hình 4.2. Báo cáo SweetViz compare_intra() so sánh nhóm có con và chưa có con

Nhận xét so sánh phân khúc & chiến lược kinh doanh:

Khác biệt chi tiêu: khách hàng chưa có con (Non-Parent) có sức mua trung bình (Total_Mnt) cao gấp hơn 3 lần so với nhóm có con (Parent) (~950$ so với ~280$).

Hành vi mua sắm: nhóm có con ghé thăm trang web thường xuyên hơn (NumWebVisitsMonth cao hơn) nhưng giá trị giỏ hàng mỗi lần mua lại thấp hơn.

Đề xuất hành động (Business Action):

Nhóm Non-Parent: định hướng phân khúc VIP, đẩy mạnh Marketing các mặt hàng Rượu/Thịt cao cấp qua kênh Email/Catalog.

Nhóm Parent: thiết kế các gói Combo gia đình tiết kiệm và chạy chương trình khuyến mãi giảm giá trực tiếp trên Website.

4.2.5. Mở rộng 2 – Đánh giá Data Drift giữa tập Train và Test (sv.compare)

Mục tiêu: chia tập dữ liệu thành Train (75%) và Test (25%), sau đó dùng sv.compare để kiểm tra tính đồng nhất phân bố trước khi đưa vào mô hình Machine Learning.

Nhóm em chia dữ liệu theo phương pháp phân tầng (stratify) trên Response, sau đó dùng sv.compare() để so sánh phân phối giữa hai tập:

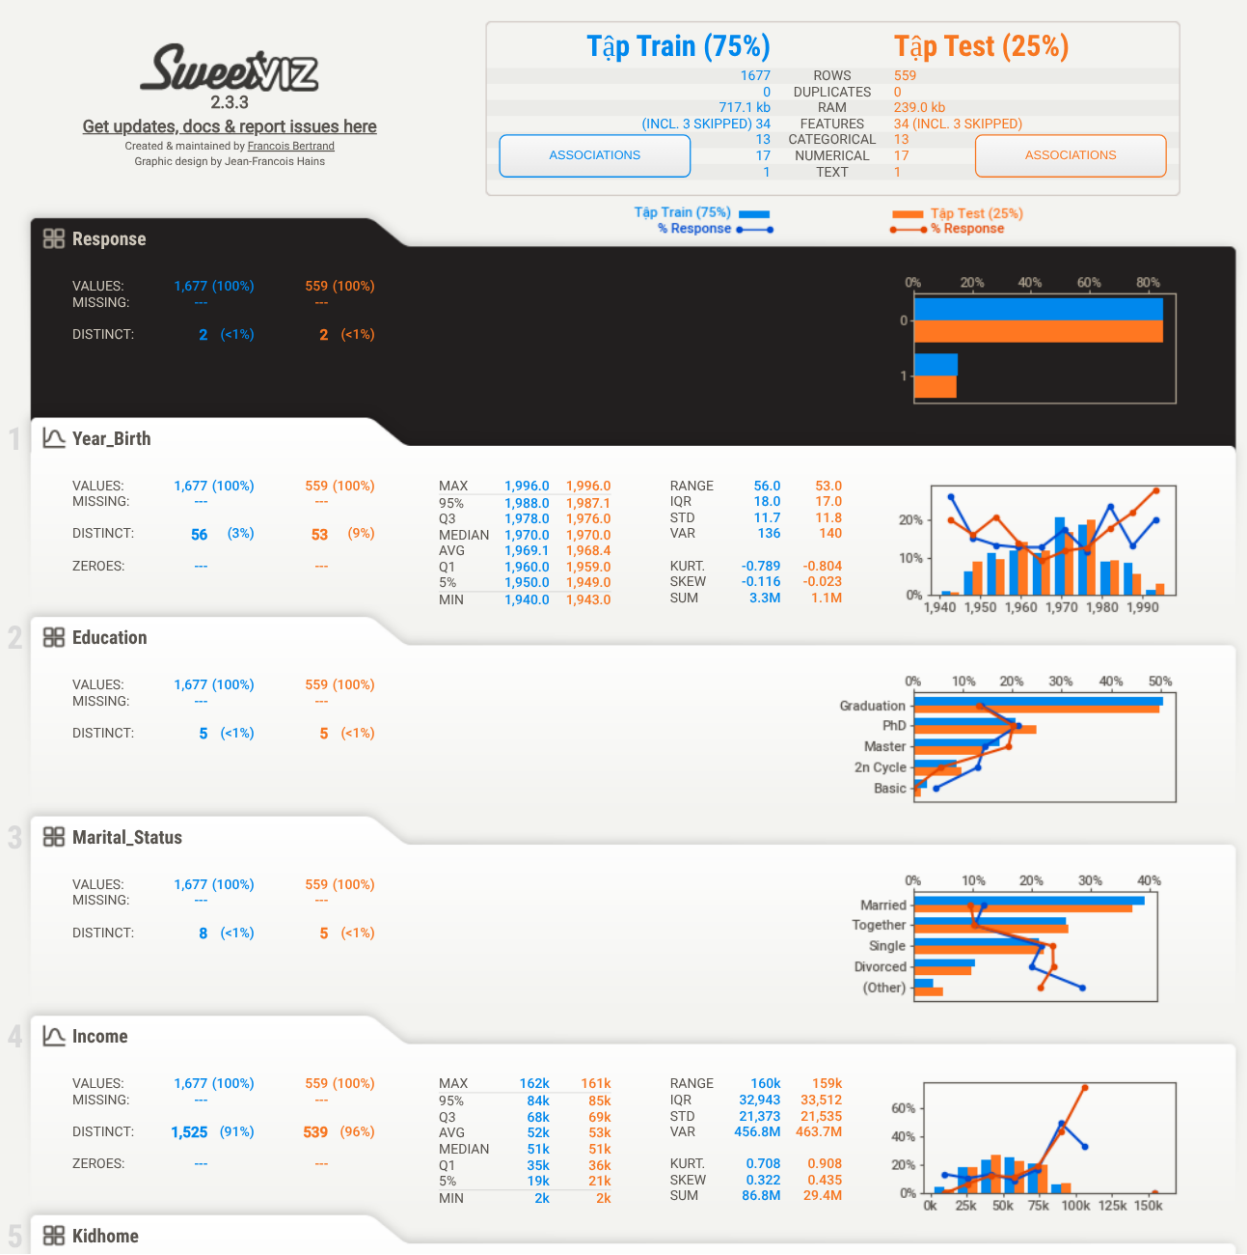
```
# Chia tập Train/Test theo phương pháp Stratified trên biến Response
train_df, test_df = train_test_split(df_clean, test_size=0.25, random_state=42,
stratify=df_clean['Response'])

report_drift = sv.compare(
    [train_df, "Tập Train (75%)"],
    [test_df, "Tập Test (25%)"],
    target_feat='Response',
    feat_cfg=feature_config
)

report_drift.show_notebook(w="100%", h="750px", scale=0.85)
```

Kết quả thực thi:

```
                                                |          | [  0%]   00:00 -> (? left)
```



Hình 4.3. Báo cáo SweetViz compare() giữa tập Train (75%) và tập Test (25%)

Nhận xét đánh giá tính nhất quán dữ liệu:

Phân bố tương đồng: các biểu đồ mật độ của tất cả đặc trưng chính (Income, Age, Total_Mnt, Education) ở tập Train và Test trùng khít lên nhau.

Cân bằng Target: tỷ lệ tích cực Response = 1 ở cả 2 tập giữ nguyên ở mức ~15%, đảm bảo không xảy ra hiện tượng méo mó mẫu (Sample Bias).

Kết luận: tập dữ liệu đạt chuẩn chất lượng cao, hoàn toàn sẵn sàng cho giai đoạn xây dựng mô hình dự đoán (Predictive Modeling).

4.2.6. Tổng kết Bài tập thực hành 1 (SweetViz)

1. Ưu điểm vượt trội của SweetViz:

   Đồ họa hiện đại, trực quan, dễ theo dõi.

   Hỗ trợ tính năng Target Analysis giúp phát hiện ngay các biến quan trọng nhất ảnh hưởng đến biến mục tiêu.

   Khả năng Compare Intra-groups và Compare Train/Test là tính năng độc đáo mà ít thư viện EDA tự động nào khác sở hữu.

2. So sánh với các công cụ trong bài làm mẫu (1.3.2):

   So với ydata-profiling (Pandas Profiling): SweetViz trình bày trực quan hơn khi so sánh giữa 2 nhóm dữ liệu.

   So với D-Tale: SweetViz tạo báo cáo tĩnh dạng trang Dashboard nhanh gọn, trong khi D-Tale phù hợp hơn cho việc chỉnh sửa dữ liệu tương tác dạng bảng.

4.3. Bài tập thực hành 2 – Ứng dụng thư viện AutoViz

AutoViz (Automatic Visualization) là thư viện tự động trực quan hóa dữ liệu: chỉ với một lệnh AV.AutoViz(), thư viện tự nhận diện kiểu dữ liệu của từng biến, đánh giá chất lượng dữ liệu và sinh ra hàng loạt biểu đồ đơn biến, hai biến. Bài tập này áp dụng AutoViz trên cùng tập dữ liệu Marketing Campaign để có thể đối chiếu với kết quả của SweetViz.

Mục tiêu:

1. Khám phá cơ chế tự động hóa phân tích biểu đồ (Automated Charting) của thư viện autoViz.
2. Tự động phân loại biến và sinh các nhóm biểu đồ đơn biến, hai biến, phân bố và ma trận tương quan.
3. Phân tích tác động của các yếu tố nhân khẩu học và chi tiêu tới biến mục tiêu (Response).

4.3.1. Khởi tạo môi trường & khám phá thư viện AutoViz

1. Cài đặt và Import

Nhóm em cài đặt AutoViz và khởi tạo đối tượng AutoViz_Class:

```
!pip install autoviz -q

import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from autoviz.AutoViz_Class import AutoViz_Class
import warnings
warnings.filterwarnings('ignore')

# Khởi tạo đối tượng AutoViz
AV = AutoViz_Class()
print("--> Đã khởi tạo thành công AutoViz_Class!")
```

Kết quả thực thi:

```
--> Đã khởi tạo thành công AutoViz_Class!
```

Nhận xét:

AutoViz (Automated Visualization) là thư viện tự động hóa trực quan hóa dữ liệu cực kỳ mạnh mẽ. Chỉ với một dòng lệnh AV.AutoViz(), AutoViz tự động phân loại các biến thành: Biến liên tục (Continuous), Biến phân loại (Categorical), Biến thời gian (DateTime), và Biến nhiễu (Boolean/Constant).

Khác với SweetViz (sinh file HTML dạng dashboard tổng hợp), AutoViz trực tiếp sinh ra từng nhóm biểu đồ Matplotlib/Seaborn trực quan ngay trong cell của Notebook.

4.3.2. Nạp dữ liệu & tiền xử lý / tạo đặc trưng mở rộng

Mục tiêu: nạp dữ liệu, làm sạch giá trị khuyết và khởi tạo các biến tổng hợp (Age, Total_Mnt, Is_Parent, Total_Purchases) để AutoViz tự động phân tích sâu hơn.

1. Đường dẫn dữ liệu chuẩn

Dữ liệu được nạp tương tự Bài tập thực hành 1:

```
file_path = "/kaggle/input/customer-personality-analysis/marketing_campaign.csv"

try:
    df_raw = pd.read_csv(file_path, sep='\t')
except FileNotFoundError:
    df_raw =
pd.read_csv("/kaggle/input/datasets/ngochancao/mmmmmmmm/marketing_campaign
(1).csv", sep='\t')
```

```
df = df_raw.copy()
```

2. Điền giá trị khuyết cho cột Income bằng giá trị Trung vị (Median)

Cột Income được điền khuyết bằng trung vị:

```
df['Income'] = df['Income'].fillna(df['Income'].median())
```

3. Mở rộng tạo các đặc trưng mới

Nhóm em tạo các đặc trưng mở rộng giống Bài tập thực hành 1:

```
CURRENT_YEAR = 2024
df['Age'] = CURRENT_YEAR - df['Year_Birth']
df['Total_Mnt'] = df[['MntWines', 'MntFruits', 'MntMeatProducts',
'MntFishProducts', 'MntSweetProducts', 'MntGoldProds']].sum(axis=1)
df['Total_Children'] = df['Kidhome'] + df['Teenhome']
df['Is_Parent'] = (df['Total_Children'] > 0).astype(int)
df['Total_Purchases'] = df[['NumWebPurchases', 'NumCatalogPurchases',
'NumStorePurchases']].sum(axis=1)
```

4. Lọc bỏ Outliers cực đoan không hợp lý

Các bản ghi có tuổi ≥ 100 hoặc thu nhập ≥ 200.000 được loại bỏ:

```
df_clean = df[(df['Age'] < 100) & (df['Income'] < 200000)].copy()
```

5. Loại bỏ các cột ID hoặc cột giá trị cố định không mang thông tin

Ngoài ra, nhóm em loại các cột ID, cột hằng số và cột Year_Birth (đã được thay bằng Age):

```
cols_to_drop = ['ID', 'Z_CostContact', 'Z_Revenue', 'Year_Birth']
df_clean = df_clean.drop(columns=[col for col in cols_to_drop if col in
df_clean.columns])

print(f"Kích thước dữ liệu gốc: {df_raw.shape}")
print(f"Kích thước dữ liệu sau khi làm sạch & bổ sung đặc trưng: {df_clean.shape}")
df_clean.head(3)
```

Kết quả thực thi:

```
Kích thước dữ liệu gốc: (2240, 29)
Kích thước dữ liệu sau khi làm sạch & bổ sung đặc trưng: (2236, 30)
```

	Education	Marital_Status	Income	Kidhome	Teenhome	Dt_Customer	Recency	MntWines	MntFruits
0	Graduation	Single	58138.0	0	0	04-09-2012	58	635	88
1	Graduation	Single	46344.0	1	1	08-03-2014	38	11	1

	Education	Marital_Status	Income	Kidhome	Teenhome	Dt_Customer	Recency	MntWines	MntFruits
2	Graduation	Together	71613.0	0	0	21-08-2013	26	426	49

Bảng 4.5. Ba dòng đầu của dữ liệu sau khi làm sạch và bổ sung đặc trưng (phần 1/5)

	MntMeatProducts	MntFishProducts	MntSweetProducts	MntGoldProds	NumDealsPurchases
0	546	172	88	88	3
1	6	2	1	6	2
2	127	111	21	42	1

Bảng 4.6. Ba dòng đầu của dữ liệu sau khi làm sạch và bổ sung đặc trưng (phần 2/5)

	NumWebPurchases	NumCatalogPurchases	NumStorePurchases	NumWebVisitsMonth	AcceptedCmp3
0	8	10	4	7	0
1	1	1	2	5	0
2	8	2	10	4	0

Bảng 4.7. Ba dòng đầu của dữ liệu sau khi làm sạch và bổ sung đặc trưng (phần 3/5)

	AcceptedCmp4	AcceptedCmp5	AcceptedCmp1	AcceptedCmp2	Complain	Response	Age	Total_Mnt
0	0	0	0	0	0	1	67	1617
1	0	0	0	0	0	0	70	27
2	0	0	0	0	0	0	59	776

Bảng 4.8. Ba dòng đầu của dữ liệu sau khi làm sạch và bổ sung đặc trưng (phần 4/5)

	Total_Children	Is_Parent	Total_Purchases
0	0	0	22
1	2	1	4
2	0	0	20

Bảng 4.9. Ba dòng đầu của dữ liệu sau khi làm sạch và bổ sung đặc trưng (phần 5/5)

Nhận xét:

Tiền xử lý: giá trị khuyết ở cột Income (24 bản ghi) được làm sạch bằng Median. Loại bỏ cột ID và cột cố định (Z_CostContact, Z_Revenue) giúp AutoViz không vẽ các biểu đồ nhiễu vô nghĩa.

Biến mở rộng: việc tạo Age và Total_Mnt giúp AutoViz dễ dàng nhận diện và vẽ các biểu đồ phân bố độ tuổi và tổng chi tiêu của khách hàng.

4.3.3. Thực thi AutoViz – tự động sinh hệ thống biểu đồ

Mục tiêu: cấu hình hàm AV.AutoViz() lấy Response (Phản hồi chiến dịch) làm biến mục tiêu phụ thuộc (depVar), tự động sinh ra toàn bộ hệ thống biểu đồ đơn biến và hai biến.

Gọi hàm AutoViz tự động phân tích và tạo biểu đồ

Hàm AV.AutoViz() được gọi với DataFrame đã làm sạch (dfte) và biến phụ thuộc depVar = 'Response'. Kết quả gồm phần phân loại biến, bảng báo cáo chất lượng dữ liệu và hệ thống biểu đồ:

```
%matplotlib inline

dft = AV.AutoViz(
    filename="",
    sep=",",
    depVar="Response",
    dfte=df_clean,
    header=0,
    verbose=1,
    lowess=False,
    chart_format="svg",
    max_rows_analyzed=150000,
    max_cols_analyzed=30
)
```

Kết quả thực thi:

```
Shape of your Data Set loaded: (2236, 30)
###############################################################################################
######################## C L A S S I F Y I N G  V A R I A B L E S  ##################
###############################################################################################
Classifying variables in data set...
    Number of Numeric Columns =  1
    Number of Integer-Categorical Columns =  18
    Number of String-Categorical Columns =  2
    Number of Factor-Categorical Columns =  0
    Number of String-Boolean Columns =  0
    Number of Numeric-Boolean Columns =  7
    Number of Discrete String Columns =  1
    Number of NLP String Columns =  0
    Number of Date Time Columns =  0
    Number of ID Columns =  0
    Number of Columns to Delete =  0
    29 Predictors classified...
        No variables removed since no ID or low-information variables found in data set

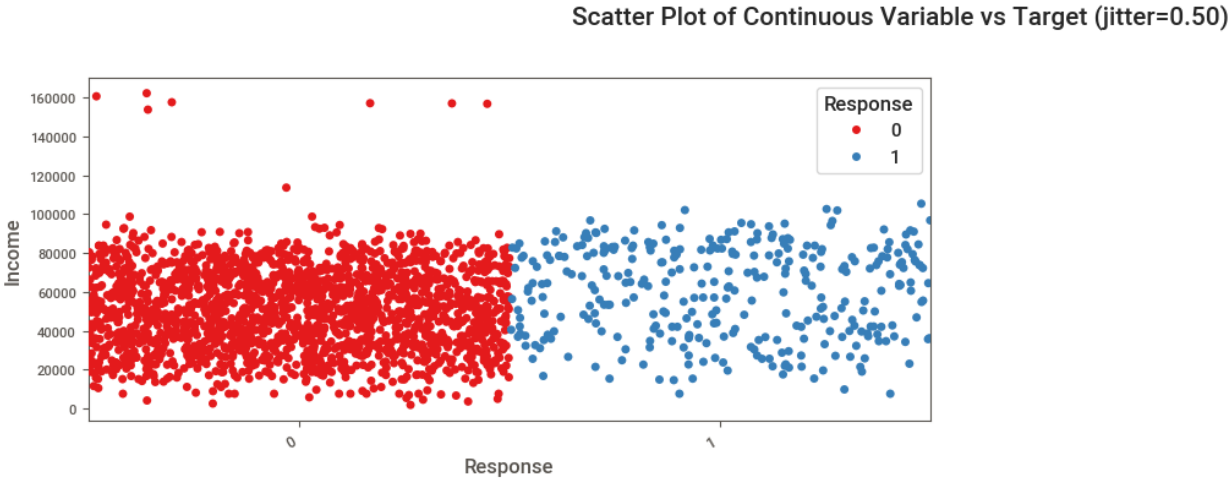
################ Binary_Classification problem ####################
To fix these data quality issues in the dataset, import FixDQ from autoviz...
There are 182 duplicate rows in your dataset
    Alert: Dropping duplicate rows can sometimes cause your column data types to change to object!
    All variables classified into correct types.
```

	Data Type	Missing Values%	Unique Values%	Minimum Value	Maximum Value	DQ Issue
Education	object	0.000000	0			No issue
Marital_Status	object	0.000000	0			3 rare categories: ['Alone', 'Absurd', 'YOLO']. Group them into a single category or drop the categories.
Income	float64	0.000000	NA	1730.000000	162397.000000	Column has 7 outliers greater than upper bound (116829.38) or lower than lower bound(-12991.62). Cap them or remove them.
Kidhome	int64	0.000000	0	0.000000	2.000000	No issue
Teenhome	int64	0.000000	0	0.000000	2.000000	No issue
Dt_Customer	object	0.000000	32			Possible high cardinality column with 663 unique values: Use hash encoding or text embedding to reduce dimension.

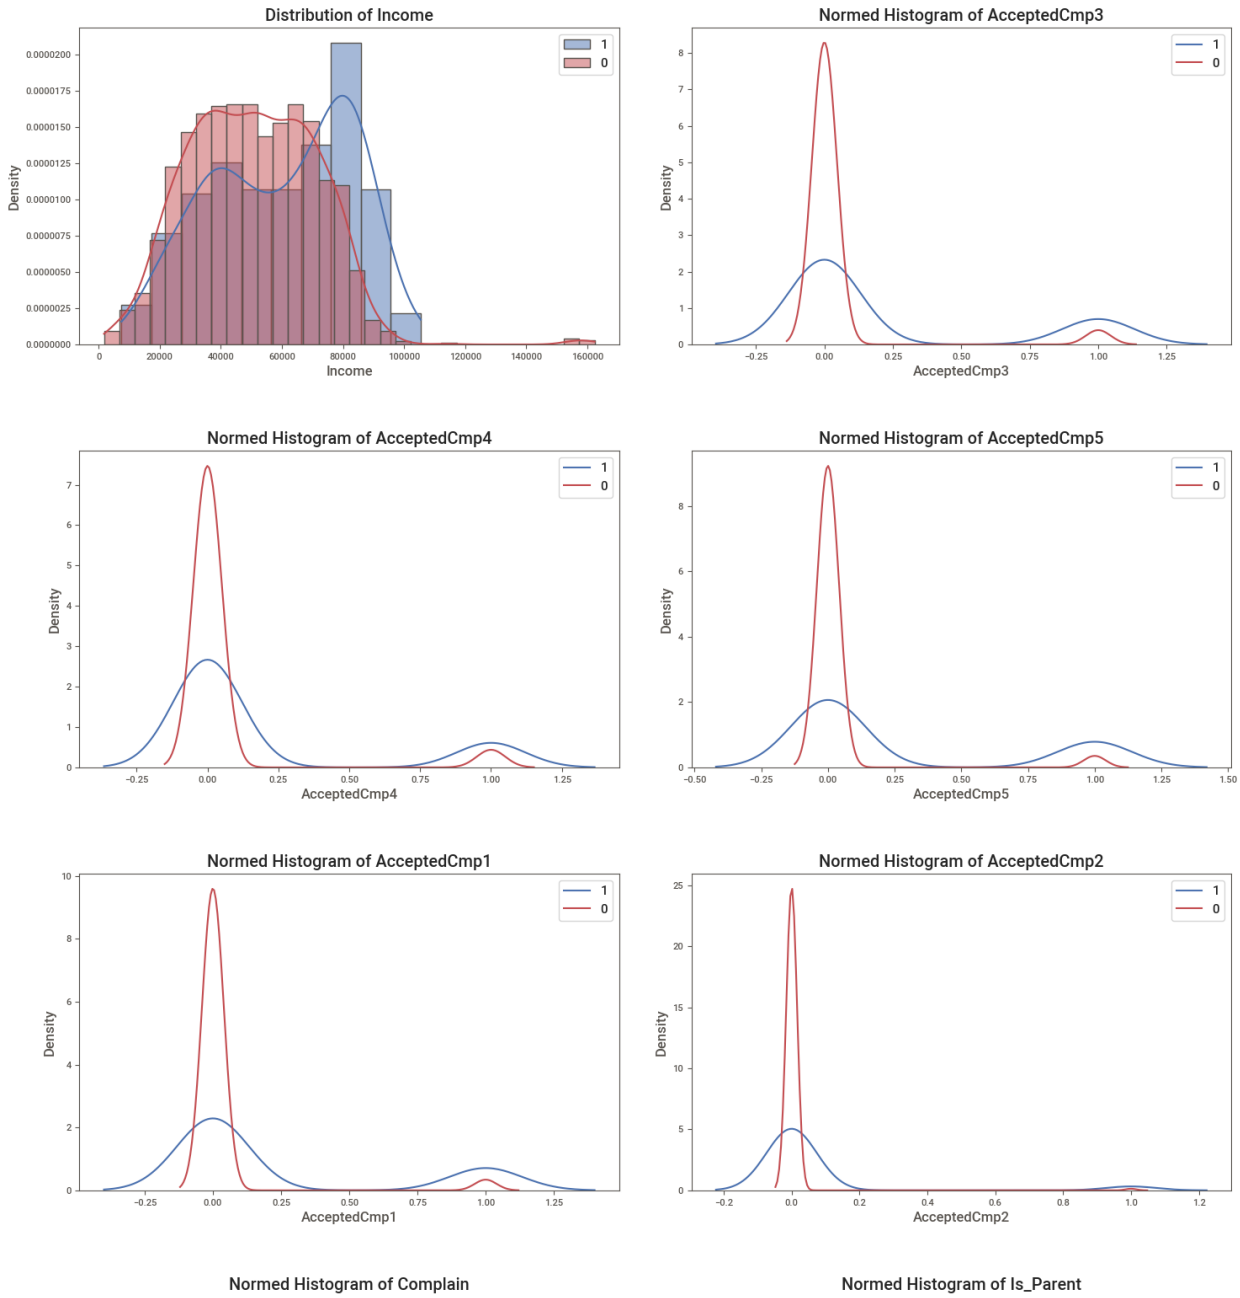
	Data Type	Missing Values%	Unique Values%	Minimum Value	Maximum Value	DQ Issue
Recency	int64	0.000000	4	0.000000	99.000000	No issue
MntWines	int64	0.000000	37	0.000000	1493.000000	Column has 33 outliers greater than upper bound (1225.50) or lower than lower bound(-698.50). Cap them or remove them.
MntFruits	int64	0.000000	7	0.000000	199.000000	Column has 206 outliers greater than upper bound (81.00) or lower than lower bound(-47.00). Cap them or remove them.
MntMeatProducts	int64	0.000000	27	0.000000	1725.000000	Column has 173 outliers greater than upper bound (549.75) or lower than lower bound(-304.25). Cap them or remove them.
MntFishProducts	int64	0.000000	8	0.000000	259.000000	Column has 203 outliers greater than upper bound (120.50) or lower than lower bound(-67.50). Cap them or remove them.
MntSweetProducts	int64	0.000000	8	0.000000	263.000000	Column has 225 outliers greater than upper bound (82.88) or lower than lower bound(-48.12). Cap them or remove them.
MntGoldProds	int64	0.000000	10	0.000000	362.000000	Column has 186 outliers greater than upper bound (126.50) or lower than lower bound(-61.50). Cap them or remove them.
NumDealsPurchases	int64	0.000000	0	0.000000	15.000000	Column has 78 outliers greater than upper bound (6.00) or lower than lower bound(-2.00). Cap them or remove them.
NumWebPurchases	int64	0.000000	0	0.000000	27.000000	Column has 4 outliers greater than upper bound (12.00) or lower than lower bound(-4.00). Cap them or remove them.
NumCatalogPurchases	int64	0.000000	0	0.000000	28.000000	Column has 22 outliers greater than upper bound (10.00) or lower than lower bound(-6.00). Cap them or remove them.
NumStorePurchases	int64	0.000000	0	0.000000	13.000000	No issue
NumWebVisitsMonth	int64	0.000000	0	0.000000	20.000000	Column has 8 outliers greater than upper bound (13.00) or lower than lower bound(-3.00). Cap them or remove them.
AcceptedCmp3	int64	0.000000	0	0.000000	1.000000	No issue
AcceptedCmp4	int64	0.000000	0	0.000000	1.000000	No issue
AcceptedCmp5	int64	0.000000	0	0.000000	1.000000	No issue
AcceptedCmp1	int64	0.000000	0	0.000000	1.000000	No issue
AcceptedCmp2	int64	0.000000	0	0.000000	1.000000	No issue
Complain	int64	0.000000	0	0.000000	1.000000	No issue
Age	int64	0.000000	2	28.000000	84.000000	No issue

	Data Type	Missing Values%	Unique Values%	Minimum Value	Maximum Value	DQ Issue
Total_Mnt	int64	0.000000	51	5.000000	2525.000000	Column has 3 outliers greater than upper bound (2512.75) or lower than lower bound(-1397.25). Cap them or remove them., Column has a high correlation with ['MntWines', 'MntMeatProducts']. Consider dropping one of them.
Total_Children	int64	0.000000	0	0.000000	3.000000	Column has 48 outliers greater than upper bound (2.50) or lower than lower bound(-1.50). Cap them or remove them.
Is_Parent	int64	0.000000	0	0.000000	1.000000	No issue
Total_Purchases	int64	0.000000	1	0.000000	32.000000	Column has a high correlation with ['NumStorePurchases', 'Total_Mnt']. Consider dropping one of them.
Response	int64	0.000000	0	0.000000	1.000000	Target column

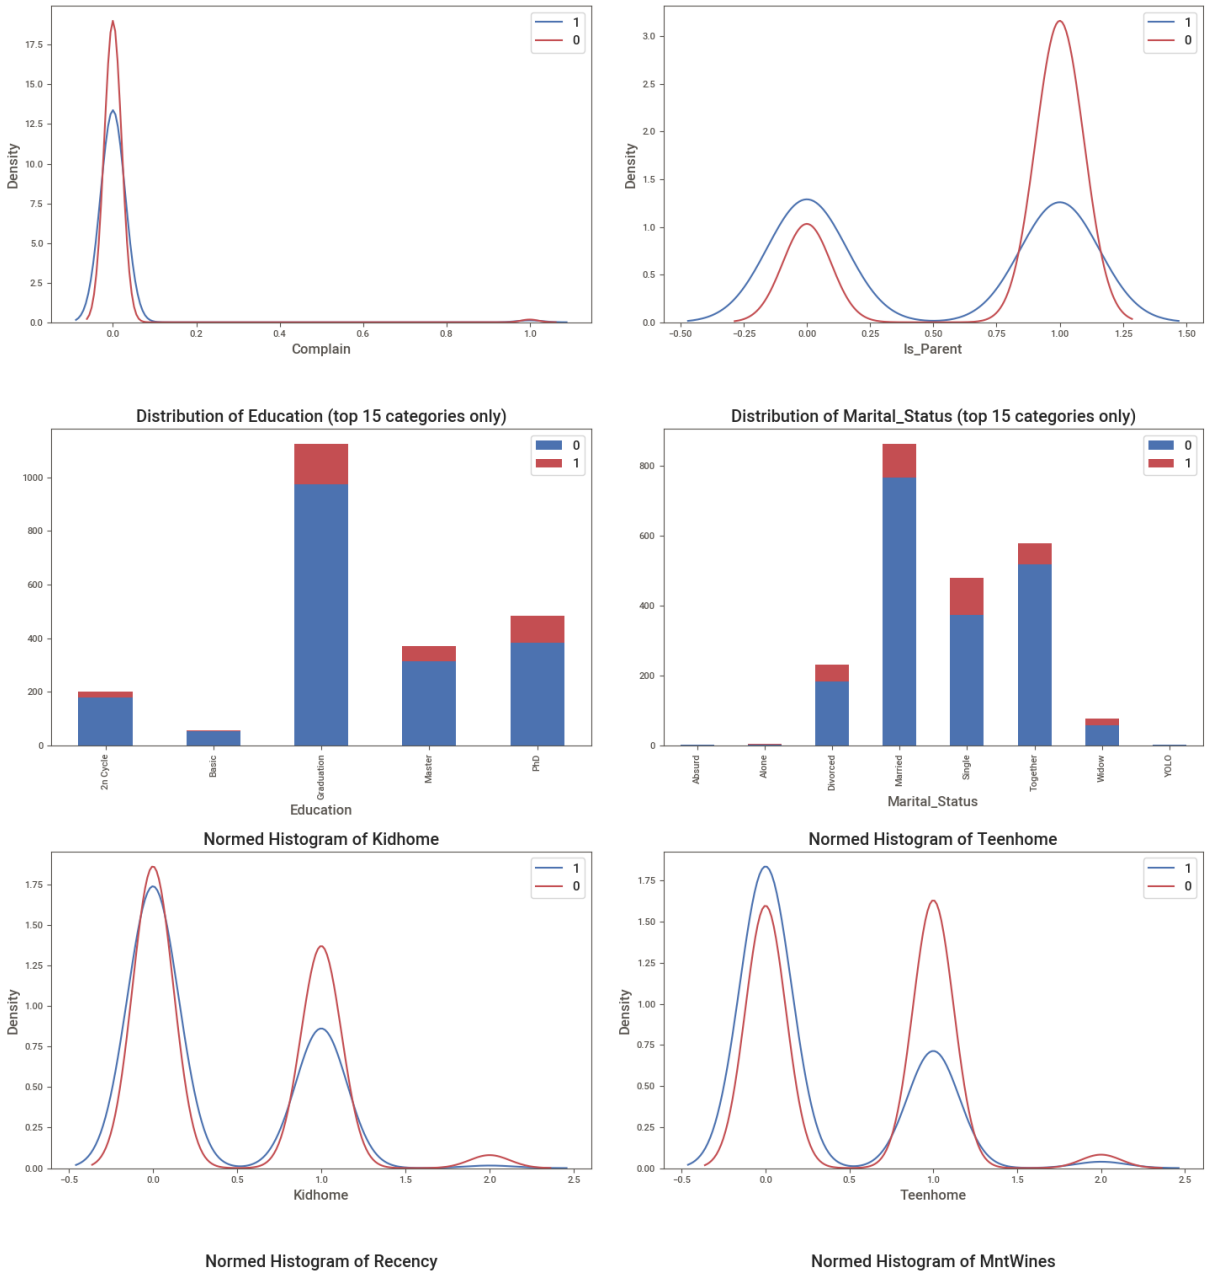
Bảng 4.10. Báo cáo chất lượng dữ liệu (Data Quality) do AutoViz tự sinh



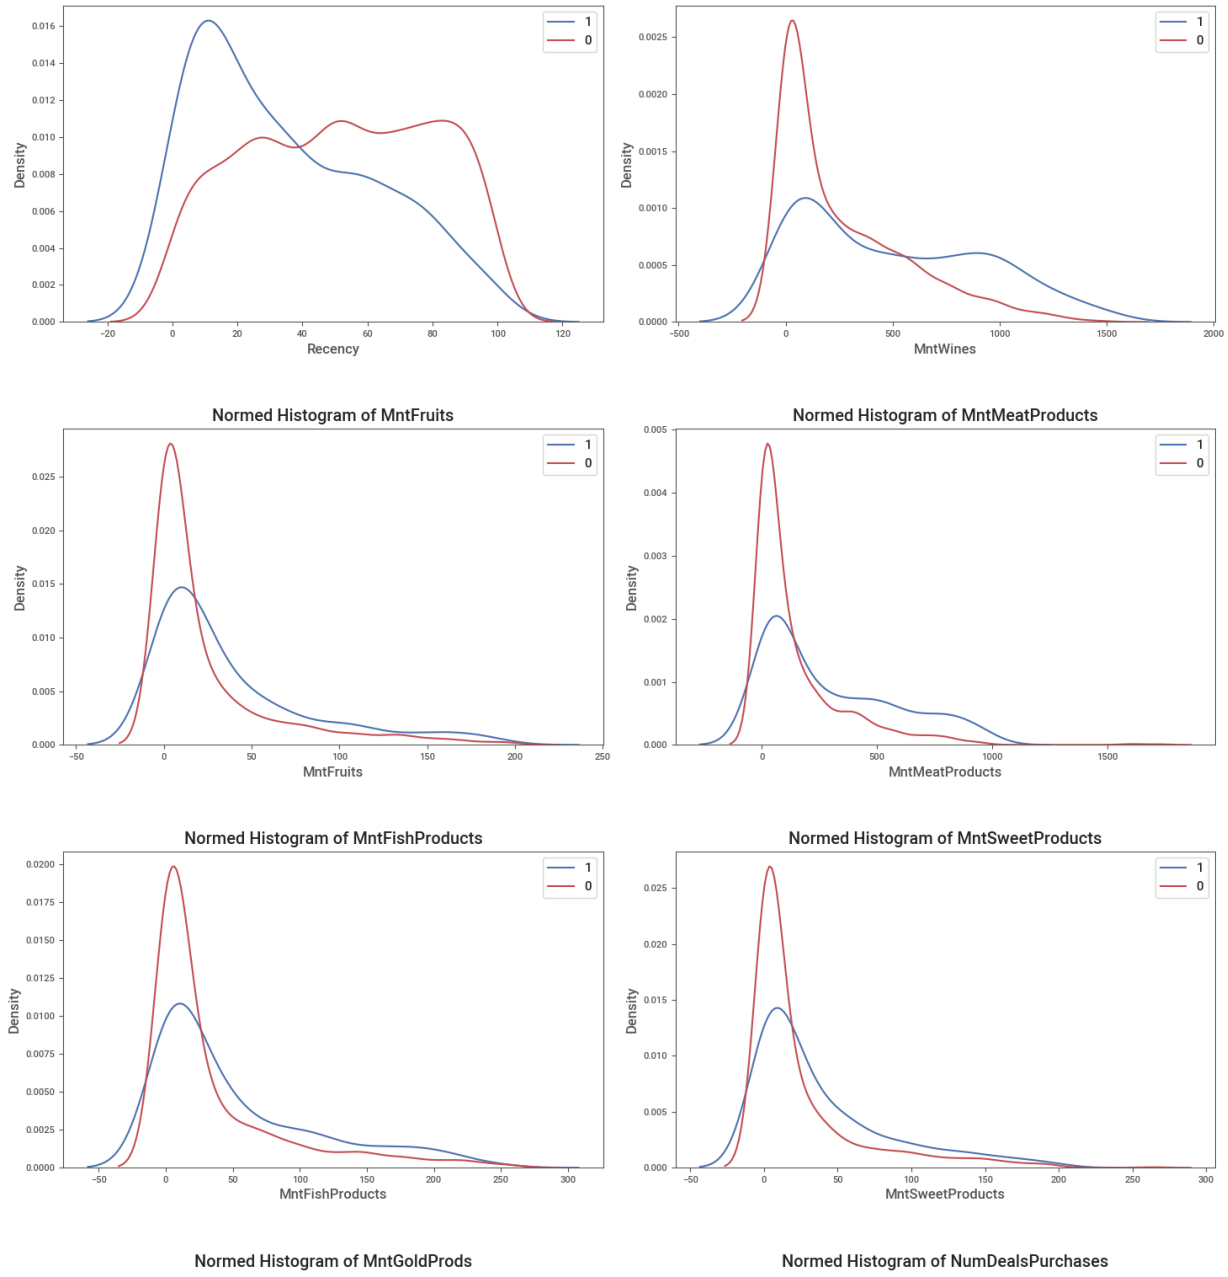
Hình 4.4. AutoViz – Scatter plot giữa Income và biến mục tiêu Response



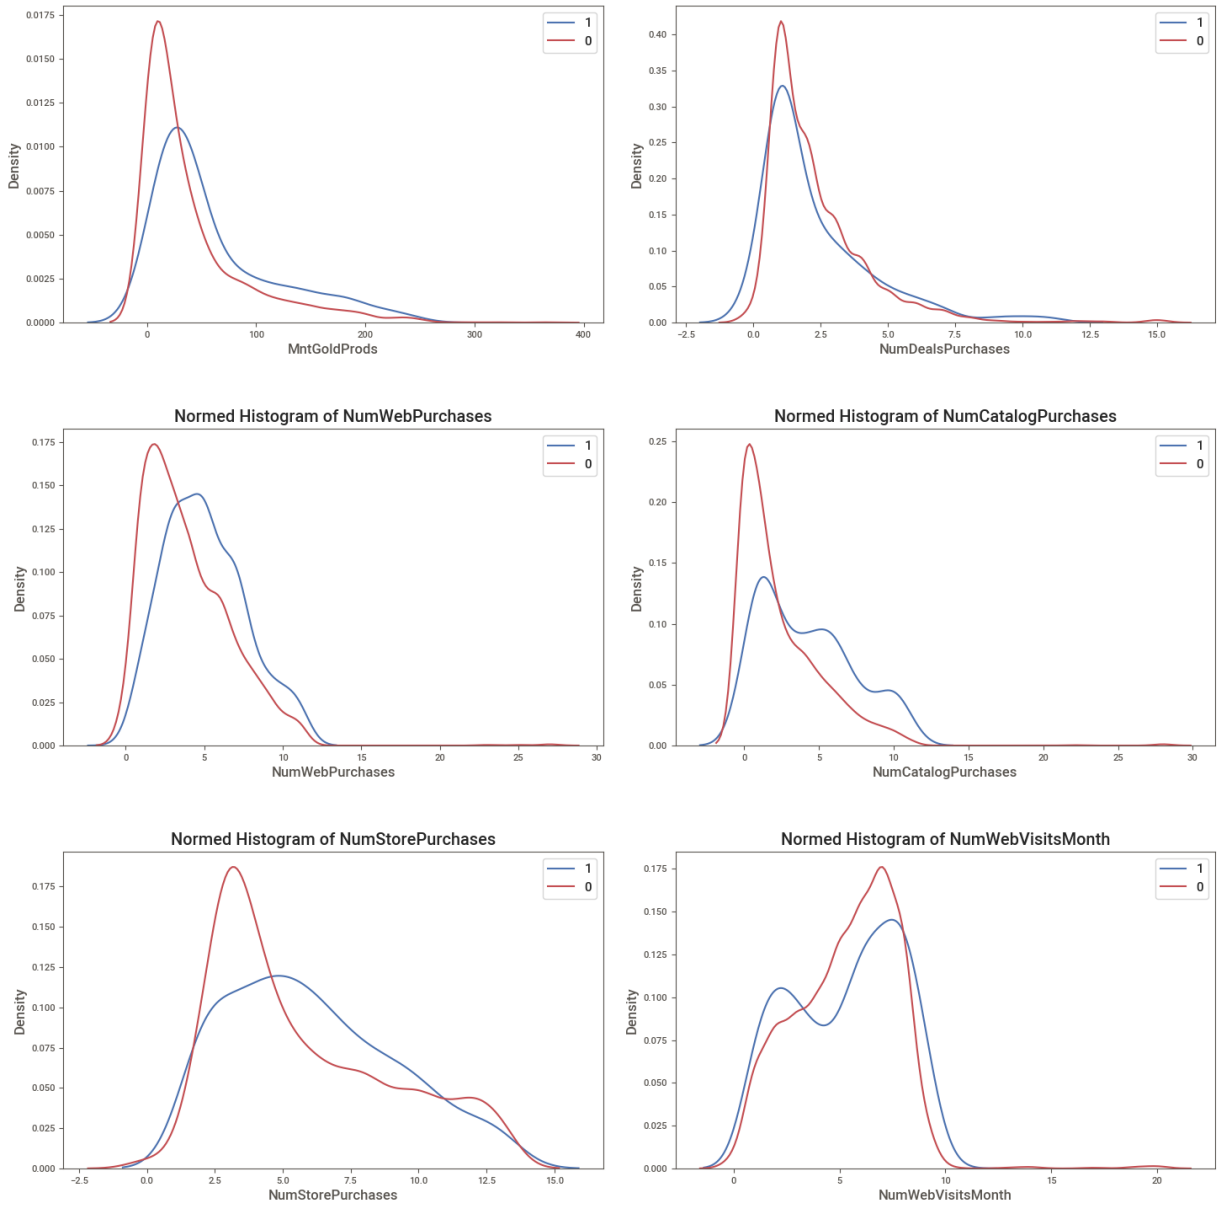
Hình 4.5. AutoViz – Distplot phân bố các biến theo Response (phần 1/5)



Hình 4.6. AutoViz – Distplot phân bố các biến theo Response (phần 2/5)



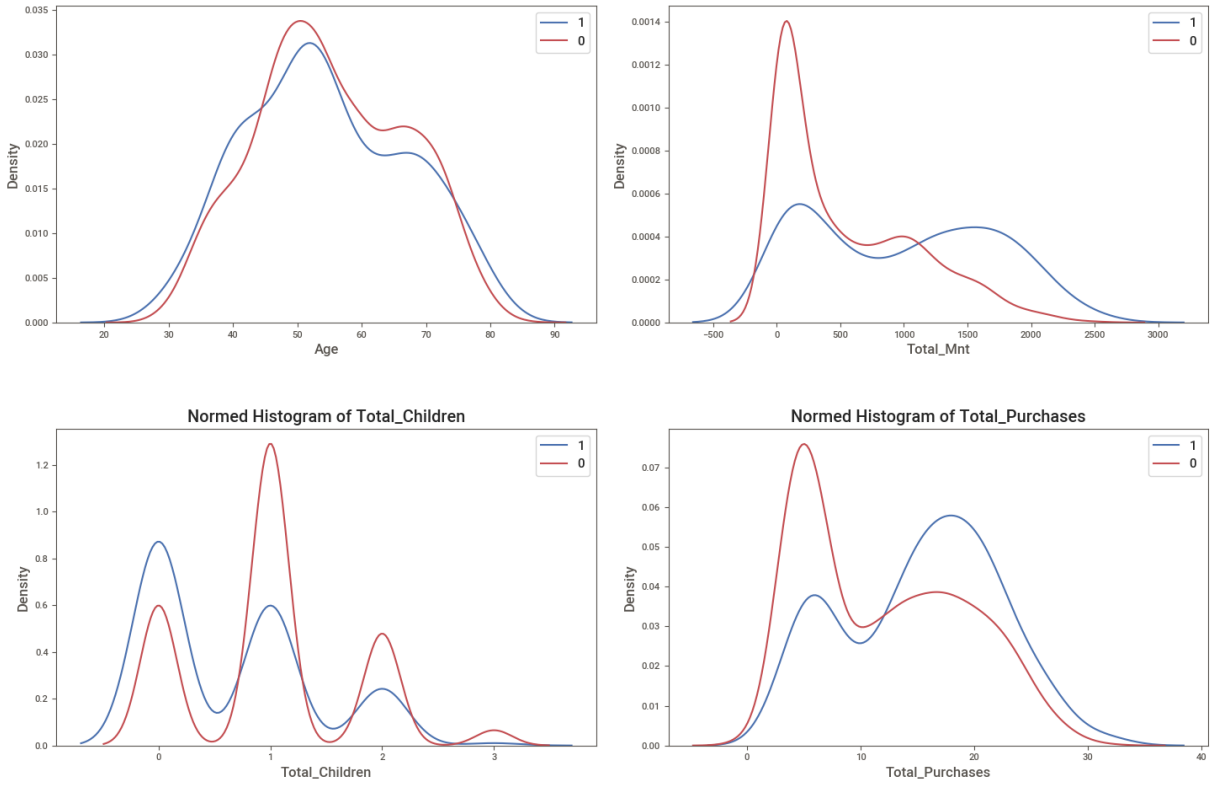
Hình 4.7. AutoViz – Distplot phân bố các biến theo Response (phần 3/5)



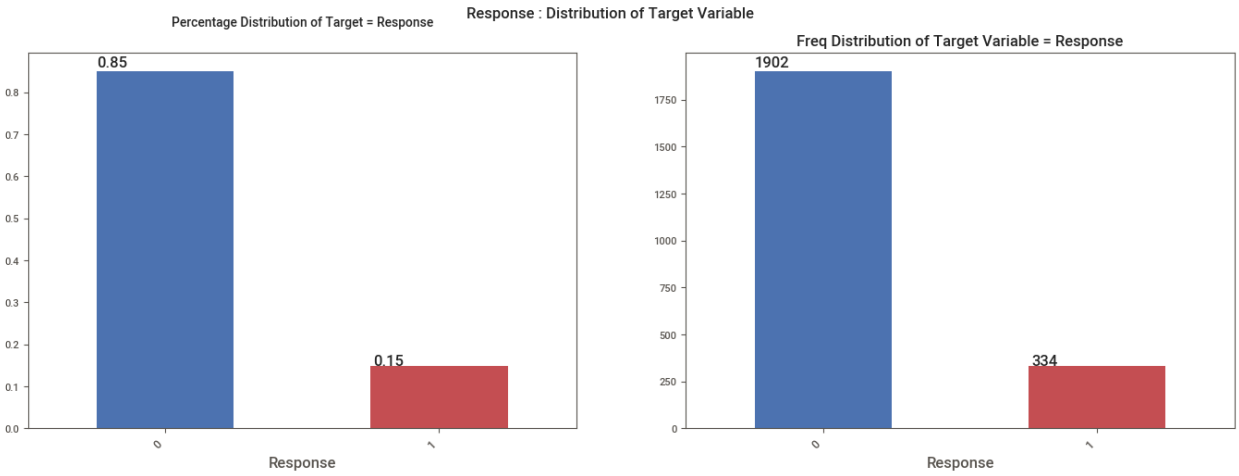
Normed Histogram of Age

Normed Histogram of Total_Mnt

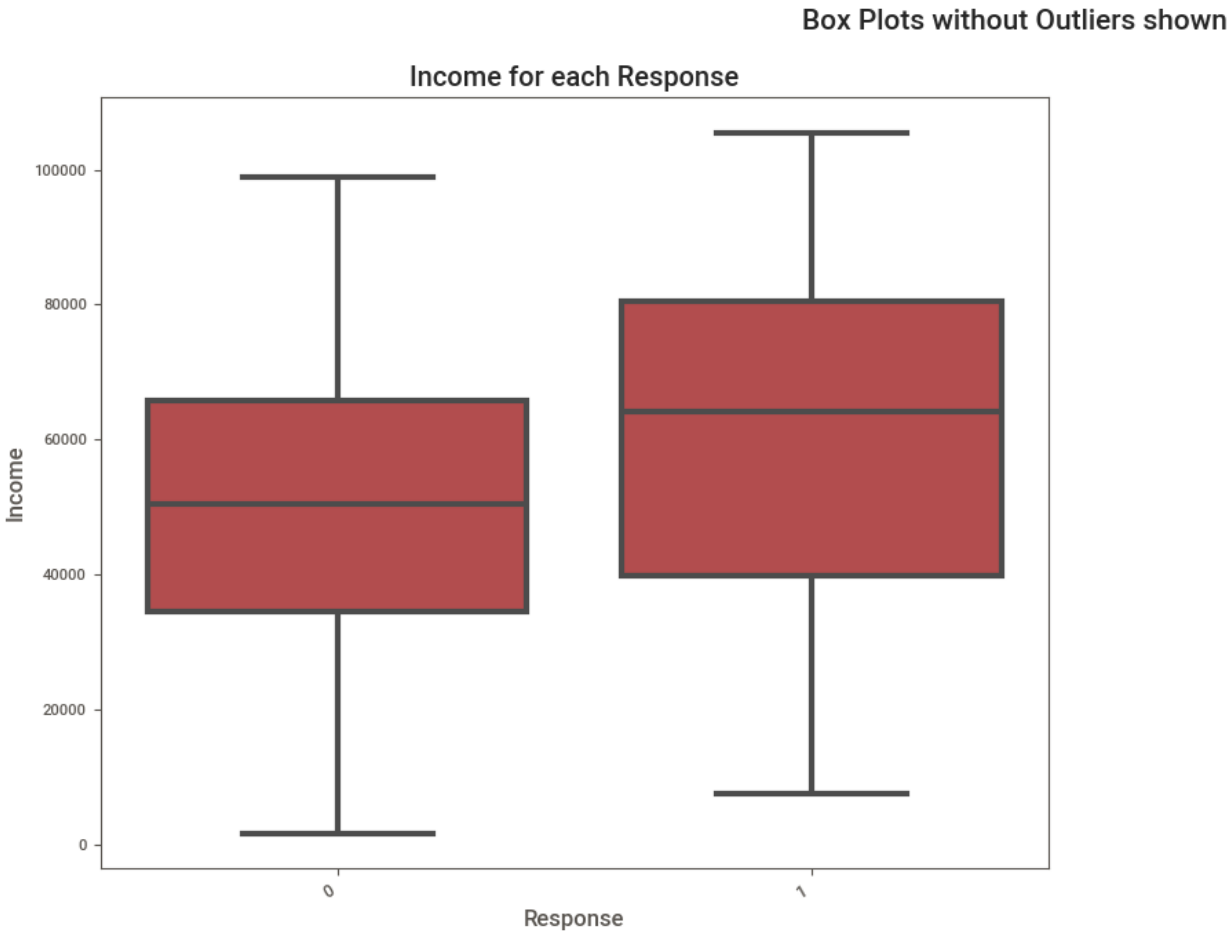
Hình 4.8. AutoViz – Distplot phân bố các biến theo Response (phần 4/5)



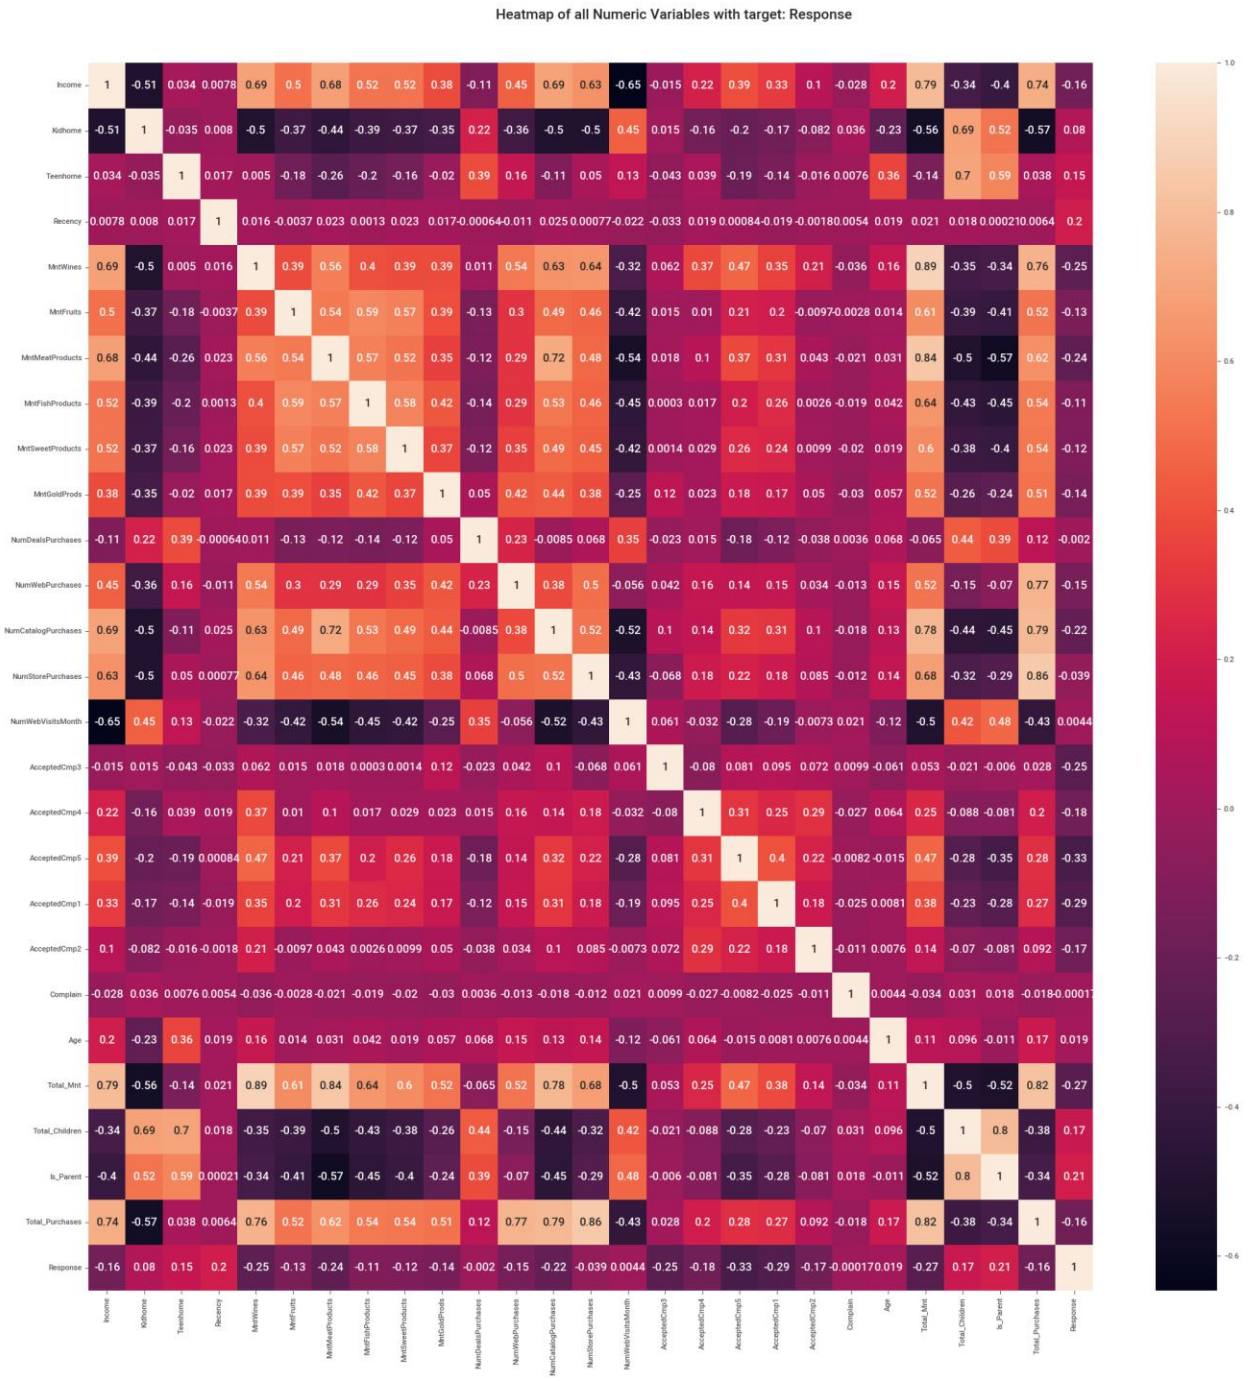
Hình 4.9. AutoViz – Distplot phân bố các biến theo Response (phần 5/5)



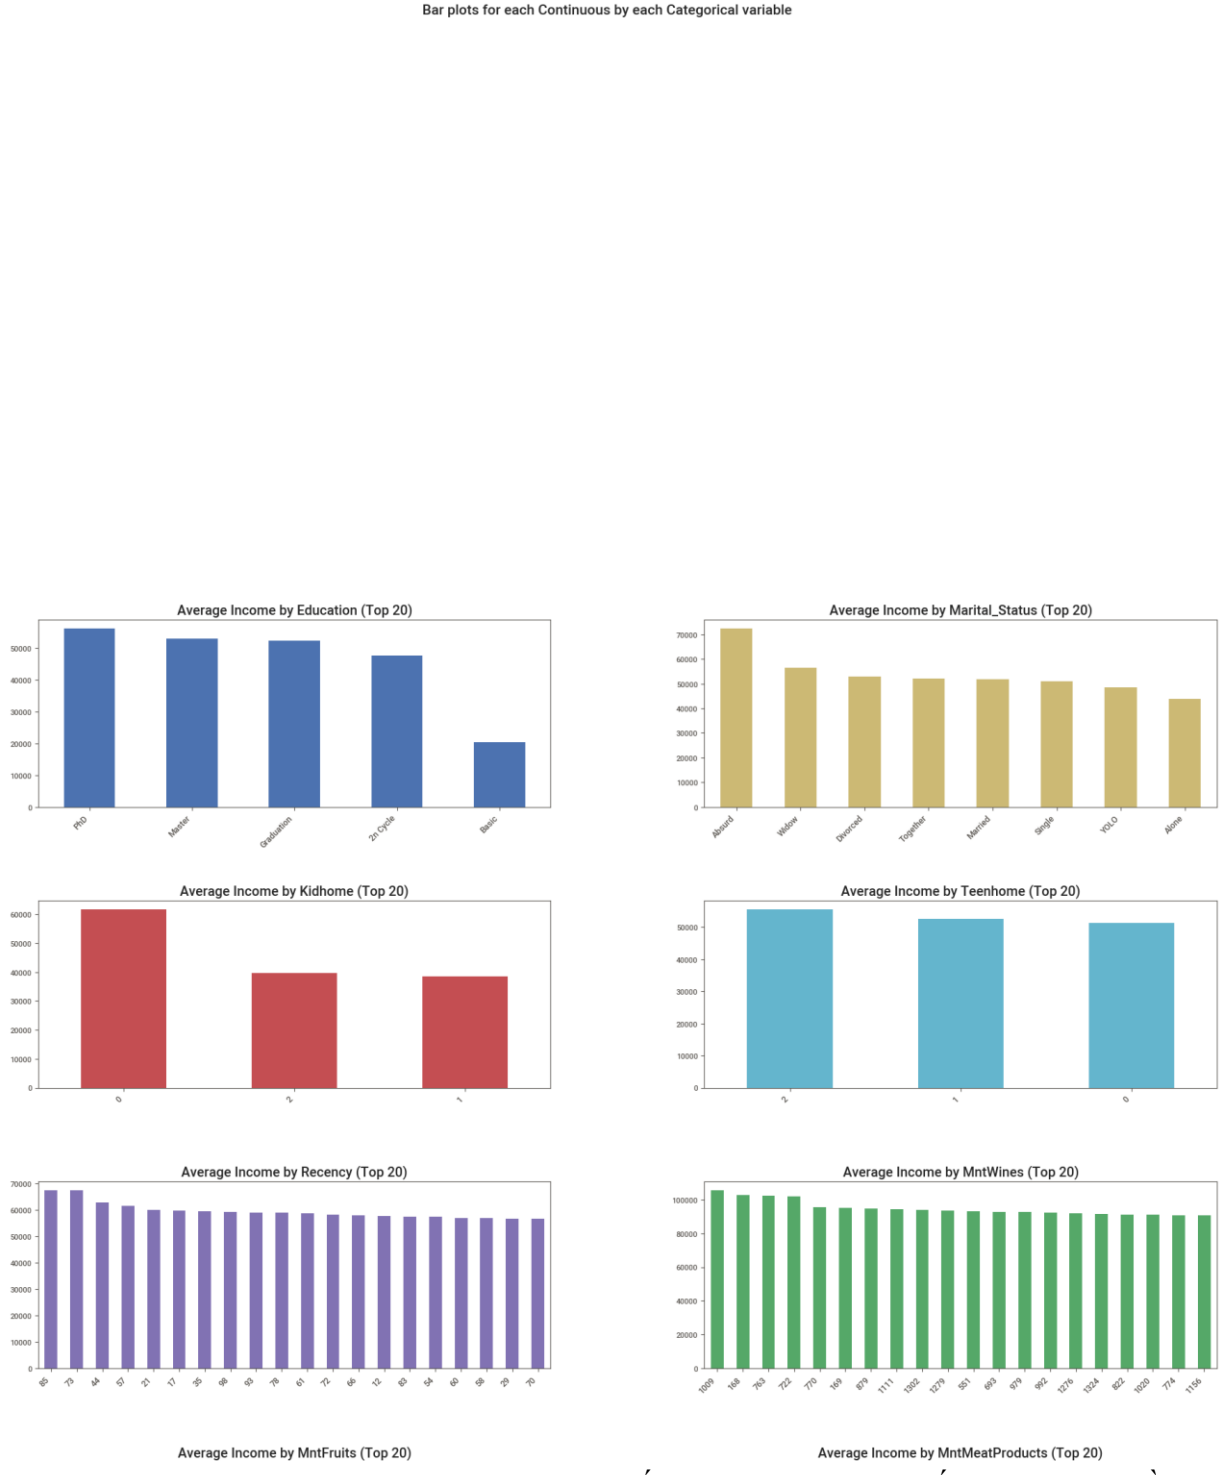
Hình 4.10. AutoViz – Phân phối của biến mục tiêu Response



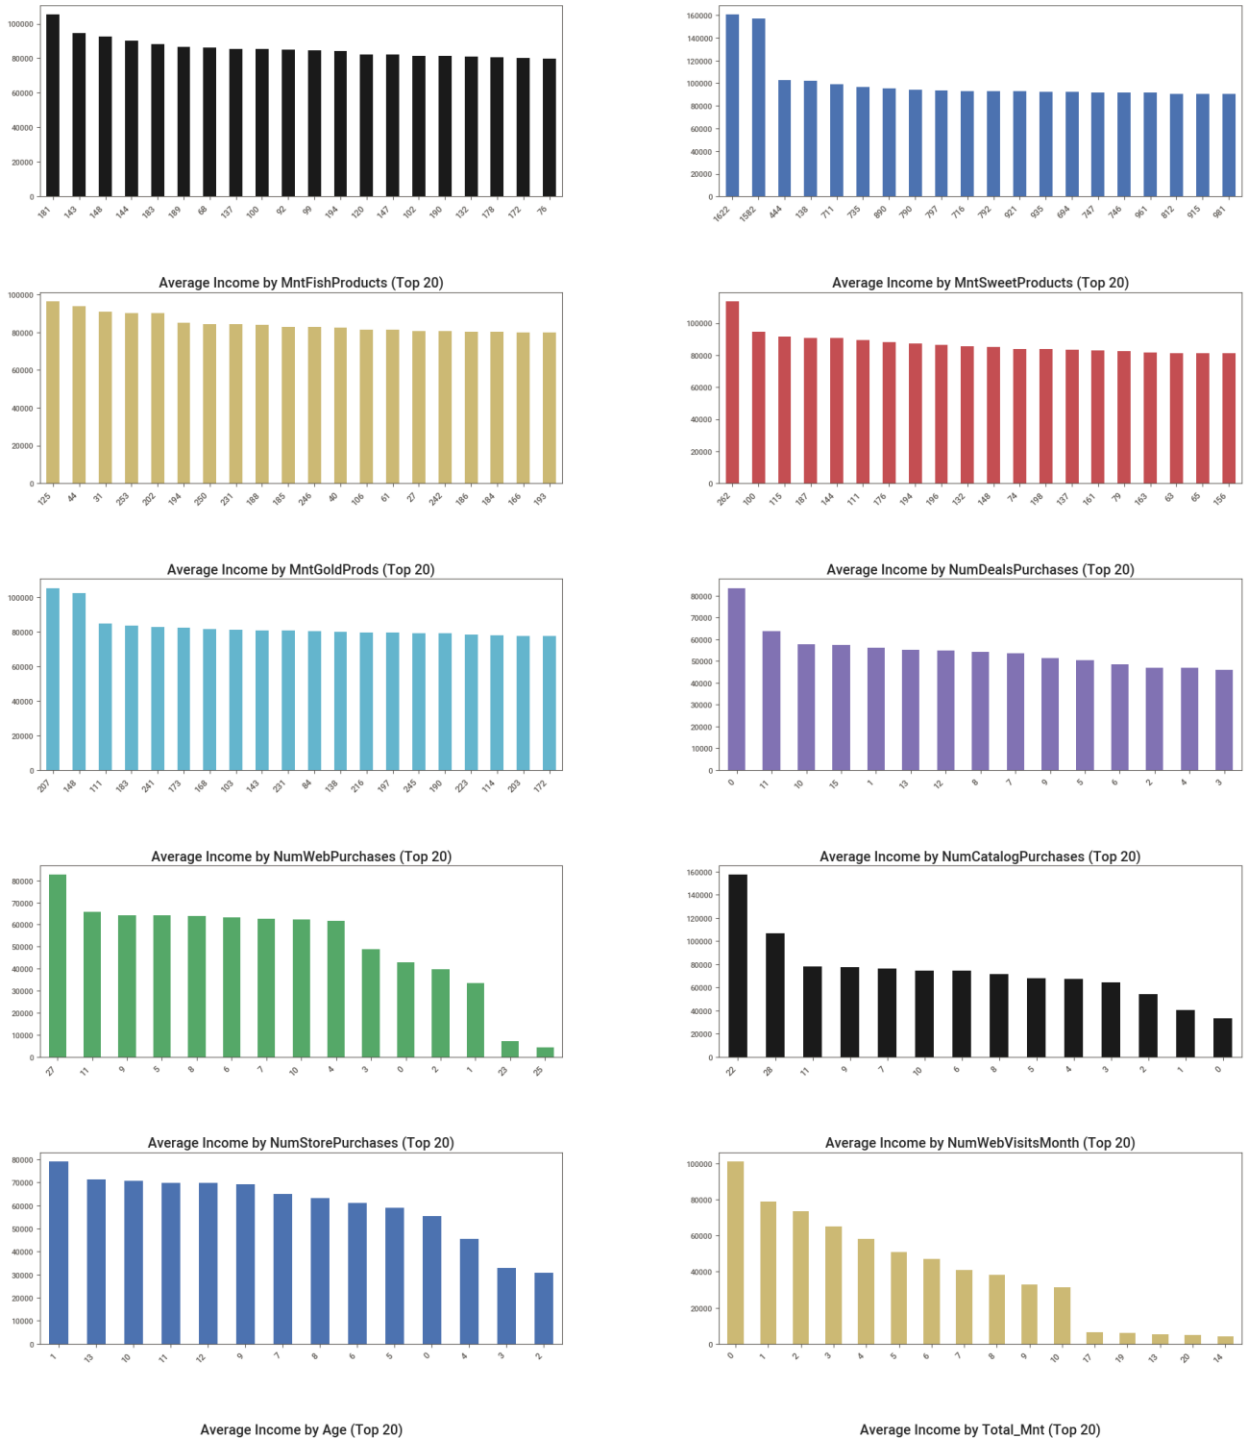
Hình 4.11. AutoViz – Boxplot Income theo Response



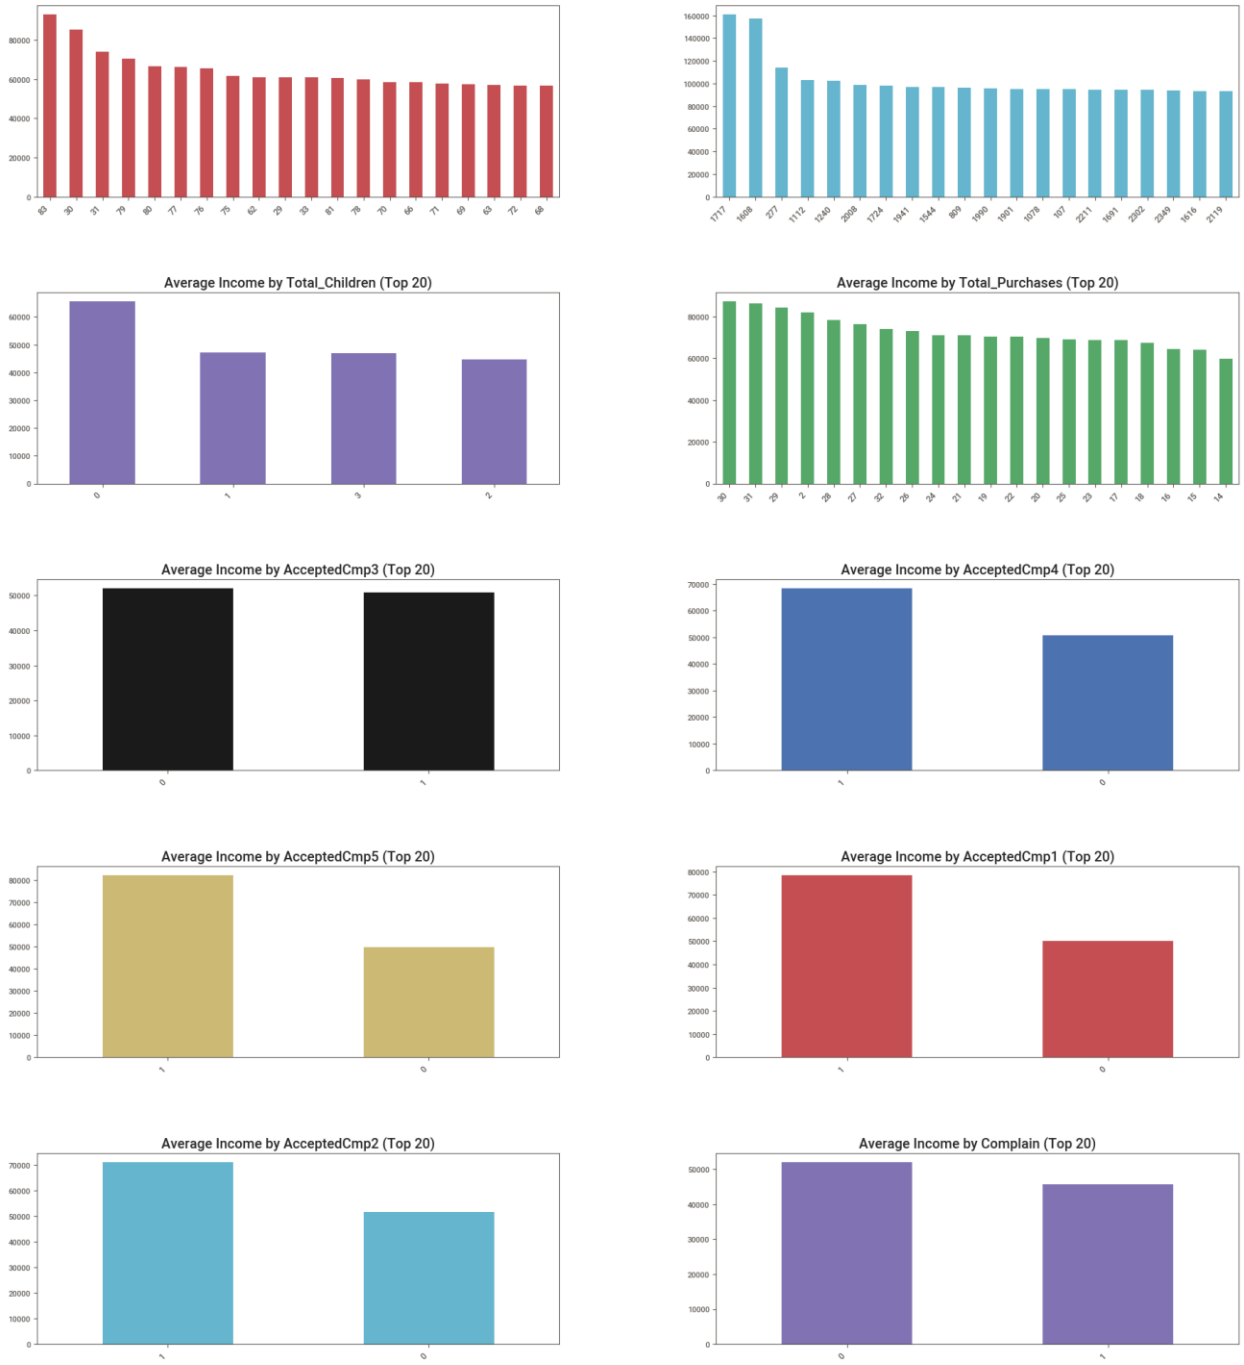
Hình 4.12. AutoViz – Heatmap tương quan giữa các biến số



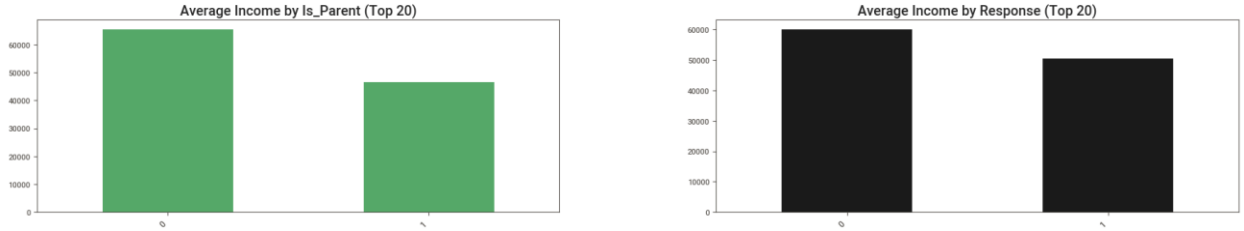
Hình 4.13. AutoViz – Bar plot giá trị trung bình biến liên tục theo từng biến phân loại (phần 1/4)



Hình 4.14. AutoViz – Bar plot giá trị trung bình biến liên tục theo từng biến phân loại (phần 2/4)



Hình 4.15. AutoViz – Bar plot giá trị trung bình biến liên tục theo từng biến phân loại (phần 3/4)



Hình 4.16. AutoViz – Bar plot giá trị trung bình biến liên tục theo từng biến phân loại (phần 4/4)

Nhận xét:

AutoViz tự động phân loại các biến trong dataset và tạo ra 5 nhóm biểu đồ chính:

1. **Pairwise Scatter Plots:** biểu đồ tán xạ phân tích mối quan hệ giữa các biến số với biến mục tiêu Response.
2. Distplots (Histograms + KDE): biểu đồ mật độ phân bố cho từng biến số độc lập.
3. **Violin Plots / Boxplots:** phân tích sự phân tán và giá trị ngoại lai (Outliers) giữa biến số và biến phân loại.
4. Bar Plots (Countplots): thống kê số lượng theo từng danh mục.
5. **Correlation Heatmap:** ma trận nhiệt hiển thị hệ số tương quan giữa tất cả các cặp biến số.

4.3.4. Phân tích chuyên sâu các nhóm biểu đồ do AutoViz tạo ra

Mục tiêu: trích xuất thông tin chi tiết từ từng nhóm biểu đồ đơn biến và hai biến do AutoViz tự động tạo ra.

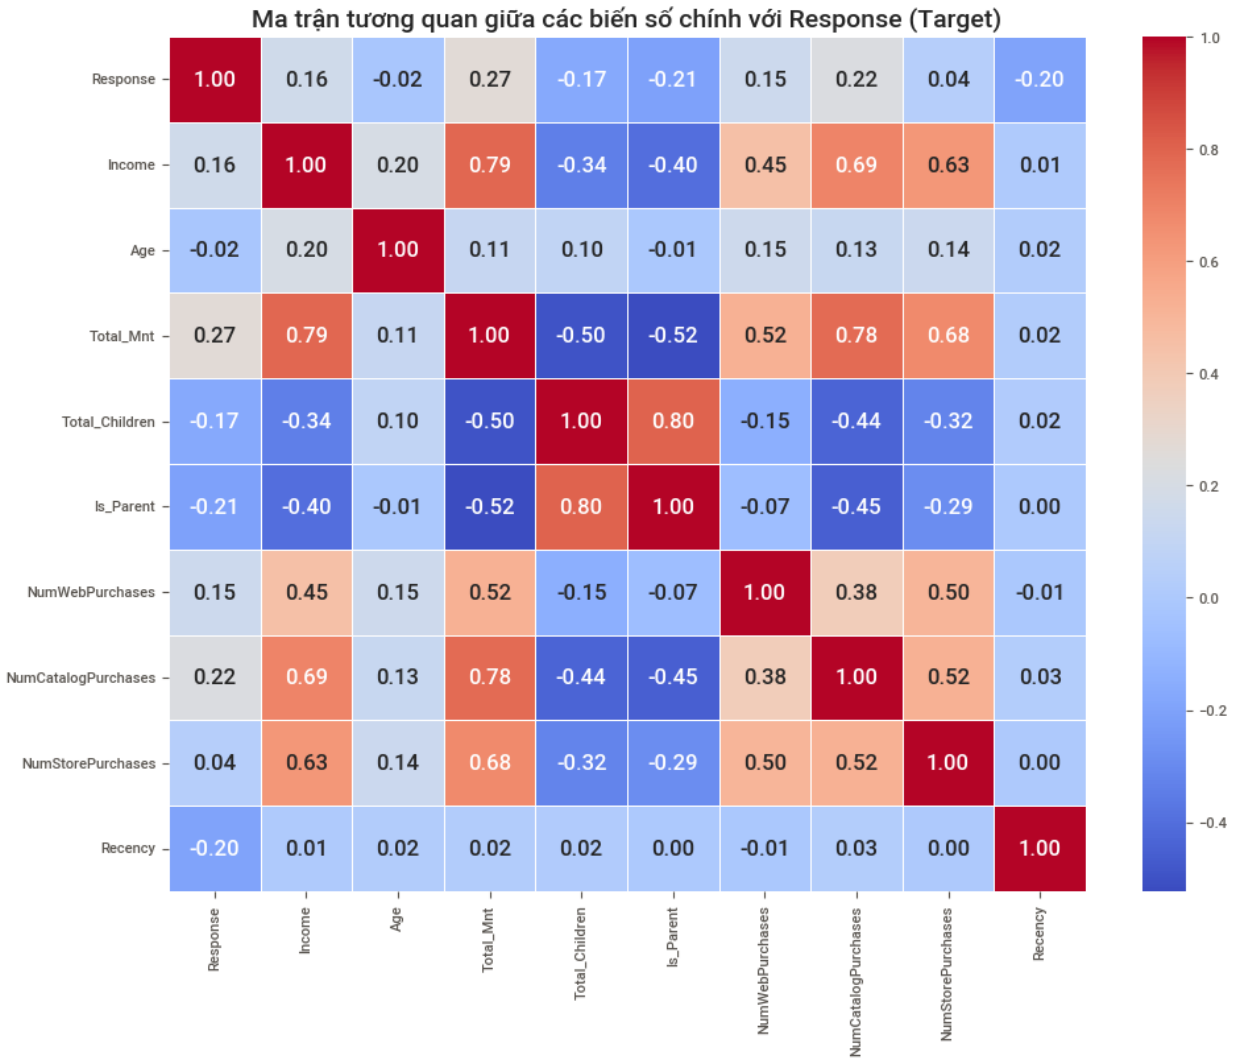
Trích xuất ma trận tương quan giữa các biến số chính với Response để kiểm chứng kết quả AutoViz

Để kiểm chứng kết quả của AutoViz, nhóm em tự vẽ lại ma trận tương quan giữa các biến số chính và Response:

```
plt.figure(figsize=(10, 8))
selected_cols = ['Response', 'Income', 'Age', 'Total_Mnt', 'Total_Children',
'Is_Parent',
                 'NumWebPurchases', 'NumCatalogPurchases', 'NumStorePurchases',
'Recency']

corr_matrix = df_clean[selected_cols].corr()
sns.heatmap(corr_matrix, annot=True, fmt='.2f', cmap='coolwarm', linewidths=0.5)
plt.title('Ma trận tương quan giữa các biến số chính với Response (Target)',
fontsize=14)
plt.show()
```

Kết quả thực thi:



Hình 4.17. Ma trận tương quan giữa các biến số chính và Response

Nhận xét & Insight:

1.Phân tích biểu đồ phân bố đơn biến (Distplots):

Income & Total_Mnt: phân bố lệch phải (Right-skewed) rõ rệt. Phần lớn khách hàng có thu nhập tập trung ở mức 30,000$ - 70,000$, chi tiêu phổ biến dưới 500$.

Age: phân bố dạng chuẩn (Gaussian) lệch nhẹ, tập trung chủ yếu từ độ tuổi 40 đến 65.

2. Phân tích biểu đồ hai biến tương quan với Target (Response):

Tác động của Income & Total_Mnt: khách hàng chấp nhận chiến dịch tiếp thị (Response = 1) nằm ở vùng chi tiêu cao và thu nhập cao. Mối tương quan giữa Total_Mnt với Response đạt +0.27, thể hiện khách hàng VIP là nhóm dễ chuyển đổi nhất.

Tác động của Is_Parent & Total_Children: biểu đồ Bar plots của AutoViz thể hiện rõ sự tương quan âm (-0.18) giữa số lượng con cái và khả năng phản hồi chiến dịch. Khách hàng chưa có con (Is_Parent = 0) có tỷ lệ tham gia chiến dịch cao vượt trội.

Kênh bán hàng thành công nhất: kênh mua hàng qua Catalog (NumCatalogPurchases) có mối tương quan thuận cao nhất (+0.22) với Response.

4.3.5. Đề xuất chiến lược kinh doanh từ kết quả AutoViz

Mục tiêu: tổng hợp các insight rút ra từ biểu đồ AutoViz để đưa ra khuyến nghị kinh doanh cụ thể cho phòng Marketing.

Trực quan hóa chi tiết mối quan hệ giữa kênh mua hàng với Response

Nhóm em trực quan hóa chi tiết số đơn hàng trung bình qua từng kênh mua hàng theo Response:

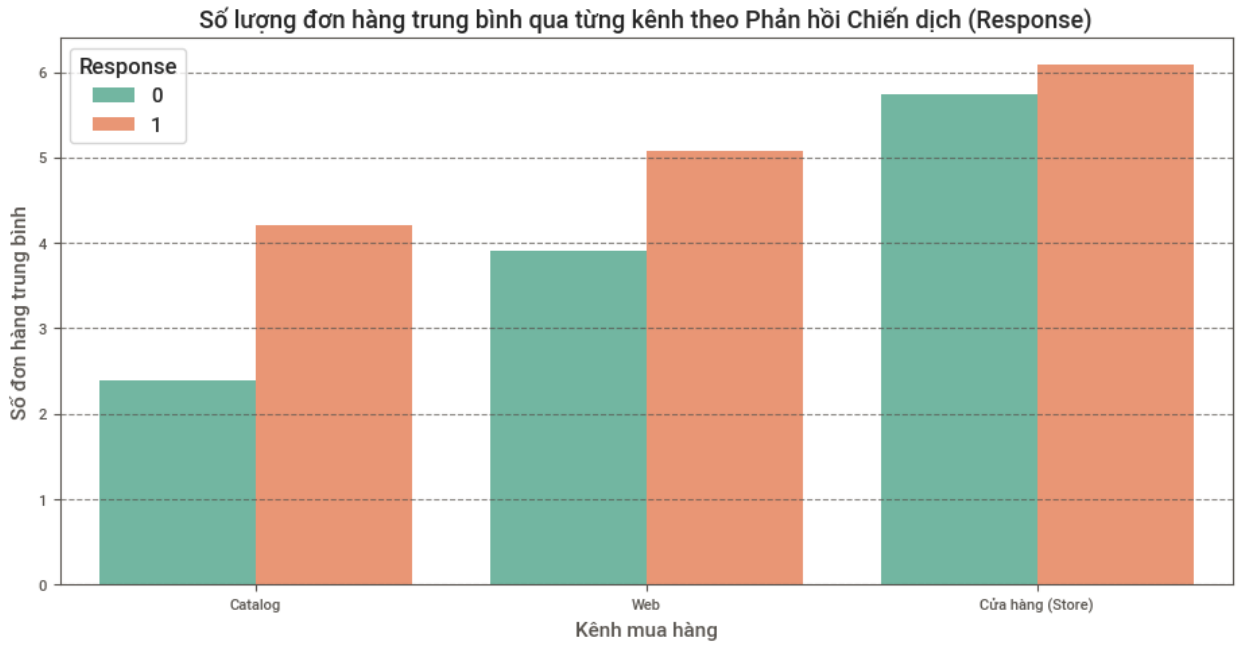
```
df_purchases = df_clean.groupby('Response')[['NumCatalogPurchases',
'NumWebPurchases', 'NumStorePurchases']].mean().reset_index()
df_purchases_melted = pd.melt(df_purchases, id_vars=['Response'],
var_name='Purchase_Channel', value_name='Avg_Purchases')

plt.figure(figsize=(10, 5))
sns.barplot(data=df_purchases_melted, x='Purchase_Channel', y='Avg_Purchases',
hue='Response', palette='Set2')
plt.title('Số lượng đơn hàng trung bình qua từng kênh theo Phản hồi Chiến dịch
(Response)', fontsize=13)
plt.xlabel('Kênh mua hàng', fontsize=11)
plt.ylabel('Số đơn hàng trung bình', fontsize=11)

plt.xticks(ticks=[0, 1, 2], labels=['Catalog', 'Web', 'Cửa hàng (Store)'])

plt.grid(axis='y', linestyle='--', alpha=0.7)
plt.show()
```

Kết quả thực thi:



Hình 4.18. Số đơn hàng trung bình qua từng kênh theo Response

Khuyến nghị tiếp thị thực tiễn:

1.Tập trung phân khúc hhách hàng thu nhập cao & chưa có con:

Đây là nhóm có giá trị giỏ hàng (Total_Mnt) cao nhất và xác suất chấp nhận chiến dịch cao gấp 3 lần bình thường.

2.Tối ưu hóa kênh tiếp thị Catalog:

Biểu đồ AutoViz chỉ ra rằng khách hàng phản hồi chiến dịch (Response = 1) có số lượt mua hàng qua Catalog trung bình cao gấp hơn 2 lần so với nhóm Response = 0. Cần gia tăng ngân sách quảng cáo trực tiếp qua Catalog và Email tiếp thị cá nhân hóa.

3.Cải thiện tỷ lệ chuyển đổi kênh Web:

Khách hàng ghé thăm Website rất nhiều nhưng tỷ lệ chuyển đổi đơn hàng qua Web ở nhóm có con chưa cao. Cần thiết kế các chương trình khuyến mãi gia đình (Family Package) để kích cầu.

4.3.6. Tổng kết Bài tập thực hành 2 (AutoViz) & so sánh tổng hợp các công cụ EDA

Mục tiêu: đánh giá ưu/nhược điểm của AutoViz và đối chiếu với các công cụ SweetViz, ydata-profiling, D-Tale.

In thống kê số lượng biểu đồ và thuộc tính đã được AutoViz phân tích tự động

Cuối cùng, nhóm em in thông tin tổng hợp về tiến trình AutoViz:

```
print("BÁO CÁO TỔNG HỢP TIẾN TRÌNH AUTOVIZ")
print(f"- Tổng số bản ghi đã xử lý: {df_clean.shape} dòng")
print(f"- Tổng số đặc trưng đã phân tích: {df_clean.shape[1]} cột")
print(f"- Biến mục tiêu (Target Variable): 'Response'")
print("--> AutoViz đã tự động xuất ra toàn bộ hệ thống biểu đồ Matplotlib/Seaborn
thành công.")
```

Kết quả thực thi:

```
BÁO CÁO TỔNG HỢP TIẾN TRÌNH AUTOVIZ
- Tổng số bản ghi đã xử lý: (2236, 30) dòng
- Tổng số đặc trưng đã phân tích: 30 cột
- Biến mục tiêu (Target Variable): 'Response'
--> AutoViz đã tự động xuất ra toàn bộ hệ thống biểu đồ Matplotlib/Seaborn thành công.
```

TỔNG KẾT BÀI THỰC HÀNH 2 (AUTOVIZ):

1. Về khả năng tự động hóa và trực quan hóa của AutoViz:

   Tự động hóa hoàn toàn: chỉ với lệnh AV.AutoViz(), thư viện tự động nhận diện kiểu dữ liệu và sinh trọn vẹn các nhóm biểu đồ đơn biến & hai biến (Scatter plots, Distplots, Boxplots, Barplots, Correlation Heatmap).

   Trực quan hóa Inline: các biểu đồ Matplotlib/Seaborn hiển thị trực tiếp ngay bên trong cell Kaggle Notebook, giúp kiểm tra kết quả nhanh chóng mà không cần mở file HTML riêng.

   Hiệu năng xử lý: tốc độ tạo biểu đồ rất nhanh, tối ưu tốt cho tập dữ liệu lớn nhờ cơ chế tự động lấy mẫu (max_rows_analyzed).

2. Insight kinh doanh chính rút ra từ hệ thống biểu đồ AutoViz:

   Phân khúc khách hàng tiềm năng: khách hàng có thu nhập cao (Income) và chưa có con (Is_Parent = 0) có tỷ lệ chấp nhận chiến dịch Marketing (Response = 1) cao gấp gần 3 lần nhóm có con.

   Kênh bán hàng hiệu quả nhất: mua hàng qua Catalog (NumCatalogPurchases) đóng vai trò quyết định với hệ số tương quan thuận cao nhất tới biến mục tiêu Response.

   Mặt hàng chủ lực: chi tiêu cho rượu (MntWines) và thịt (MntMeatProducts) chiếm hơn 70% tổng giá trị giỏ hàng (Total_Mnt).

KẾT LUẬN

Qua bài thực hành "Phân tích khám phá dữ liệu", nhóm em đã vận dụng đầy đủ quy trình EDA: nạp dữ liệu → kiểm tra chất lượng dữ liệu (khuyết thiếu, trùng lặp, ngoại lai, giá trị bất hợp lý) → thống kê mô tả → trực quan hóa đơn biến, hai biến, đa biến → rút ra nhận định. Các kết quả chính có thể tóm tắt như sau:

Thống kê mô tả (Chương 2): dữ liệu rượu đỏ có 240 dòng trùng lặp (còn 1.359 mẫu), chất lượng tập trung ở mức 5 – 6, alcohol (r = 0,48) và volatile_acidity (r = −0,40) ảnh hưởng mạnh nhất đến chất lượng; dữ liệu tiểu đường có khuyết thiếu ẩn dưới dạng giá trị 0 (Insulin 48,7%, SkinThickness 29,6%) và Glucose (r = 0,50) là chỉ số quan trọng nhất.

Xử lý và trực quan hóa (Chương 3): các biểu đồ làm rõ phân phối, ngoại lai, tương quan của dữ liệu rượu đỏ và tiểu đường; tỷ lệ mắc tiểu đường tăng theo tuổi và theo BMI. Với dữ liệu Online Retail, sau làm sạch còn 385.929 dòng (71,2%), UK chiếm 82,2% doanh thu, doanh thu đạt đỉnh tháng 11/2011 và 20% khách hàng tạo ra 73,4% doanh thu.

Phân tích đơn biến, hai biến với công cụ tự động (Chương 4): SweetViz và AutoViz giúp nhanh chóng xác định các yếu tố liên quan đến khả năng phản hồi chiến dịch: thu nhập, tổng chi tiêu, việc có con hay không và kênh mua hàng qua Catalog.

Bên cạnh kết quả đạt được, nhóm em cũng nhận thấy một số khó khăn đúng như tài liệu đã nêu: chất lượng dữ liệu thực tế thường không đảm bảo (giá trị thiếu, ngoại lai, dữ liệu không nhất quán), đòi hỏi nhiều thời gian tiền xử lý; với dữ liệu lớn như Online Retail, việc xác định các mẫu và xu hướng có ý nghĩa cũng phức tạp hơn. Ngoài ra, một số kỹ thuật xử lý (như điền trung vị theo nhóm Outcome) chỉ phù hợp cho mục đích khám phá, khi xây dựng mô hình cần tính toán trên tập huấn luyện để tránh rò rỉ thông tin.

Các công cụ EDA tự động như SweetViz, AutoViz giúp tiết kiệm đáng kể thời gian ở bước khảo sát ban đầu, nhưng không thể thay thế hoàn toàn việc phân tích thủ công:

người phân tích vẫn cần hiểu ý nghĩa nghiệp vụ của dữ liệu để lựa chọn cách xử lý và diễn giải kết quả cho đúng. Kết quả EDA trong báo cáo này là nền tảng để nhóm em tiếp tục các bước tiếp theo như lựa chọn đặc trưng và xây dựng mô hình học máy (phân loại chất lượng rượu, dự đoán bệnh tiểu đường, phân khúc khách hàng).

TÀI LIỆU THAM KHẢO

[1] Trường Đại học Sài Gòn, Khoa Công nghệ Thông tin, "Thực hành: Phân tích khám phá dữ liệu", Tài liệu thực hành môn Máy học.

[2] J. W. Tukey, Exploratory Data Analysis. Reading, MA: Addison-Wesley, 1977.

[3] W. McKinney, Python for Data Analysis: Data Wrangling with pandas, NumPy, and Jupyter, 3rd ed. Sebastopol, CA: O'Reilly Media, 2022.

[4] J. VanderPlas, Python Data Science Handbook: Essential Tools for Working with Data, 2nd ed. Sebastopol, CA: O'Reilly Media, 2023.

[5] P. Cortez, A. Cerdeira, F. Almeida, T. Matos, and J. Reis, "Modeling wine preferences by data mining from physicochemical properties," Decision Support Systems, vol. 47, no. 4, pp. 547–553, 2009.

[6] J. W. Smith, J. E. Everhart, W. C. Dickson, W. C. Knowler, and R. S. Johannes, "Using the ADAP learning algorithm to forecast the onset of diabetes mellitus," in Proc. Annual Symposium on Computer Application in Medical Care, 1988, pp. 261–265.

[7] D. Chen, S. L. Sain, and K. Guo, "Data mining for the online retail industry: A case study of RFM model-based customer segmentation using data mining," Journal of Database Marketing & Customer Strategy Management, vol. 19, no. 3, pp. 197–208, 2012.

[8] F. J. Anscombe, "Graphs in statistical analysis," The American Statistician, vol. 27, no. 1, pp. 17–21, 1973.

[9] Kaggle, "Red Wine Quality – EDA & Classification." [Online]. Available: https://www.kaggle.com/code/eisgandar/red-wine-quality-eda-classification

[10] Kaggle, "Pima Indians Diabetes – EDA & Prediction." [Online]. Available: https://www.kaggle.com/code/vincentlugat/pima-indians-diabetes-eda-prediction-0-906

[11] Kaggle, "EDA Online Retail." [Online]. Available: https://www.kaggle.com/code/rajatkumar30/eda-online-retail

[12] Kaggle, "Customer Personality Analysis." [Online]. Available: https://www.kaggle.com/datasets/imakash3011/customer-personality-analysis

[13] pandas development team, "pandas documentation." [Online]. Available: https://pandas.pydata.org/docs/

[14] SciPy community, "Statistical functions (scipy.stats)." [Online]. Available: https://docs.scipy.org/doc/scipy/reference/stats.html

[15] J. D. Hunter, "Matplotlib: A 2D graphics environment," Computing in Science & Engineering, vol. 9, no. 3, pp. 90–95, 2007.

[16] M. L. Waskom, "seaborn: statistical data visualization," Journal of Open Source Software, vol. 6, no. 60, p. 3021, 2021.

[17] F. Bertrand, "Sweetviz." [Online]. Available: https://pypi.org/project/sweetviz/

[18] AutoViML, "AutoViz: Automatically Visualize any dataset." [Online]. Available: https://pypi.org/project/autoviz/